

激光雷达雪花模拟以实现稳健的3D目标检测

Martin Hahner¹ Christos Sakaridis¹ Mario Bijelic²

Felix Heide² Fisher Yu¹ Dengxin Dai^{1,3} Luc Van Gool^{1,4}

¹ 苏黎世联邦理工学院 ² 普林斯顿大学 ³ MPI信息学研究所 ⁴ 鲁汶大学

摘要

3D 目标检测是自动驾驶等应用的核心任务，系统需要在恶劣天气条件下定位和分类周围的交通参与者。在本文中，我们解决了雪天条件下基于LiDAR的3D目标检测问题。由于在此环境中收集和标注训练数据困难，我们提出了一种基于物理的方法，模拟雪花对真实晴天LiDAR点云的影响。我们的方法在每条LiDAR线上以二维空间采样雪粒子，并利用由此引发的几何变化相应地修改每个LiDAR束的测量值。此外，由于降雪常导致地面潮湿，我们还模拟了LiDAR点云上的地面湿润。我们利用该模拟生成部分合成的雪天LiDAR数据，并用这些数据训练对雪天具有鲁棒性的3D目标检测模型。我们进行了广泛的评估，采用多种先进的3D目标检测方法，结果显示我们的模拟在真实的雪天STF数据集上持续带来显著的性能提升，相较于晴天基线和其他模拟方法，同时在晴天条件下性能未受影响。我们的代码可在github.com/SysCV/LiDAR_snow_sim获取。

1. 引言

激光雷达（LiDAR）传感器是一种主动测距传感器，适用于多种应用[10, 27, 39, 61]。其高质量的三维输出使其成为需要三维推理的任务（如三维目标检测[25, 59]）的首选模态。随着LiDAR传感器成本逐渐降低[53]，其在自动驾驶汽车中的集成也变得更加可行。

然而，以前的传感器测试显示，这种主动脉冲系统在散射介质中容易受到影响，导致在各种天气条件下感知距离缩短，例如雨[4, 14, 52]、雾[2, 4, 18, 19]、雪[19, 24, 28]，如图1所示。在这些条件下，光学介质中含有水或雪的颗粒，它们与激光束相互作用，吸收、反射或折射其光子。




图1。在大雪中使用所提出的数据增强方案（右上角）进行3D目标检测的结果，与无增强（左上角）进行比较。底部显示RGB图像作为参考。

这会带来两个效果：(i) 目标视线上的接收功率衰减，以及 (ii) 粒子的后向散射导致的虚假最大值，从而在不同于目标真实距离的范围内产生虚假回波。因此，由于强烈的噪声、与晴朗天气下点云相比的较大域偏移，测量质量严重下降，进而对高层任务如3D目标检测的性能产生不利影响[1, 16]。然而，在恶劣天气中实现鲁棒感知是一个理想目标，因为据美国交通部[49]和欧洲委员会[8]报道，恶劣天气下人类驾驶员的死亡率明显更高。

由于难以收集恶劣天气数据[1]，之前的研究已探讨了在雾[36]和雨[48]中通过模拟方法缩小相机数据的域差距。

最近,已经提出用于LiDAR传感器信息[1,16]和降雨[14,22]的模拟方法。受到此类工作的启发,我们引入了一种基于物理的模拟雪花在真实晴朗天气LiDAR点云上的方法。特别地,我们使用[33]中引入的线性系统模型来模拟LiDAR脉冲的传输及其在传感器处的接收功率。我们通过显式采样雪粒子并将其建模为不透明的球体,控制其大小的雪花速率[15,32],来模拟降雪。在采样过程中,我们遵守排斥原则,即没有两个粒子相交。给定雪粒子样本后,我们计算每个LiDAR光束与之相交的粒子集,并推导出每个粒子反射的光束截面角度,考虑潜在的遮挡。这一推导直接提供了在降雪条件下线性系统的修正冲激响应,从而可以解析计算传感器的接收功率。

与降雪相关的另一种情况是地面湿润。这层新出现的薄水层增加了地面反射的镜面成分[44]。为了模拟地面反射,我们引入了一种使用菲涅尔方程和薄表面反射的光学模型,为湿润表面提供了适应的反射率值。

我们利用包含雪和湿润地面的部分合成点云作为训练数据,用于优化最先进的3D目标检测方法,从而使学习到的模型在降雪条件下更具鲁棒性。希望我们的物理基础模拟足够逼真,能免除使用真实雪景训练样本的需求。我们在具有挑战性的STF数据集[1]的真实雪景子集上对在此条件下训练的模型进行基准测试,发现基于我们模拟雪的模型在性能上持续优于仅在晴朗天气和其他模拟方法训练的基线模型,取得显著提升。

2. 相关工作

恶劣天气研究可以细分为提供计算机视觉方法基础知识的气象学出版物[15,32,33,38],引入不同天气条件扰动模式的现象学推理[2,4,24],以及将计算机视觉算法应用于这些具有挑战性的条件[1,29,37,48]。在[33]中,研究了预测各种天气类型对LiDAR影响的通用理论框架,包括雨、雾和雪。作者根据散射粒子的统计分布研究这些天气效应,例如在[15]和[38]中引入的雪的散射粒子分布。关于降雪中能见度的进一步影响在[32]中提出。

这些由此产生的扰动模式及其强度在[4,14,52]的降雨、在[2,4,18,19,52]的雾、在[19,24,28]的雪以及在[5,44,56]的湿润表面上进行了现象学研究。作者在算法上尝试通过鲁棒融合算法[1]、用于[36,48]的数据增强模拟技术以及用于[1,14,16,22]的LiDAR数据模拟技术来应对这些条件。作者还研究了在[6,17,43]中去除恶劣天气影响的增强技术,或在[37]中应用领域适应方法,将清晰天气算法调整至恶劣天气。包含恶劣天气样本的深度数据集已在[1,3,29,37,46]中引入。然而,由于恶劣天气样本稀少且代表性不足[1],传统的数据循环方法难以应用。

恶劣天气模拟能够缓解恶劣天气影响的罕见性以及数据收集活动中的困难,例如通过数据合成在[35,36,48]中所示。此外,它能够生成具有明确真实情况的可重现条件,这对于学习[17,43]中的图像增强技术或研究[48]中不同天气影响下可重现的恶劣天气噪声相关性能下降是必要的。[1,14,16,22]中明确研究了激光雷达模拟方法。相关研究始于[1]中在雾天采用的数据驱动方法,[16]对其进行了扩展,引入了基于物理的模型并实现了更高的3D目标检测性能。[14]中介绍了一种针对降雨的模拟方法,[22]中提出了一种针对雪、雨和雾的通用方法。与[22]不同,我们的降雪模拟在功率信号域采用了连续公式,这使我们能够叠加不同粒子的反射,并推断粒子与目标之间的遮挡情况,从而更好地符合激光传输的物理原理。此外,我们考虑了湿滑路面的影响,从而能够以数据驱动的方式根据干燥路面的强度来估计激光硬件参数,如噪声基底和发射强度。

近年来,3D目标检测取得了巨大进展。针对RGB相机[45,54,60]、激光雷达[25,31,39–42,62]、门控成像仪[20]或[7,23,30,51]中多模态融合,已经提出了几种方法。然而,在许多数据集排行榜上,顶级性能排名通常都在基于激光雷达的方法[3,13,46]中决出。在我们的工作中,我们采用了PV-RCCN[39]、VoxelRCNN-Car[9]、CenterPoint[59]、Part-A2[42]、PointRCNN[41]、SECOND[57]和Point-Pillars[25]这些方法。这些方法在点云表示、使用的特征提取骨干网络和检测阶段数量上有所不同。作为输入模态,点云可以在体素空间[39,40,42,57,62]中处理,推断原始点云[31,41],或者使用如[25]中支柱这样的抽象表示。




图2. 一种LiDAR传感器的示意图，其中发射器Tx和接收器Rx没有同轴光学系统，而是具有平行轴（称为双基地光束配置）。

检测阶段的数量通常分为单阶段[25]和两阶段方法[39-41, 57, 59, 62]，其中单阶段方法直接离散化输入空间，并为每个单元预测目标，遵循[26]的做法。两阶段方法先预测候选，然后在后续的池化特征空间中进行细化，遵循[34]的基本思想。

3. 基于LiDAR点云的降雪模拟

在自由空间中，脉冲传播可以用几何光学模型来模拟，以实现成本效益高的激光雷达系统。这类系统采用一组同步的近场红外脉冲发射器Tx和雪崩光电二极管（APD）作为接收器Rx，如图2所示并在[55]中描述。发射的激光脉冲 P_0 被固体场景物体（通常称为目标）反射，反射率为 ρ_0 ，并被接收器捕获，提供捕获回波的时间延迟 τ 及其对应的功率 P_R 。物体距离 R 通过应用 $R = c\tau$ 计算，其中 c 为光速。物体的三维位置 $[x, y, z]$ 通过发射脉冲的方向获得。对于扩展物体，可以应用几何光学[11]模型来模拟接收功率 P_R ，如下所示

$$P_R(R) = C_A P_0 \rho_0 \frac{\cos(\alpha_{in})}{R^2}, \quad (1)$$

这适用于直径大于距离 R 处光束直径的物体，并且需要额外的信息 (i) 入射角 α_{in} 和 (ii) 与距离和时间无关的系统常数 C_A 。然而，接收的激光功率通常会进行校正[11]，因为每个扫描层的 C_A 不同，原因是光学系统和光束发散角不同。根据[21]，可以报告四个不同级别的强度校准。对于我们实验中使用的 Velodyne HDL-S3D 传感器，按照传感器手册[50]，进行了光束发散角校正。该校正定义为

$$i = P_R + f_s \left| f_o - \left(1 - \frac{R}{R_{max}} \right) \right|^2, \quad (2)$$

其中 f_s 是焦距斜率， f_o 是焦距偏移。每个激光器的参数均来自出厂校准。

在应用所提出的模拟方法之前，我们首先通过反转此强度校准来获取原始强度。在降雪条件下，光学介质中包含比光束直径更小的颗粒，因此必须考虑米散射以及颗粒的精确空间分布[33]。

在非弹性散射条件下，散射粒子存在时的脉冲传播由[33]中引入的线性模型描述，该模型表达了范围相关的接收功率 P_R ，作为时间上的传输信号功率 P_T 与光学系统的冲激响应 H 的卷积：

$$P_R(R) = C_A \int_0^{2R/c} P_T(t) H\left(R - \frac{ct}{2}\right) dt, \quad (3)$$

传输脉冲的时间特征由

$$P_T(t) = \begin{cases} P_0 \sin^2\left(\frac{\pi}{2\tau_H} t\right), & 0 \leq t \leq 2\tau_H, \\ 0 & \text{otherwise.} \end{cases} \quad (4)$$

τ_H 为半功率脉冲宽度，设为 10 ns，适用于 Velodyne HDL-S3D 传感器。冲激响应 H 可以分解为光学通道的冲激响应 H_C 和目标的冲激响应 H_T ：

$$H(R) = H_C(R) H_T(R). \quad (5)$$

H_C 取决于光束发散角、由 $\xi(R)$ 描述的发射器与接收器的重叠，以及介质的透射率 $T(R)$ 。

$$H_C(R) = \frac{T^2(R)}{R^2} \xi(R). \quad (6)$$

在未被雪粒占据的介质部分，假设不存在其他散射体，透过率 $T(R)$ 等于1。重叠部分 $\xi(R)$ 可以从图2中几何推导得出

$$\xi(R) = \begin{cases} 0, & R \leq R_1 \\ \frac{R-R_1}{R_2-R_1}, & R_1 < R < R_2 \\ 1, & R_2 \leq R. \end{cases} \quad (7)$$

目标的脉冲响应 H_T ，使我们能够模拟雪粒，具体如下所述。

场景反射通过 H_T 定义了粒子与激光脉冲的相互作用。对于一个扩展的固体目标，我们可以写成

$$H_T(R) = \rho_0 \delta(R - R_0), \quad (8)$$

其中 ρ_0 是目标的反射率， δ 是狄拉克δ函数。然而，在降雪中，除了固体目标外，激光束也会被雪粒部分反射。




图3. 对应雪降率 $r_s = 2.5 \text{ mm/h}$ 的模拟降雪。左侧块显示清晰未受干扰的输入。右侧块上方是我们的降雪模拟，下方是LISA [22]中的降雪模拟。请注意，我们以真实的方式模拟散射，只衰减受单个雪花影响的点，而不是根据距离衰减所有点。




图4. 雪粒干扰单个激光雷达束（上图）。对应的接收功率回波示意图（下图）。注意单个目标的接收功率可能与其他目标重叠 ($c\tau_H \approx 3 \text{ m}$ 与 $\tau_H = 10 \text{ ns}$)。

我们将雪粒子 j 建模为具有反射率 ρ_s 、直径 D_j 、遵循[15]中引入的分布、距离传感器 R_j 的球形物体，并在传感器周围随机均匀放置，以避免与其他粒子相交。粒子数量根据降雪速率选择，通常在 0-2.5毫米/小时范围内（详细信息请参见补充材料）。粒子可以遮挡彼此和目标物体，如图4（上）所示。因此，每个粒子 j 仅反射光束开角 Θ 的一部分 θ_j/Θ ，同时允许一部分 θ_0/Θ 的光束到达目标。关于计算比例 θ_j/Θ 的详细信息也在补充材料中提供。

假设所有 j 的 $D_j \ll c\tau_H$ ，我们可以写出

$$H_T(R) = \frac{1}{\Theta} \left(\rho_0 \theta_0 \delta(R - R_0) + \rho_s \sum_{j=1}^n \theta_j \delta(R - R_j) \right), \quad (9)$$

与 $\Theta = \theta_0 + \sum_{j=1}^n \theta_j$ 一起。在将(4)、(5)、(6)和(9)代入(3)后，雪中接收的功率为

$$P_{R,\text{snow}}(R) = P_{R,\text{snow}}^0(R) + \sum_{j=1}^n P_{R,\text{snow}}^j(R), \quad (10)$$

其中

$$\begin{aligned} P_{R,\text{snow}}^j(R) &= \frac{C_A P_0 \rho_s \theta_j \xi(R_j)}{\Theta R_j^2} \int_0^{2\tau_H} \sin^2 \left(\frac{\pi}{2\tau_H} t \right) \delta \left(R - \frac{ct}{2} - R_0 \right) dt \\ &= \begin{cases} \frac{C_A P_0 \rho_s \theta_j \xi(R_j)}{\Theta R_j^2} \sin^2 \left(\frac{\pi(R - R_j)}{c\tau_H} \right), & R_j \leq R \leq R_j + c\tau_H \\ 0 & \text{otherwise.} \end{cases} \end{aligned} \quad (11)$$

$P_{R,\text{snow}}^0(R)$ 可以通过将 (θ_j, R_j, ρ_s) 替换为 (θ_0, R_0, ρ_0) ，并代入(11)的右侧推导得出。

接收的功率因此是多个回波的叠加，每个回波与一个物体（雪粒或目标物）相关，如图4（底部）所示。关键在于，每个回波的幅值取决于角度 θ_j 和该物体到传感器的距离的倒数平方 R_j 。在本工作中，我们将接收功率的最大峰值作为LiDAR的返回值。因此，如果由于雪粒引起的峰值高于与目标物相关的峰值，就会错过真实的回波，并在模拟点云中在前者的距离处添加一个杂波点。




图5。干燥高速公路上的真实场景（上），水位为 $d_w = 0.53$ mm 的真实场景（中），以及从清晰参考中合成的道路湿度（下）。

算法1 LiDAR降雪模拟

过程 SNOWFALL ($\mathbf{pc}, n_l, \tau_H, R_{\max}, \Theta, r_s, \rho_s, \rho_0$)

对 l 在 n_l 中执行

$\mathbf{pc}_l \leftarrow \mathbf{pc}.\text{SELECT}(\text{layer} = l)$

$f_d, f_s, i_{\max} \leftarrow \text{载入校准}(l)$

$f_o \leftarrow \left(\frac{1-f_s}{13100} \right)^2 \triangleright \text{焦距偏移 [50]}$

$\mathbf{s} \leftarrow \text{SAMPLE_SNOWFLAKES}(R_{\max}, r_s) \triangleright \text{在 2D 中 [15]}$

对 $\mathbf{p}$ 在 $\mathbf{pc}_l$ 中执行 $\triangleright$ ，对层 l 中的每个点

$x, y, z, i \leftarrow \mathbf{p}$

$R_0 \leftarrow \|\mathbf{p}\|_2$

$\mathbf{t} \leftarrow \text{获取束中的粒子}(\mathbf{s}, x, y, R_0, \Theta) \triangleright$ ，在 2D 中

如果 $\text{len}(\mathbf{t}) > 1$ 则 $\triangleright$ 否则无干扰

$\mathbf{P}_{R, \text{snow}} \leftarrow \mathbf{0} \triangleright \text{初始化为零}$

对于 i, R, θ 在 $\mathbf{t}$ 中，执行 $\triangleright$ ，针对每个目标

如果 $R = R_0$ 则 $\triangleright$ 原始目标

$$P_R \leftarrow i - f_s \left| f_o - \left(1 - \frac{R}{R_{\max}} \right) \right|^2 \text{ ———}$$

$$C_A P_0 \leftarrow \frac{P_R}{\rho_0} R_0^2 \triangleright \text{推导自式 (1)}$$

17: 否则 $\triangleright \text{snowflake}$

$$18: P_R \leftarrow \rho_s i_{\max}$$

$$19: C_A P_0 \leftarrow \frac{P_R}{\rho_0}$$

20: 结束 if

$$21: \mathbf{P}_{R, \text{snow}} += \text{Eq. (11)}(C_A P_0, R, \rho, \tau_H, \theta, \Theta)$$

22: 结束 for

$$23: P_R \leftarrow \max(\mathbf{P}_{R, \text{snow}})$$

$$24: R^* \leftarrow \arg \max(\mathbf{P}_{R, \text{snow}}) - c \frac{\tau_H}{2}$$

$$i \leftarrow P_R + i_{\max} f_s \left| f_o - \left(1 - \frac{R^*}{R_{\max}} \right) \right|^2 \text{ ———}$$

$$(x, y, z) \leftarrow \frac{R^*}{R_0} \times (x, y, z)$$

$$27: \mathbf{p} \leftarrow x, y, z, i$$

28: 结束 if

29: 结束 for

30: 结束 for

31: 返回 $\mathbf{pc}$

32: 结束程序

否则，目标对象的强度将根据其遮挡百分比进行衰减。我们的完整降雪模拟在算法1中展示。在图3中，我们展示了一个冬季场景的示例，一次加入我们的降雪模拟，一次加入LISA [22] 提出的模拟。

3.1. 湿地面模型

激光雷达读数受到周围表面湿度的影响。




图6。显示描述湿路面反射的几何光学模型的可视化。

发射的光脉冲从湿地面镜面反射，导致激光回波显著衰减，具体取决于水位高度[5]。分析STF[1]的路面湿度统计（见补充材料），可以看出湿路面常伴有降雪等恶劣天气，是路面点数丢失的主要原因（见图5）。

为了模拟由路面湿润引起的衰减，我们采用几何光学模型，模拟单个光线及其在图6所示的薄水层中的折射。一个定性示例显示在图5（底部）。我们在过渡点使用折射率 ($n_{\text{in}}, n_{\text{out}}$) 和角度 ($\alpha_{\text{in}}, \alpha_{\text{out}}$)。角度 α_{out} 可以根据斯涅尔定律计算：

$$\sin(\alpha_{\text{out}}) = \frac{n_{\text{in}}}{n_{\text{out}}} \sin(\alpha_{\text{in}}). \quad (12)$$

脉冲振幅的变化由菲涅尔方程建模，分别由相对于地面的垂直和平行传输 $t^{\perp}, t^{\parallel}$ 和反射 $r^{\perp}, r^{\parallel}$ 描述（详细内容见补充材料）。由振幅转为透射功率，我们可以推导出功率反射 R_k^p 和透射 T_k^p ：

$$R_k^p = (r_k^p)^2, \quad (13)$$

$$T_k^p = \frac{n_2 \cos(\alpha_{\text{in}})}{n_1 \cos(\alpha_{\text{out}})} t_k^p, \quad (14)$$

其中 $p \in (\perp, \parallel)$ 指偏振。我们将所有返回到传感器的单个光线相加，如图6所示，形成几何级数

$$T_{\text{total}}^p = T_{\text{air}}^p \rho_0 T_{\text{water}}^p \sum_{k=0}^{\infty} (\rho_0 R_{\text{water}}^p)^k, \quad (15)$$

对于 $(\rho_0 R_{\text{water}}) < 1$ 可以简化为

$$T_{\text{total}}^p = T_{\text{air}}^p \rho_0 T_{\text{water}}^p / (1 - \rho_0 R_{\text{water}}^p). \quad (16)$$

由于实际偏振是专有的，我们假设制造商根据距离优化偏振以实现最佳性能，意味着

$$T_{\text{total}} = \max(T_{\text{total}}^{\perp}, T_{\text{total}}^{\parallel}). \quad (17)$$

算法2 激光雷达湿地面模拟

```

程序 WET_GROUND ( $\mathbf{p}, i, \mathbf{w}, h, \epsilon_g, d_w, d_p, P_T, i_n$ )
    如果  $|\mathbf{p} \cdot \mathbf{w} - h| < \epsilon_g$  则
         $R_0 \leftarrow \|\mathbf{p}\|_2$ 
         $\alpha_{in} \leftarrow \arccos\left(\frac{\mathbf{p} \cdot \mathbf{w}}{R_0 \|\mathbf{w}\|_2}\right)$ 
5:    $\rho_0 \leftarrow \frac{i}{\cos(\alpha_{in})P(R_0)}$   $\triangleright$  see Eq. (18)
6:    $\gamma = \min(\max(d_w/d_p, 0), 1)$   $\triangleright$  见式 (19)
7:    $\rho_w \leftarrow (1 - \gamma) \cdot \rho_0 + \gamma \cdot T_{total} / \cos(\alpha_{in})$   $\triangleright$  见式 (20)
8:    $i \leftarrow \rho_w \cos(\alpha_{in})P_T(R_0)$ 
9:   如果  $i > i_n(R_0)$  则
10:    返回  $\mathbf{p}, i$ 
11:  否则
12:    返回 None
13:  结束 if
14:  否则
15:    返回  $\mathbf{p}, i$ 
16:  结束条件
17: 结束过程

```

基于此公式，我们设计了算法2。预处理步骤包括使用RANSAC [12] 估计地面平面法线 $\mathbf{w}$ 和截距 h ，详细内容见补充材料。这些参数可以识别所有属于地面的点以及入射角 α_{in} 。然后，可以从测量的“干”强度中重建修正后的强度，考虑到激光束发散角 Θ 已通过工厂侧校正得到 $i \propto \rho_0 P_T(R) \rho_0 \cos(\alpha_{in})$ 。用入射角 $i(R) / \cos(\alpha_{in})$ 归一化 i ，可以在测量强度 i 和距离 R 之间建立线性对应关系，从而可以线性近似功率 $P_T(R)$ 和噪声底 $i_n(R)$ ，根据已知回波。然后，我们可以为每个点 $\mathbf{p}$ 获取反射率 ρ_0 ：

$$\rho_0 = i / (\cos(\alpha_{in}) P(R_0)). \quad (18)$$

这些校正的反射率通过加权干湿反射进行增强，假设道路纹理轮廓深度 d_p ，充满深度为 d_w 的水，得到

$$\gamma(d_w, d_p) = \min(\max(d_w/d_p, 0), 1), \quad (19)$$

$$\rho_w(\gamma) = (1 - \gamma) \cdot \rho + \gamma \cdot T_{total} / \cos(\alpha_{in}). \quad (20)$$

最后，基于修改后的反射率 ρ_w 更新测量强度 i ，并且只有当其强度 i 大于噪声底 i_n 时，才保留由此产生的点 $\mathbf{p}$ 。

4. 实验

数据集。我们的实验在STF数据集[1]上进行。该数据集提供12997个带有精确3D边界框的标注样本，用于在包括轻雾、浓雾和雪在内的各种天气条件下进行汽车、行人和自行车的目标检测。

虽然不否认行人和骑行者类别的重要性，但在主文中我们关注最主要的类别，即汽车。在补充材料中，我们提供了额外的结果。总共可以用于训练的清晰条件下的帧数为3469，在雪天条件下提供了3916帧。我们根据雪花的强度将这3916个样本划分为两个子集，称为轻雪和重雪，分别包含2512和1404个样本。受到[29]的启发，我们利用DROR算法[6]进行此划分。轻雪样本中的帧，DROR[6]会从自车前方的 $10 \times 2 \times 2$ m 框中筛选出10-79个点，而重雪样本中至少有80个此类点在该框内（详细信息见补充材料）。

评估设置。为了评估，我们采用在KITTI评估框架[13]和[58]中定义的3D目标检测指标。具体而言，[58]通过按目标距离报告结果，扩展了KITTI指标。由于第3节详细描述的天气影响是与距离相关的，我们选择沿用其扩展，并按照[20]中的区间报告结果。此外，我们遵循[45]，在40个召回位置报告平均精度（AP），以提供公平的比较。除此之外，我们使用[13]中定义的典型重叠阈值。为减小潜在的统计波动，我们对每个实验报告三次独立训练的平均性能。

基线方法。我们总共研究了我们的降雪模拟方案在七种知名3D目标检测方法 [9, 25, 39, 41, 42, 57, 59] 中的有效性。我们将我们的方法与晴朗天气基线以及两种竞争的恶劣天气模拟方法进行比较，一种用于雾 [16]，另一种用于降雪 [22]。此外，我们还将点云去噪方法DROR [6] 纳入比较。为了训练检测模型，我们使用OpenPCDet [47]，并遵循每种方法的默认训练配置。所有方法均从零开始训练。

数据增强。我们选择每隔第10个训练样本应用一次模拟，降雪速率从 $[0, 0.5, \dots, 2.5]$ mm/h 采样，设置传感器常数

$\tau_H = 10$ ns, $R_{\max} = 120$ m, $\Theta = 0.003$ rad、 $\rho_s = 0.9$ 和 $\rho_0 = \frac{1 \times 10^{-6}}{\pi}$ 。与[22]使用的设置完全相同。对于湿地模拟，我们采用指数分布，从0.1到1.2 mm 的区间采样 d_w ，同时将 d_p 固定为 1.2 mm，并将 ϵ_g 设为 0.5 m。

4.1. 定量结果

我们在表1中展示了定量结果。在阅读表1时，读者应首先关注显示在整个评估范围 0 – 80 m 内的AP列。

检测方法	模拟方法	大雪 ↑				小雪 ↑				晴朗天气 ↑			
		0-80m	0-30m	30-50m	50-80m	0-80m	0-30m	30-50m	50-80m	0-80m	0-30m	30-50m	50-80m
PV-RCNN [39]	无	39.69	65.05	36.14	8.03	41.13	69.24	39.72	11.68	45.36	72.34	42.48	10.53
	雾 [16]	38.19	64.72	33.38	7.49	39.82	68.41	38.68	9.65	43.37	71.05	40.03	9.90
	DROR [6]	38.57	64.27	35.40	8.07	39.33	66.73	38.14	10.51	41.44	67.76	38.48	9.44
	LISA [22]	39.21	64.21	35.34	8.64	41.60	69.15	41.08	11.15	45.30	71.06	42.86	11.45
	我们-湿	40.03	65.34	35.82	9.31	41.07	68.49	40.03	11.02	44.81	71.60	42.71	10.63
	我们-雪	<u>41.61</u>	<u>67.44</u>	37.47	8.84	41.20	68.79	40.20	11.13	<u>45.61</u>	<u>72.14</u>	43.40	11.21
	我们-雪+湿	41.79	68.39	<u>37.14</u>	<u>8.85</u>	41.79	70.30	<u>41.01</u>	<u>11.28</u>	45.71	71.88	<u>43.31</u>	11.69
VoxelRCNN-车 [9] (单一类别方法)	无	39.47	65.14	36.29	6.83	41.25	69.12	39.86	11.81	45.19	72.33	43.20	10.69
	雾 [16]	40.06	65.58	36.78	7.33	41.10	68.93	39.25	10.98	44.46	71.67	41.78	<u>10.84</u>
	DROR [6]	38.16	64.97	33.23	6.83	38.48	66.93	35.68	9.97	40.65	67.94	36.85	8.45
	LISA [22]	39.06	66.61	33.56	6.93	40.68	68.80	38.78	10.75	45.03	72.05	41.96	10.59
	我们-湿	40.28	<u>67.37</u>	36.03	6.95	40.89	69.41	39.28	10.37	43.98	72.08	40.23	9.23
	我们-雪	41.20	68.27	<u>37.18</u>	7.90	41.75	70.22	40.95	11.78	44.52	72.40	42.23	10.39
	我们-雪+湿	<u>40.76</u>	<u>66.58</u>	<u>37.74</u>	7.78	<u>41.57</u>	<u>68.94</u>	<u>40.82</u>	11.66	45.20	71.30	<u>42.84</u>	11.23
CenterPoint [59]	无	38.68	63.50	34.20	8.23	40.91	68.36	39.96	10.98	44.11	71.66	40.97	9.76
	雾 [16]	38.82	64.43	33.70	8.69	40.82	68.71	40.05	10.48	43.79	70.34	41.22	10.77
	DROR [6]	38.42	64.47	34.31	8.27	38.69	65.62	37.59	10.26	40.80	67.62	36.61	8.69
	LISA [22]	38.11	63.74	33.58	7.67	40.26	68.16	39.25	11.20	<u>44.70</u>	71.54	41.46	11.23
	我们-湿	39.03	63.17	36.08	7.69	40.65	68.59	39.58	10.87	43.85	70.20	41.66	<u>10.82</u>
	我们-雪	39.81	64.75	<u>35.77</u>	9.06	40.68	68.71	39.65	10.40	44.76	71.90	42.91	<u>10.13</u>
	我们-雪+湿	40.14	65.54	37.20	8.41	41.23	69.19	40.07	11.84	44.33	71.24	<u>41.49</u>	10.02
Part-A2 [42]	无	36.59	63.50	30.17	6.86	38.03	65.83	35.95	9.39	42.81	70.27	39.90	9.18
	雾 [16]	35.98	62.23	<u>30.94</u>	6.39	38.17	66.07	37.12	8.63	41.82	67.44	39.73	9.39
	DROR [6]	35.85	65.36	27.99	6.13	35.43	63.50	32.87	7.95	39.48	66.92	35.18	8.61
	LISA [22]	37.12	<u>65.57</u>	30.05	5.96	38.04	66.62	36.72	8.25	41.92	70.02	38.84	7.79
	我们的-湿	37.13	65.02	30.46	6.14	38.29	65.80	38.12	8.85	41.92	69.12	39.37	9.00
	我们的-雪	37.73	66.44	29.54	6.46	38.23	67.72	36.02	7.41	43.41	71.00	40.63	9.74
	我们的-雪+湿	<u>37.52</u>	64.97	31.65	<u>6.48</u>	38.66	<u>67.00</u>	38.18	8.43	42.45	<u>70.27</u>	39.19	8.83
PointRCNN [41]	无	36.68	61.74	33.25	6.14	39.04	66.90	39.72	9.28	41.79	68.58	40.34	7.96
	雾 [16]	36.56	62.93	33.03	5.52	38.37	<u>65.71</u>	39.60	8.50	41.28	67.79	38.82	7.88
	DROR [6]	36.14	62.64	31.64	5.28	36.31	63.52	36.62	7.77	39.08	64.96	36.54	7.70
	LISA [22]	36.68	62.85	31.80	5.78	38.08	65.20	38.96	8.96	41.80	<u>68.17</u>	39.79	8.35
	我们的方法-湿	37.07	62.92	33.76	6.38	39.46	66.33	41.51	9.69	41.70	67.41	39.59	8.05
	我们的方法-雪	37.59	63.99	<u>33.63</u>	<u>6.15</u>	38.60	65.18	39.20	<u>9.47</u>	41.43	67.61	<u>39.89</u>	<u>8.15</u>
	我们的方法-雪+湿	<u>37.51</u>	<u>63.77</u>	33.01	5.90	<u>39.15</u>	67.10	39.89	9.43	41.34	67.76	39.58	7.87
第二 [57]	无	36.08	61.53	30.92	6.60	37.77	65.68	36.06	9.80	42.10	67.82	39.52	10.81
	雾 [16]	36.08	61.65	31.25	7.65	37.31	64.27	35.43	10.55	42.34	69.85	39.20	10.13
	DROR [6]	35.04	60.72	28.79	7.88	35.09	62.24	32.09	8.85	38.96	64.74	35.50	9.76
	LISA [22]	35.90	59.31	32.81	7.44	38.07	64.38	38.47	<u>10.32</u>	41.75	67.01	38.24	11.47
	我们的-湿	36.79	61.18	32.48	8.86	38.04	64.73	37.31	9.95	42.48	69.32	39.28	10.58
	我们的-雪	<u>36.83</u>	61.94	31.40	8.50	37.99	65.40	36.70	9.59	42.72	69.16	40.13	10.86
	我们的-雪+湿	37.03	64.00	31.06	7.05	37.11	<u>65.42</u>	35.75	8.69	42.31	<u>69.80</u>	38.25	10.18
PointPillars [25]	无	30.85	52.45	27.31	5.59	34.09	59.88	32.80	8.52	38.24	64.02	35.76	8.01
	雾 [16]	30.39	52.13	26.79	5.71	35.38	60.81	35.15	9.60	37.74	<u>64.56</u>	34.48	7.30
	DROR [6]	29.32	54.52	21.88	4.82	30.99	57.17	28.43	6.95	34.72	60.59	30.34	6.72
	LISA [22]	28.70	49.78	24.98	5.63	33.87	<u>60.93</u>	31.38	8.70	37.92	63.98	34.61	7.94
	我们的-湿	31.58	52.81	28.64	6.93	34.58	60.57	34.00	8.66	38.10	65.12	34.31	7.75
	我们的-雪	32.94	54.21	29.79	7.81	35.96	61.50	35.67	10.13	39.25	64.37	36.65	8.80
	我们的-雪+湿	31.38	54.09	27.67	6.14	34.18	60.27	33.12	8.08	38.17	64.40	34.73	7.95

表1. STF [1]中雪中3D目标检测模拟方法的比较。我们报告了在三个STF划分上的中等车辆的3D平均精度

(AP)：重雪测试划分有1404个样本，轻雪测试划分有2512个样本，晴朗天气测试划分有1816个样本。

“Ours-wet”：我们的湿地面模拟，“Ours-snow”：我们的降雪模拟，“Ours-snow+wet”：降雪和湿地面模拟的级联应用。

从表1的主要实验结果可以看出，我们的全模拟（包括降雪和湿地模型（Ours-snow+wet））在所有方法中都显著提升了在最具挑战性的测试案例——大雪天气下的性能，远超基线方法以及所有竞争的模拟[16,22]和去噪[6]方法。这一在大雪天气中的提升对于表现最佳的检测方法——PV-RCNN [39]尤为明显，我们的全模拟在AP上比晴天基线高出 2.1%。

。

对于PV-RCNN [39]、CenterPoint [59]和Part-A2 [42]，我们的全模拟在轻雪天气下也都取得了最佳表现，显示出我们的模拟优势延伸至所有雪量强度。此外，在晴天测试集上，我们的无湿地模拟在七种检测方法中有六种表现优于所有竞争方案，持续优于晴天基线。




图7. 在 STF [1] 样本中, PV-RCNN [39] 在大雪天气下的定性比较。最左列显示对应的RGB图像, 其余列显示带有地面真实框和预测的LiDAR点云, 使用晴朗天气基线 ("无增强")、DROR [6]、LISA [22] 和我们完整的模拟 ("我们的雪+湿增强")。

这一发现表明, 使用我们的降雪模拟进行训练, 可以提升在严重雪天条件下的检测性能, 同时不会牺牲, 反而还能改善晴天的表现。

采用为不同不良条件设计的模拟方法, 如[16]中的雾模拟, 并不适用于降雪, 因为相关的物理模型不同; 在大多数检测方法的降雪测试中, [16]的性能略低于晴天基线。应用DROR [6]作为去除杂点的增强步骤, 获得了较低的结果, 因为它也会去除一些有效点, 这些点不属于降雪杂乱点。

4.2. 定性结果

展示了所提出的数据增强方案的定性结果, 见图7。这里, 将PV-RCNN [39]与无增强的晴朗天气基线、DROR [6]和LISA [22]进行了比较。在第一行中, 我们看到在降雪杂乱中, 只有在训练时应用我们提出的数据增强后, 才能检测到行人。在第二行中, 所有竞争方法都出现了额外的误报。底部显示一个难以应对的高速公路场景, 雪尘被扬起。我们的方法在此示例中表现良好, 是唯一检测到前导车辆的方法。还应注意, 在这种扬起雪尘的场景中, DROR [6]无法完全去除杂乱。

5. 结论

在本工作中, 我们提出了一种用于从清晰的LiDAR采集数据中逼真合成冬季场景的创新方法, 物理上准确地模拟降雪和湿润表面。此外, 我们验证了所提算法的有效性, 在七种不同的3D目标检测方法中进行了测试, 在大雪天气下AP指标提升了最多2.1%。未来工作中, 我们计划探索利用时间线索实现基于LiDAR的鲁棒3D目标检测。

致谢。本工作由丰田汽车欧洲通过TRACE-Zürich研究项目提供资金支持。该工作还获得了AI-SEE项目的资金, 资金来自奥地利研究促进局(FFG)、芬兰商业局、联邦教育与研究部(BMBF)以及加拿大国家研究委员会工业研究援助计划(NRC-IRAP)。我们还感谢联邦经济事务与能源部在“VVM-自动驾驶汽车第4级和第5级的验证与确认方法”PEGASUS系列项目中的支持。Felix Heide获得了NSF CAREER奖(2047359)、索尼青年教师奖以及Project X创新奖的资助。我们感谢Emmanouil Sakaridis验证我们在降雪模拟中推导的遮挡角度。

参考文献

- [1] Mario Bijelic, Tobias Gruber, Fahim Mannan, Florian Kraus, Werner Ritter, Klaus Dietmayer, 和 Felix Heide. 在看不见雾的情况下看透雾：在未见过的不良天气中进行深度多模态传感器融合。发表于 IEEE/CVF 计算机视觉与模式识别会议 (CVPR), 2020。1,2,5,6,7,8
- [2] Mario Bijelic, Tobias Gruber, 和 Werner Ritter. 雾中激光雷达传感器的基准测试：检测是否失效？发表于 IEEE 智能车辆研讨会 (IV), 2018。1,2
- [3] Holger Caesar, Varun Bankiti, Alex Lang, Sourabh Vora, Venice Erin Liong, Qiang Xu, Anush Krishnan, Yu Pan, Giancarlo Baldan, 和 Oscar Beijbom. nuScenes：用于自动驾驶的多模态数据集。发表于 IEEE/CVF 计算机视觉与模式识别会议 (CVPR), 2020。2
- [4] Alexander Carballo, Jacob Lambert, Abraham MonrroyCano, David Robert Wong, Patiphon Narksri, Yuki Kit-sukawa, Eijiro Takeuchi, Shinpei Kato, 和 Kazuya Takeda. LIBRE：多重3D LiDAR数据集。发表于IEEE智能车辆研讨会 (IV), 2020年。1, 2
- [5] Johan Casselgren, Mikael Sjö Dahl, 和 James LeBlanc. 被覆盖沥青的角谱响应。应用光学, 46(20):4277-4288, 2007年。2, 5
- [6] Nicholas Charron, Stephen Phillips, 和 Steven Waslander. 雪灾中受污染的LiDAR点云去噪。在计算机与机器人视觉会议 (CRV), 2018年。2, 6, 7, 8
- [7] Xiaozhi Chen, Huimin Ma, Ji Wan, Bo Li, 和 Tian Xia. 自动驾驶多视角3D目标检测网络。发表于 IEEE/CVF 计算机视觉与模式识别会议 (CVPR), 2017年。2
- [8] 欧洲委员会。欧盟道路安全。<https://doi.org/10.2832/169706>, 2018年。查阅日期：2021年11月15日。1
- [9] 邓佳俊, 石少帅, 李沛威, 周文刚, 张艳勇, 李厚强. Voxel R-CNN：面向高性能体系基础3D目标检测。2021年AAAI人工智能会议。2, 6, 7
- [10] Ayush Dewan, Tim Caselitz, Gian Diego Tipaldi, Wolfram Burgard. 基于运动的3D激光扫描检测与跟踪。2016年IEEE机器人与自动化国际会议 (ICRA)。1
- [11] 丁琼, 陈武, 金布鲁斯, 刘彦雄, 刘国祥. 融合重叠驱动调整与Phong模型的LiDAR强度校正。摄影测量与遥感, 75: 40-47, 2013年。3
- [12] Martin Fischler 和 Robert Bolles. 随机抽样一致性：一种模型拟合范例，应用于图像分析和自动制图。ACM 通讯, 24: 381-395, 1981。6
- [13] Andreas Geiger, Philip Lenz 和 Raquel Urtasun. 我们准备好自动驾驶了吗？KITTI 视觉基准套件。发表于 IEEE/CVF 计算机视觉与模式识别会议 (CVPR), 2012。2, 6
- [14] Christopher Goodin, Daniel Carruth, Matthew Doude 和 Christopher Hudson. 预测雨对ADAS中LiDAR的影响。电子学, 8, 2019。1, 2
- [15] Kevin Gunn 和 John Marshall. 集体雪花的大小分布。大气科学, 15(5): 452-461, 1958。2, 4, 5
- [16] Martin Hahner, Christos Sakaridis, Dengxin Dai, 和 LucVan Gool. 在恶劣天气下对真实LiDAR点云进行雾模拟以进行3D目标检测。发表于IEEE国际计算机视觉会议 (ICCV), 2021。1, 2, 6, 7, 8
- [17] Robin Heinzler, Florian Piewak, Philipp Schindler, 和 Wilhelm Stork. 在恶劣天气条件下基于CNN的LiDAR点云去噪。IEEE机器人与自动化快报, 2020。2
- [18] Robin Heinzler, Philipp Schindler, Jürgen Seekircher, Werner Ritter, 和 Wilhelm Stork. 天气影响与汽车LiDAR传感器的分类。发表于IEEE智能车辆研讨会 (IV), 2019。1, 2
- [19] Maria Jokela, Matti Kuttila, 和 Pasi Pyrkönen. 在恶劣天气条件下对汽车点云传感器的测试与验证。应用科学, 2019。1, 2
- [20] Frank Julca-Aguilar, Jason Taylor, Mario Bijelic, FahimMannan, Ethan Tseng, 和 Felix Heide. Gated3D：利用时间照明线索进行单目3D目标检测。在IEEE国际计算机视觉会议 (ICCV), 2021。2, 6
- [21] Alireza Kashani, Michael Olsen, Christopher Parrish, 和 Nicholas Wilson. 激光雷达辐射处理综述：从临时强度校正到严格的辐射定标。传感器, 15(11), 2015。3
- [22] Velat Kilic, Deepti Hegde, Vishwanath Sindagi, A. Brinton Cooper, Mark Foster, 和 Vishal Patel. 激光雷达光散射增强 (LISA)：基于物理的极端天气条件模拟，用于3D目标检测。arXiv预印本 2107.07004, 2021。2, 4, 5, 6, 7, 8
- [23] Jason Ku, Melissa Mozifian, Jungwook Lee, Ali Harakeh, 和 Steven Waslander. 基于视角聚合的联合3D提议生成与目标检测。发表于IEEE/RSJ智能机器人与系统国际会议 (IROS), 2018。2
- [24] Matti Kuttila, Pasi Pyrkönen, Maria Jokela, Tobias Gruber, Mario Bijelic, 和 Werner Ritter. 在北极条件下的汽车LiDAR性能基准测试。发表于IEEE智能交通系统国际会议 (ITSC), 2020。1, 2
- [25] Alex Lang, Sourabh Vora, Holger Caesar, Lubing Zhou, Jiong Yang, 和 Oscar Beijbom. PointPillars：用于点云目标检测的快速编码器。发表于IEEE/CVF计算机视觉与模式识别会议 (CVPR), 2019。1, 2, 3, 6, 7
- [26] Wei Liu, Dragomir Anguelov, Dumitru Erhan, ChristianSzegedy, Scott Reed, Cheng-Yang Fu, 和 Alexander C.Berg. SSD：单次多框检测器。发表于2016年欧洲计算机视觉会议 (ECCV), 第3页

- [27] Weixin Lu, Yao Zhou, Guowei Wan, Shenhua Hou, 和 Shiyu Song。L3-Net：面向自动驾驶的基于学习的LiDAR定位。在IEEE/CVF计算机视觉与模式识别会议 (CVPR)，2019.1
- [28] Sebastien Michaud, Jean-François Lalonde, 和 Philippe Giguère。旨在描述雪地条件下LiDAR行为的研究。在智能车辆规划、感知与导航研讨会, IEEE/RSJ国际机器人与系统会议 (IROS)，2015.1,2
- [29] Matthew Pitropov, Danson Evan Garcia, Jason Rebello, Michael Smart, Carlos Wang, Krzysztof Czarnecki, 和 Steven Waslander。加拿大不良驾驶条件数据集。国际机器人研究杂志, 40:681 - 690, 2021. 2, 6
- [30] Charles Qi, Wei Liu, Chenxia Wu, Hao Su 和 Leonidas Guibas。用于RGB-D数据的3D目标检测的Frustum PointNets。发表于IEEE/CVF计算机视觉与模式识别会议 (CVPR)，2018年. 2
- [31] Charles Qi, Hao Su, Kaichun Mo 和 Leonidas Guibas。PointNet：用于3D分类和分割的点集深度学习。发表于IEEE/CVF计算机视觉与模式识别会议 (CVPR)，2017年. 2
- [32] Roy Rasmussen, Jothiram Vivekanandan, Jeffrey Cole, Barry Myers 和 Charles Masters。利用能见度估算降雪速率。应用气象学, 38(10):1542-1563, 1999年. 2
- [33] Ralph Rasshofer, Martin Spies 和 Hans Spies。天气现象对汽车激光雷达系统的影响。无线电科学进展, 9, 2011年. 2, 3
- [34] Shaoqing Ren, Kaiming He, Ross Girshick, 和 Jian Sun。Faster R-CNN：面向实时目标检测的区域提议网络。发表于神经信息处理系统会议 (NeurIPS)，2015. 3
- [35] Christos Sakaridis, Dengxin Dai, Simon Hecker, 和 Luc Van Gool。利用合成与真实数据进行模型适应, 以理解语义密集的雾天场景。发表于欧洲计算机视觉会议 (ECCV)，2018. 2
- [36] Christos Sakaridis, Dengxin Dai, 和 Luc Van Gool。利用合成数据实现语义雾天场景理解。国际计算机视觉期刊, 126(9):973-992, 2018. 1,2
- [37] Christos Sakaridis, Dengxin Dai, 和 Luc Van Gool。ACDC：具有对应关系的不良条件数据集, 用于语义驾驶场景理解。发表于IEEE国际计算机视觉会议 (ICCV)，2021. 2
- [38] R. S. Sekhon 和 R. C. Srivastava。雪大小光谱与雷达反射率。大气科学, 27(2):299 - 307,1970. 2
- [39] Shaoshuai Shi, Chaoxu Guo, Li Jiang, Zhe Wang, Jianping Shi, Xiaogang Wang, 和 Hongsheng Li。PV-RCNN：点-体素特征集抽象用于3D目标检测。在IEEE/CVF计算机视觉与模式识别会议 (CVPR)，2020. 1, 2, 3, 6, 7, 8
- [40] Shaoshuai Shi, Li Jiang, Jiajun Deng, Zhe Wang, Chaoxu Guo, Jianping Shi, Xiaogang Wang, 和 Hongsheng Li。PV-RCNN++：带有局部向量表示的点-体素特征集抽象用于3D目标检测。arXiv预印本2102.00463, 2021. 2, 3
- [41] 史少帅, 王晓刚, 李宏生。PointR-CNN：基于点云的三维目标提议生成与检测。发表于IEEE/CVF计算机视觉与模式识别会议 (CVPR)，2019年. 2, 3, 6, 7
- [42] 史少帅, 王哲, 史建平, 王晓刚, 李宏生。从点到部分：基于部分感知与部分聚合网络的点云三维目标检测。发表于IEEE模式分析与机器智能汇刊 (TPAMI)，2020年. 2, 6, 7
- [43] 郑石, Ethan Tseng, Mario Bijelic, Werner Ritter, Felix Heide。Zeroscatter：用于长距离成像与通过散射介质视觉的域转移。发表于IEEE/CVF计算机视觉与模式识别会议 (CVPR)，2021年. 2
- [44] Jungil Shin, Hyunsuk Park, 和 Taejung Kim。激光反向散射强度检测道路冻结和湿润表面的特性。传感器, 2019: 8973248, 2019年2月
- [45] Andrea Simonelli, Samuel Rota Buló, Lorenzo Porzi, Manuel Lopez-Antequera 和 Peter Kotschieder。单目3D目标检测的解缠技术。发表于IEEE国际计算机视觉会议 (ICCV)，2019年. 2, 6
- [46] Pei Sun, Henrik Kretzschmar, Xerxes Dotiwalla, AurelienChouard, Vijaysai Patnaik, Paul Tsui, James Guo, Yin Zhou, Yuning Chai, Benjamin Caine, Vijay Vasudevan, Wei Han, Jiquan Ngiam, Hang Zhao, Aleksei Timofeev, Scott Ettinger, Maxim Krivokon, Amy Gao, Aditya Joshi, Yu Zhang, Jonathon Shlens, Zhifeng Chen, 和 Dragomir Anguelov。自动驾驶感知的可扩展性：Waymo开放数据集。发表于IEEE/CVF计算机视觉与模式识别会议 (CVPR)，2020年. 2
- [47] OpenPCDet开发团队。OpenPCDet：一个用于点云中三维目标检测的开源工具箱。https://github.com/open-mmlab/OpenPCDet, 2020年。访问时间：2021年11月15日. 6
- [48] Maxime Tremblay, Shirsendu S. Halder, Raoul de Charette, 和 Jean-François Lalonde。用于评估和提升恶劣天气鲁棒性的雨水渲染。国际计算机视觉期刊 (IJCV)，126, 2021. 1, 2
- [49] 美国交通部：联邦公路管理局。天气事件如何影响道路？https://ops.fhwa.dot.gov/weather/q1_roadimpact.htm, 2019。访问时间：2021年11月15日. 1
- [50] Velodyne。Hdl-64e 用户手册, 2007. 3, 5
- [51] Sourabh Vora, Alex Lang, Bassam Helou, 和 Oscar Beijbom。PointPainting：用于3D目标检测的序贯融合。在IEEE/CVF计算机视觉与模式识别会议 (CVPR)，2020. 2
- [52] Andrew Wallace, Abderrahim Halimi, 和 Gerald Buller。恶劣天气条件下的全波形LiDAR。IEEE车辆技术杂志, 69, 2020. 1, 2

- [53] Dingkang Wang, Connor Watkins, 和 Huikai Xie。用于LiDAR的MEMS反射镜：综述。Micromachines, 11(5), 2020.1
- [54] Yan Wang, Wei-Lun Chao, Divyansh Garg, Bharath Hariharan, Mark Campbell, 和 Kilian Weinberger。基于视觉深度估计的伪LiDAR：弥合自动驾驶中3D目标检测的差距。发表于IEEE/CVF计算机视觉与模式识别会议 (CVPR), 2019.2
- [55] George Williams。面向汽车安全与自动驾驶系统的眼安全雪崩光电二极管LiDAR的优化。Optical Engineering, 56(3):1 - 9, 2017.3
- [56] 亚采克·沃伊塔诺夫斯基、马雷克·齐格蒙特、米罗斯瓦娃·卡斯楚克、齐格蒙特·米尔奇克和米哈尔·穆扎尔。905 nm 和1550纳米半导体激光测距仪因恶劣环境条件导致的性能下降比较。《光电子评论》，22，2014年。2
- [57] Yan Yan, Yuxing Mao 和 Bo Li。SECOND：稀疏嵌入卷积检测。传感器，18，2018年。2, 3, 6,7
- [58] Bin Yang, Wenjie Luo 和 Raquel Urtasun。Pixor：基于点云的实时3D目标检测。在IEEE/CVF计算机视觉与模式识别会议 (CVPR), 2018年。6
- [59] Tianwei Yin, Xingyi Zhou 和 Philipp Krahenbuhl。基于中心的3D目标检测与跟踪。在IEEE/CVF计算机视觉与模式识别会议 (CVPR), 2021年。1, 2, 3, 6, 7
- [60] Yurong You, Yan Wang, Wei-Lun Chao, Divyansh Garg, Ge-off Pleiss, Bharath Hariharan, Mark Campbell, 和 Kilian QWeinberger。Pseudo-LiDAR++：用于自动驾驶中3D目标检测的精确深度。在国际学习表征会议 (ICLR), 2020年。2
- [61] Ji Zhang 和 Sanjiv Singh。LOAM：实时激光雷达里程计与建图。机器人：科学与系统会议 (RSS), 2014年。1
- [62] Yin Zhou 和 Oncel Tuzel。VoxelNet：端到端的点云基础3D目标检测学习。在IEEE/CVF计算机视觉与模式识别会议 (CVPR), 2018年。2, 3