

面向真实场景生成的 LiDAR 扩散模型

冉昊熙
卡内基梅隆大学
ranhaoxi@cmu.edu

Vitor Guizilini
丰田研究院
vitor.guizilini@tri.global

王越
南加州大学
yue.w@usc.edu




图 1. 我们的方法 (LiDM) 通过保留类曲线结构与更接近真实世界数据 (Reference) 的物体，朝着真实感 LiDAR 场景生成迈进，并标志着从不同输入模态进行条件化 LiDAR 场景生成的一个里程碑。

摘要

扩散模型 (DMs) 擅长生成照片级真实感图像，但将其用于 LiDAR 场景生成存在重大困难。这主要因为在点空间运行的 DMs 难以保留 LiDAR 场景的曲线状模式与三维几何形态，消耗了大量表征能力。本文提出 LiDAR 扩散模型 (LiDMs)，在一个为捕捉 LiDAR 场景真实感而定制的潜在空间中生成 LiDAR 真实场景，通过学习流程中引入几何先验。我们的方法针对三大目标：模式真实、几何真实与物体真实。具体来说，我们引入基于曲线的压缩以模拟真实世界 LiDAR 模式、基于点的坐标监督以学习场景几何、以及基于块的编码以获取完整的三维物体上下文。通过这三项核心设计，我们的方法在无条件 64 光束场景的 LiDAR 生成上取得了有竞争力的表现，并在有条件 LiDAR 生成上达到最先进水平，同时相较于基于点的 DMs 保持高效 (最快达 $107\times$ 倍)。此外，通过将 LiDAR 场景压缩到潜在空间，我们使 DMs 可受多种条件控制，如语义地图、相机视角与文本提示。

我们的代码与预训练权重可在

<https://github.com/hancyran/LiDAR-Diffusion> 获取。

1. 引言

近年来条件生成模型激增，能够生成视觉上吸引且高度逼真的图像。其中，扩散模型 (DMs) 凭借其无可争议的性能成为最流行的方法之一。为实现任意条件下的生成，潜在扩散模型 (LDMs) [44] 将交叉注意力机制与卷积自编码器结合以生成高分辨率图像。其后续扩展 (如 Stable Diffusion [2]、Midjourney [1]、ControlNet [60]) 进一步提升了其在条件图像合成方面的潜力。

这一成功促使我们探问：能否将可控的扩散模型应用于自动驾驶和机器人用的 LiDAR 场景生成？例如，给定一组边界框，这些模型能否合成相应的 LiDAR 场景，从而将这些边界框变成高质量且昂贵的带标签数据？或者，仅凭一组图像就能生成一个 3D 场景吗？更大胆地，能否设计出一种以语言驱动的 LiDAR 生成器以实现可控仿真？

为回答这些交织的问题，我们的目标是设计融合多种条件（例如，布局、相机视角、文本）的扩散模型，以生成逼真的 LiDAR 场景。

为此，我们从近期面向自动驾驶的扩散模型工作中获取洞见。在 [62] 中，引入了基于点的扩散模型（即 LiDARGen）用于无条件的 LiDAR 场景生成。但该模型倾向于生成噪声背景（例如道路、墙面）和模糊物体（例如汽车），导致无法生成 LiDAR 真实感场景（参见图 1）。此外，在点云上不做任何压缩直接应用扩散会在推理过程中显著降低计算速度。将基于补丁的扩散模型（即 Latent Diffusion [44]）直接应用于 LiDAR 场景生成，在定性和定量上均表现不佳（参见图 1）。

为实现条件式 LiDAR 真实感场景生成，我们提出了一种基于曲线的生成器，称为 Li-DAR Diffusion Models (LiDMs)，以回应上述问题并解决近期工作的不足。LiDMs 能处理任意条件，如边界框、相机图像和语义图。LiDMs 采用深度图（range images）作为 LiDAR 场景的表示，这在检测 [28, 37]、语义分割 [38, 55] 和生成 [62] 等多种下游任务中广泛使用。之所以如此选择，是因为深度图与点云之间可以可逆且无损地互相转换，并且能从高度优化的二维卷积操作中获得重大收益。为了在扩散过程中把握 LiDAR 场景的语义与概念要义，我们的方法在扩散前将 LiDAR 场景的点编码到一个在感知上等价的潜在空间中。

为了进一步提升对真实世界 LiDAR 数据的真实感模拟，我们聚焦于三大要素：模式真实感、几何真实感与物体真实感。首先，受 [49] 启发，我们在自编码过程中采用曲线级压缩以保留点的曲线模式。其次，为实现几何真实感，我们引入点级坐标监督，使自编码器具备场景级几何的理解。最后，我们通过加入额外的块级下采样策略来扩大感受野，以捕捉视觉上较大物体的完整上下文。结合这些模块增强后，所得的感知空间使扩散模型能够高效合成高质量的 LiDAR 场景（参见图 1），同时相较于基于点的扩散模型在单块 NVIDIA RTX 3090 上表现出 $\times 107$ 的加速，并支持任意类型的基于图像和基于 token 的条件。我们的主要贡献总结如下：

- 我们提出了一种新型 LiDAR 扩散模型（LiDM），该生成模型可接受任意输入条件以生成具有 LiDAR 真实感的场景。

据我们所知，这是首个能够从多模态条件生成 LiDAR 场景的方法。

- 我们引入曲线级压缩以保持真实的 LiDAR 模式、点级坐标监督以规范场景级几何结构的学习，以及块级编码以完整捕捉 3D 物体的上下文。
- 我们提出三项指标，用于在感知空间中对生成的 LiDAR 场景质量进行全面且量化的评估，比较的表示包括距离图、稀疏体积和点云。
- 我们的方法在 64-beam 条件场景合成上达到最新水平，同时相比基于点的扩散模型实现了 $\times 107$ 的加速。

2. 相关工作

扩散模型。扩散模型（DMs）[48] 在像素空间的图像合成中取得了巨大成功[9, 18, 26]。潜在扩散模型（LDMs）[44] 并非在像素空间上施加扩散，而是采用与感知等价的潜在空间用于 DMs。LDMs 的大规模应用（如 Stable Diffusion [2]、Midjourney [1]）进一步推动了扩散模型社区的发展。近期的扩散模型应用，包括语言引导的 DMs（如 Glide [39]、DALL-E2 [43]）和其他可控的 DMs（如 ControlNet [60]），也展示了扩散模型的巨大潜力。

3D 扩散模型。3D 扩散模型是扩散模型的一个关键分支，能够在多种 3D 模态上生成高质量样本。包括点云 [33, 36, 52, 61]、网格 [16, 32, 34] 和隐式场 [7, 11, 19, 29, 30, 47, 59]。最近，Point-E [40] 作为一种语言引导的扩散模型，已在基于大规模 3D 数据集的高质量手工 3D 模型生成上展现出高效能力。

LiDAR 场景生成。在更大尺度和复杂场景下，将 LiDAR 点云视为类似手工制作 3D 模型的点云生成任务会遇到困难。在 [6] 中，作者通过提供两种方案 LiDARVAE 和 LiDARGAN 探讨了生成模型在 LiDAR 场景中的可行性。[62] 进一步引入了基于点的扩散模型 LiDARGen，以生成令人满意的视差图像样本作为 LiDAR 场景。然而，上述方法仍未能生成 LiDAR 真实感场景，因为它们可能忽视了 LiDAR 数据固有的曲线状结构和几何细节。

LiDAR 场景模拟。LiDAR 模拟通过基于物理的模拟器 [10, 27] 或数据驱动的模拟器 [4, 20, 35, 54] 生成 LiDAR 点云。基于物理的 LiDAR 模拟器（例如 CARLA [10]）使用光线投射从传感器原点向环境几何体发射光线，通过计算交点来模拟 LiDAR。

得益于生成逼真的激光雷达场景，数据驱动的激光雷达模拟在业内受到了广泛关注。开创性工作 LiDARSim [35] 采用深度学习模型，对基于物理的模拟结果进行偏差修正，以生成逼真的激光雷达点云。

3. LiDAR 扩散模型

在本节中，我们详细介绍了 LiDAR 扩散模型 (LiDMs)。总体如图 2 所示。在第 3.1 节中，我们讨论了选择距离图作为数据表示的设计取舍。在第 3.2 节中，我们用 LiDMs 对 LiDAR 场景生成任务进行形式化。在第 3.3 节中，我们从采样模式和场景几何真实性两方面探讨了 LiDAR 压缩的设计。在第 3.4 节中，我们基于多模态条件介绍了 LiDM 的潜在应用。在第 3.5 节中，我们给出了 LiDAR 压缩与 LiDAR 扩散阶段的训练目标。最后，在第 3.6 节中，我们描述了三种新颖的感知度量，用于定量分析 LiDAR 场景生成的样本质量。

3.1. 数据表示

LiDAR 数据可以用不同的模态表示。由于我们的目标是模拟原始 LiDAR 输出，我们必须选择一种可与原始数据无损相互转换的表示方式，这排除了可选的体素化。为此，我们考虑两种选择，即三维点云和二维距离图。这两种模态在以往工作中都被成功探索过，尽管在不同场景下：点云生成 [3, 57, 58] 通常因效率限制而侧重于人工设计的物体，而距离图生成 [6, 62] 则更适用于如 LiDAR 场景这类更大尺度的场景。这种区分表明在我们的设置中明显偏好距离图。

3.2. 问题表述

我们生成器的输入和输出都表示为深度图，分别记为 x 和 $\hat{x}$ ，其中 $x, \hat{x} \in \mathbb{R}^{H \times W}$ 、 H 和 W 分别是深度图的高度和宽度。对于一个像素，其由归一化的二维位置和测距值定义，我们可以在给定预定义参数的情况下直接计算其深度、偏航角和俯仰角。具体地，我们将该像素的三维坐标 $p = [\alpha, \beta, \gamma]$ 定义为：

$$\alpha = \cos(\text{yaw}) \times \cos(\text{pitch}) \times \text{depth}, \quad (1)$$

$$\beta = -\sin(\text{yaw}) \times \cos(\text{pitch}) \times \text{depth}, \quad (2)$$

$$\gamma = \sin(\text{pitch}) \times \text{depth}. \quad (3)$$

我们的 LiDMs 流程可分为两部分：LiDAR 压缩和扩散过程。对于 LiDAR 压缩，我们使用编码器 $\mathcal{E}$ 将深度图压缩为潜在编码 $z = \mathcal{E}(x)$ ，其中 $z \in \mathbb{R}^{h \times w \times d}$ ，并使用解码器 $\mathcal{D}$ 将其解码为 $\hat{x} = \mathcal{D}(z) = \mathcal{D}(\mathcal{E}(x))$ 。

对于扩散过程，遵循标准做法 [44]，我们将一系列同等加权的无条件去噪自编码器记为 $\epsilon_\theta(z_t, t)$ ，时间戳为 $t = 1 \dots T$ 。

3.3. 面向 LiDAR 真实感生成

Pattern Realism 曲线的存在是 LiDAR 场景中的常见模式。一个曲线 $c_i = [p_1, \dots, p_{n_i}]$ 由一系列 n_i 点表示，其中相邻点通过折线相连。此外，如 [49] 所定义，LiDAR 点云等价于一组曲线，即曲线云 $C = \{c_1, \dots, c_m\}$ 。虽然我们不能将曲线云的概念直接应用于深度图 (range images)，但仍可探讨类曲线结构。

鉴于 LiDAR 传感器的每根光束通过水平扫描场景依次捕获 3D 点，我们可以合理地假定每条曲线只存储在深度图的一行中，并以像素的连续段表示。因此，我们通过按曲线进行压缩来设计自编码器，使深度图在水平方向上下采样 $f_c := 2^\eta$ 倍，其中 $\eta \in \mathbb{N}$ 。为实现按曲线压缩，我们采用以下实现细节：1) 每个按曲线的残差块中卷积的核大小为 1×4 ，而非传统图像上使用的 3×3 ；2) 每个下采样或上采样层仅在水平方向应用；3) 填充采用循环方式，考虑到深度图的两侧首尾相连。通过该实现，我们在感知等价的空间中有效地保留了类曲线结构。

几何逼真 保持场景级几何是 LiDAR 真实感生成的另一个关键方面。为此，我们的模型应能清晰区分物体与背景，对 3D 几何轮廓敏感。然而，将点云转换为距离图像（如第 3.2 节所述）可能导致几何信息丢失。因此，我们引入了一种新颖的逐点坐标监督，以增强自编码器在三维空间中的理解。点云通过坐标提供了描述 LiDAR 场景几何的信息，但由于其不规则性，我们不能将点云距离损失函数（例如 Chamfer Distance [13]）直接用于自编码器训练。为此，我们设计了一种简单方式，通过监督输入与输出距离图像之间每个像素的转换坐标来实现。注意，基于转换坐标的图像形状为 $H \times W \times 3$ 。逐点坐标监督包括像素级三维距离损失和坐标图像上的对抗目标。

对象真实感 实现对象真实感具有挑战性，但对恢复合理且完整的形状至关重要。




图2. 关于 64 光束数据上 LiDMs 的概览，包含三部分：LiDAR 压缩（参见 Sec. 3.3 与 3.5）、多模态条件（参见 Sec. 3.4）和 LiDAR 扩散（参见 Sec. 3.5）。

虽然曲线压缩能有效捕捉 LiDAR 场景中的模式，但在捕捉 3D 目标的完整上下文时会因感受野受限而受影响，尤其是距离图像中视觉上较大的目标（即靠近自车中心的目标）。因此，我们在自编码器的中间层引入了基于补丁的块以进行分块编码，这在定性上能有效提升目标的合成质量。我们将分块编码期间的下采样因子定义为 $f_p = 2^\mu, \mu \in \mathbb{N}$ ，因此为 $h = H/f_p, w = W/(f_c \times f_p)$ 。

3.4. 多模态条件

先前工作 [44, 60] 已展示扩散模型在建模条件分布方面的能力。利用我们的 LiDMs，我们进一步引入多模态条件以实现自动驾驶领域下游任务的显著潜力。通常在 LiDAR 场景中有两类条件可作为输入：基于图像的条件（例如语义地图）和基于标记的条件（例如边界框、关键点）。我们将基于图像的条件的应用视为图像到图像的翻译任务 [21]，而对基于标记的条件则采用交叉注意力机制来处理，这与广泛采用的做法一致 [44]。

为扩大条件 LiDAR 生成的适用范围，我们通过使用 CLIP [41] 提供的预训练潜在空间提取每个视角的全局特征，引入了从相机到 LiDAR 的任务。由于多摄像头视角与 LiDAR 点云之间存在空间不匹配，不能将相机到 LiDAR 的生成直接视为另一种图像到图像的翻译任务。因此，对于一个 LiDAR 场景，与使用整个基于图像的条件任务不同，我们用由所有摄像头视角的全局特征拼接而成的条件表示来引导 LiDMs。

最近，对比图文预训练范式（例如 CLIP [41]）在零样本学习 [42] 上取得了显著进展。CLIP 使得跨文本到图像 [43]、文本到视频 [56] 等多种生成任务的零样本理解成为可能。为探索语言引导自动驾驶 [22] 在 LiDAR 生成上的潜在应用，我们利用 CLIP 的文本-图像潜在空间来编码 LiDMs 的描述性提示。因此，我们可以将相机到 LiDAR 的任务无缝转化为新颖的文本到 LiDAR 生成。

3.5. 训练目标

通过曲线级压缩、点级坐标监督和块级编码，我们设计了自动编码器来压缩矩阵图像。为训练这些自动编码器，我们采用了一组目标，包括像素级 L_1 重建目标 L_{rec} 、从 [21] 适配的基于曲线的对抗目标 L_{GAN} 和向量量化正则化 [53] L_{VQ} 。具体而言，我们对以矩阵和基于坐标的图像为输入的情况分别计算 L_{rec} 和 L_{GAN} 。我们在像素级 L_1 损失的部分使用矩阵图像计算 L_{rec} ，并在基于坐标的图像上计算像素级坐标距离损失：

$$\mathcal{L}_{rec}(x) = \mathbb{E}_x[\|x - \hat{x}\| + \lambda\|p - \hat{p}\|_2^2], \quad (4)$$

其中 λ 是用于基于坐标图像监督的缩放因子。此外，我们通过将深度图与基于坐标的图像一并输入我们的 CurveGAN（PatchGAN [21] 的变体，在第一阶段施加按曲线的压缩）来计算 L_{GAN} 。我们将对抗目标定义为：

$$\mathcal{L}_{GAN}(x) = \mathbb{E}_x[\log \mathcal{D}([x, p]) + \log(1 - \mathcal{D}([\hat{x}, \hat{p}]))], \quad (5)$$

其中 $[\dots]$ 表示拼接操作。此外，我们利用向量量化损失 [53] L_{VQ} 来学习深度图成分的码本。我们在解码器中加入向量量化层，遵循 [12] 的实现。总体而言，自动编码器的完整训练目标为：

$$L_{AE} = \mathcal{L}_{rec} + \mathcal{L}_{GAN} + \mathcal{L}_{VQ}. \quad (6)$$

作为概率模型，扩散模型（DMs）[48]旨在通过对从高斯分布采样的变量进行逐步去噪来理解数据分布。在图像合成中，先前工作在像素空间[9, 18]或潜在空间[44]使用过扩散模型。本文使扩散模型能够利用由我们的自编码器构建的低维潜在空间。该空间在保留 LiDAR 模式与场景和物体几何结构的同时，保持了计算效率。此外，它使扩散模型能够专注于大规模 LiDAR 场景的语义信息。我们定义了无条件 LiDMs 的目标：

$$L_{\text{LiDM}} = \mathbb{E}_{\mathcal{E}(x), \epsilon \sim \mathcal{N}(0,1), t} \left[\|\epsilon - \epsilon_{\theta}(z_t, t)\|_2^2 \right], \quad (7)$$

其中 $\epsilon_{\theta}(z_t, t)$ 是带时间戳条件的 UNet [45] 主干网络。推理时，我们通过用 $\mathcal{D}$ 解码去噪后的潜代码 z 来获得采样的距离图像。同样，给定输入条件 y ，我们将条件 LiDMs 的目标定义为：

$$L_{\text{cLiDM}} = \mathbb{E}_{\mathcal{E}(x), y, \epsilon \sim \mathcal{N}(0,1), t} \left[\|\epsilon - \epsilon_{\theta}(z_t, t, \tau_{\theta}(y))\|_2^2 \right], \quad (8)$$

where τ_{θ} 是一个条件编码器，负责将 y 转换为 UNet 主干可使用的表示。

3.6. 评估指标

为评估 LiDAR 生成模型，以往关于 LiDAR 场景生成的工作[6, 62] 通常采用[3] 提出的一些统计学指标。然而，这些指标在感知层面上量化合成质量时可能存在困难。因此，我们为 LiDAR 生成模型设计了若干感知层面指标。

感知评估（例如 FID [17]）是衡量图像生成质量的一种常用方式，被广泛用于各类流行图像生成器的评估 [9, 18, 23-25, 44, 46]。通常，这些先前工作在由预训练分类器（例如 Inception 模型 [50]）定义的感知空间中，计算真实数据分布与生成样本分布之间的 Fréchet 距离 [15]。为便于从感知层面理解 LiDAR 生成模型的性能，我们在感知评估中增加了三种基于 Fréchet 距离的感知度量：Fréchet 距离范围图像（FRID）、Fréchet 稀疏体素距离（FSVD）和基于点的 Fréchet 体素距离（FPVD）。

由于缺乏专门针对 LiDAR 场景的预训练分类器，我们采用基于分割的预训练模型进行评估。具体而言，我们分别通过三种简单方法计算 FRID、FSVD、FPVD，所用方法分别是 RangeNet++ [38]、MinkowskiNet [8] 与 SPVCNN [51]。

方法	感知			统计	
	FRID ↓	FSVD ↓	FPVD ↓	JSD ↓	MMD ↓ (10^{-4})
噪声	3277	497.1	336.2	0.360	32.09
LiDARGAN [6]	1222	183.4	168.1	0.272	4.74
LiDARVAE [6]	199.1	129.9	105.8	0.237	7.07
LiDARGen [62] (1160秒)	129.1	39.2	33.4	0.188	2.88
LiDARGen [62] (50秒)	2051	480.6	400.7	0.506	9.91
LDM [44] (50秒)	199.5	70.7	61.9	0.236	5.06
LiDM (本工作, 50秒)	158.8	53.7	42.7	0.213	4.46
Δ 改进	20.4%	24.0%	31.0%	9.7%	11.9%

表 1. 与近期最先进方法在无条件 LiDAR 场景生成上的比较。我们在 64 条光束（即 KITTI-360 [31]）数据上进行实验。↓ 表示值越低越好。N -s 指推理时的 N 个采样步数。Δ Improv. 是相对于具有相同扩散步数的 Latent Diffusion (LDM) [44] 基线方法的相对提升。注意，LiDARGen [62] 的扩散过程有 232 个层级且每层有 5 次迭代（即总共 1160 步）。表示基线结果，表示我们的结果。

与依赖于最终阶段每张输入图像全局特征计算的 FID 不同，我们提出的指标基于每个 LiDAR 场景在中间阶段输出特征的平均值。通过样本与真实世界数据的计算特征，我们得以在感知空间中比较以往 LiDAR 生成器与我们的 LiDMs 的性能。详见补充材料。

4. 实验

4.1. 实验设置

我们在来自 nuScenes [14] 的 32 光束郊区 LiDAR 场景和来自 KITTI-360 [31] 的 64 光束城市 LiDAR 场景上训练与评估模型。对于 32 光束场景，我们在包含 286,816 个样本的完整训练集上训练自编码器，并在 10,921 个样本上进行验证。对于 64 光束场景，我们在 9 条序列的 63,315 个样本（包含训练集和测试集）上训练自编码器，并在一条序列的 1,031 个样本上评估。与自编码器不同，我们在两个数据集广泛采用的子集上训练与验证 LiDM，这些子集提供多种条件，包括边界框、多相机视图或透视图。具体地，我们采用 SemanticKITTI [5] 用于 Semantic-Map-to-LiDAR 任务。

我们的 LiDMs 处理的深度图像尺寸为 32×1024 （32 扫描线数据）和 64×1024 （64 扫描线数据）。深度图像的像素值通过二进制对数然后缩放得到。训练在八块每块配备 24GB 显存的 NVIDIA RTX 3090 上进行，其中一块用于推理。

4.2. 无条件 LiDAR 扩散

为验证方法有效性，我们在 KITTI-360 [31] 的 64 扫描线数据上训练无条件 LiDMs。




图 3. 来自 LiDARGen [62]、潜在扩散模型 [44] 的样本，以及我们的 LiDMs 在 64 束场景下的样本。




图4. 我们 LiDMs 在 32 光束场景下的样本。

我们使用 FRID（范围图像）、FSVD（稀疏体素）和 FPVD（基于点的体素）来评估每种方法的性能，如第 3.6 节所述。这三项指标共同使感知评估能够衡量不同方法生成的 LiDAR 场景的质量。

如表1所示，在采样步数非常有限（即50步）的情况下，我们在几乎所有评估指标上都建立了新的最先进水平。具体而言，在50步采样内，我们的方法在所有考虑的指标上都大幅超越了先前的最先进方法（即LiDARGen [62]）。此外，仅用50步评估时，我们的方法与使用更长扩散过程（1160步）的LiDARGen表现相当。同时，LiDMs相较于基线模型LDM [44]报告了9.7%到31.0%的改进。为进行定性对比，图3展示了各模型生成的示例及参考点云。




图5. 来自我们 LiDM 的样本，用于 Semantic-Map-to-LiDAR 在 SemanticKITTI [5] 上的生成。

我们进一步在图4 中提供了一些 32 光束的示例。

4.3 条件式 LiDAR 扩散

为进一步挖掘 LiDM 的潜力，我们实现了多种条件式 LiDAR 场景生成变体，包括语义地图到 LiDAR 和相机到 LiDAR。为进行定量分析，我们将 LiDM 与 LiDARGen [62] 及我们的基线潜在扩散模型 [44] 进行了比较，结果见表2。

方法	语义地图到激光雷达 [5]					相机到激光雷达 [31]				
	FRID ↓	FSVD ↓	FPVD ↓	JSD ↓	MMD ↓ (10 ⁻⁴)	FRID ↓	FSVD ↓	FPVD ↓	JSD ↓	MMD ↓ (10 ⁻⁴)
LiDARGen [62]	42.5	31.7	30.1	0.130	5.18	-	-	-	-	-
Latent Diffusion [44]	24.0	21.3	20.3	0.088	3.73	50.2	35.9	26.5	0.256	3.80
LiDAR Diffusion (ours)	22.9	20.2	17.7	0.072	3.16	44.9	32.5	25.8	0.205	3.69

表 2. 与近期最先进方法在条件式 LiDAR 场景生成上的比较。我们在 SemanticKITTI [5] 上进行语义地图到 LiDAR 的实验，并在 KITTI-360 [31] 上进行相机到 LiDAR 的实验。“↓”表示值越低越好。我们通过拼接操作在 LiDARGen 上实现语义地图到 LiDAR。LiDARGen 在相机到 LiDAR 的拼接方式不可行，因此我们未在该设置中报告结果。




图6. 在 KITTI-360 [31] 上用于条件相机到激光雷达生成的 LiDM 示例。橙色框表示输入图像覆盖的区域。对于每个场景，KITTI-360 提供一个视角，只覆盖场景的一部分。因此，LiDM 对相机覆盖的区域执行条件生成，而对其余未观测到的区域执行无条件生成。

语义地图到 LiDAR 将语义地图转换为 RGB 图像是典型的图像到图像翻译任务 [21]。然而，在 LiDAR 场景生成的语境下这一方向仍然未被充分探索。正如我们报告的结果所示，LiDM 在很大程度上优于 Latent Diffusion 和 LiDARGen。此外，用语义地图对 LiDM 进行条件化相比无条件生成带来显著提升。我们认为，获取此类数据增强了 LiDM 在语义层面的理解，从而有助于生成更符合 LiDAR 真实感的场景。图 5 进一步说明了基于语义地图条件化在 LiDM 中的有效性。

相机到 LiDAR 在自动驾驶的语境中，相机视角是司空见惯的。

为了探究摄像头与 LiDAR 传感器数据之间的关系与互补性，我们在 KITTI-360 [31] 上实现了从摄像头到 LiDAR 的生成。在该设置中，LiDM 在所有指标上比 LiDARGen [62] 高出超过 36%，同时也成功从相机视图中捕捉到语义信息。在图 6 顶部，我们看到 LiDM 从包含无物体道路的输入图像生成了平滑的地面。类似地，在底部我们看到 LiDM 从图像中提取到车辆存在的语义信息并在合成的 LiDAR 场景中生成了该车辆，尽管它在三维空间中对车辆精确尺度的把握仍有困难。

4.4. 零次学习 文本到 LiDAR 生成

文本到图像的学习最近因对比语言-视觉预训练范式的引入而非常流行[41]。为便于在语言引导条件下生成 LiDAR，我们提出了基于预训练的相机到 LiDAR 的 LiDM 的零样本文本到 LiDAR 生成，该模型可转换用于文本到 LiDAR 任务。通过提供的提示，LiDM 能为输入提示幻觉出可能的场景。图 7 展示了支持该观点的一些证据。然而，当面对复杂提示时，文本到 LiDAR 的 LiDM 仍难以生成场景，主要归因于可用训练数据量有限所施加的约束。

4.5. 关于 LiDAR 真实感生成的研究

我们探索了为 LiDAR 压缩设计的自编码器，并对我们提出的逐点坐标监督进行了消融。在不同缩放因子上进行曲线式与块状编码的实验，以分析 LiDAR 压缩的行为。图 8 的结果表明，曲线式编码通常优于块状编码。然而，通过引入一个阶段的块状编码，我们允许自编码器在保持竞争性性能的同时进一步压缩矩阵图。为在性能与压缩率之间取得平衡，我们选择了 $f_c = 2$ 和 $f_p = 4$ 作为实验的默认设置。

此外，我们研究了所提逐点坐标监督的有效性。可视化结果在




图7. 64束场景下零样本文本到LiDAR生成的LiDM样本。橙色虚线圈起的区域表示受条件影响的区域，绿色框标出可能与提示关联的物体。




图 8. 整体缩放因子 ($f_c \times f_p$) 与采样质量 (FRID & FSVD) 关系。我们在 KITTI-360 [31] 上比较不同尺度的曲线级编码 (Curve)、块级编码 (Patch)，以及带有一阶段 (C+1P) 或两阶段 (C+2P) 块级编码的曲线级编码。

图9说明了点位坐标监督通过在三维空间重建更清晰的边界，帮助自编码器保留场景级几何信息。

4.6. 效率分析

效率对 LiDAR 生成模型尤为重要，特别是在考虑向下游任务部署时。为研究 LiDM 的这方面表现，我们提供了 LiDM 与先前基于点的最新扩散模型 LiDARGen [62] 在吞吐量（样本/秒）和推理速度（步/秒）方面的总体比较。




图9. 来自 LiDM 的样本，比较了是否采用第3.3节所述的点位监督。

方法	扩散尺寸	吞吐量 [†]	推理速度 [†]
LiDARGen [62]	64×1024	0.015	17.5
LiDM (本方法)	16×128	1.603	80.2

表3. 在 64 光束场景下 LiDARGen 与我们的 LiDM 的效率。我们将每个模型每秒生成的样本数作为吞吐量。Infer. Speed 表示每秒的推理次数（即一次推理代表一个扩散步骤）。我们在一块 NVIDIA RTX 3090 上测试两种模型，并调整批量大小以充分利用 24GB GPU 内存。

如表3所示，LiDM 的吞吐量和推理速度分别比 LiDARGen [62] 快约 $\times 107$ 和 $\times 4.6$ ，这表明我方法在效率方面的优越性。

5. 限制

LiDM 相较于真实世界的 Li-DAR 数据存在视觉差距。如先前工作所示 [44]，扩散模型应当足够强大以捕捉输入数据的语义信息，因此我们认为自动编码器在恢复场景大部分细节时是失败的关键。我们的贡献是朝着 LiDAR 现实的自动编码器迈出的一步，但仍需进一步工作。例如，自动编码器可能重建出物体与背景之间模糊的边界，这在距离图上虽难以察觉，却可能导致三维空间中视觉上不合理的物体。

6. 结论

我们提出了 LiDAR 扩散模型 (LiDMs)，一种用于 LiDAR 场景生成的通用条件框架。为兼顾曲线状模式以及场景层级和目标层级的几何特性，我们为扩散模型设计了一个高效的潜在空间以实现逼真的 LiDAR 生成。该设计使得我们的 LiDMs 在无条件下生成上具有竞争力，并在 64 波束场景的有条件生成中达到最先进水平，同时使 LiDMs 能够接受多种条件进行可控生成，包括语义图、相机视角和文本提示。据我们所知，这是首个成功将条件引入 LiDAR 生成的方法。

参考文献

- [1] Midjourney. <https://www.midjourney.com>. 1, 2
- [2] Stable diffusion. <https://github.com/CompVis/stable-diffusion>. 1, 2
- [3] Panos Achlioptas, Olga Diamanti, Ioannis Mitliagkas, and Leonidas Guibas. 学习 3 d 点云的表示与生成模型。载于国际机器学习大会, 页40-49. PMLR, 2018. 3, 5
- [4] Alexander Amini, Tsun-Hsuan Wang, Igor Gilitschenski, Wilko Schwarting, Zhijian Liu, Song Han, Sertac Karaman, and Daniela Rus. Vista 2.0: 一个开放的、基于数据的模拟器, 用于多模态感知和自动驾驶策略学习。载于2022年国际机器人与自动化会议 (ICRA), 页2419-2426. IEEE, 2022. 2
- [5] Jens Behley, Martin Garbade, Andres Milioto, Jan Quenzel, Sven Behnke, Cyrill Stachniss 和 Jurgen Gall. Semantickitti: 用于激光雷达序列语义场景理解的数据集。载于 IEEE/CVF 国际计算机视觉大会论文集, 页码 9297-9307, 2019. 5、6、7
- [6] Lucas Caccia, Herke Van Hoof, Aaron Courville 和 Joelle Pineau. 激光雷达数据的深度生成建模。载于 2019 IEEE/RSJ 国际智能机器人与系统会议 (IROS), 页码 5034-5040. IEEE, 2019. 2、3、5
- [7] Yen-Chi Cheng, Hsin-Ying Lee, Sergey Tuyakov, Alex Schwing 和 Liangyan Gui. SDFusion: 多模态三维形状补全、重建与生成。arXiv, 2022. 2
- [8] Christopher Choy, JunYoung Gwak, and Silvio Savarese. 4d 时空卷积网络: Minkowski 卷积神经网络。载于 IEEE/CVF 计算机视觉与模式识别会议论文集, 页 3075-3084, 2019. 5
- [9] Prafulla Dhariwal and Alexander Nichol. 扩散模型在图像合成上超越 GAN。载于神经信息处理系统进展, 34:8780-8794, 2021. 2, 5
- [10] Alexey Dosovitskiy, German Ros, Felipe Codevilla, Antonio Lopez, and Vladlen Koltun. CARLA: 一个开放的城市驾驶模拟器。载于机器学习会议, 页 1-16. PMLR, 2017. 2
- [11] Ziya Erkoç, Fangchang Ma, Qi Shan, Matthias Nießner, and Angela Dai. 超扩散: 用权重空间扩散生成隐式神经场, 2023. 2
- [12] Patrick Esser, Robin Rombach, and Bjorn Ommer. 驯服变换器以实现高分辨率图像合成。载于 IEEE/CVF 计算机视觉与模式识别会议论文集, 页 12873-12883, 2021. 4
- [13] Haoqiang Fan, Hao Su, and Leonidas J Guibas. 用于从单幅图像重建三维物体的点集生成网络。载于 IEEE 计算机视觉与模式识别会议论文集, 页 605-613, 2017. 3
- [14] Whye Kit Fong, Rohit Mohan, Juana Valeria Hurtado, Lubing Zhou, Holger Caesar, Oscar Beijbom, and Abhinav Valada. Panoptic nusenes: 一个用于激光雷达全景分割与跟踪的大规模基准。IEEE 机器人与自动化快报, 7(2):3795-3802, 2022. 5
- [15] Maurice Fréchet. 关于两种概率分布之间的距离。载于 Annales de l'ISUP, 页 183-198, 1957. 5
- [16] Anchit Gupta, Wenhan Xiong, Yixin Nie, Ian Jones 和 Bar-las Oğuz. 3dgen: 用于有纹理网格生成的三平面潜在扩散。arXiv 预印本 arXiv:2303.05371, 2023. 2
- [17] Martin Heusel, Hubert Ramsauer, Thomas Unterthiner, Bernhard Nessler 和 Sepp Hochreiter. 按双时尺度更新规则训练的 GAN 收敛到局部纳什均衡。Advances in Neural Information Processing Systems, 30, 2017. 5
- [18] Jonathan Ho, Ajay Jain 和 Pieter Abbeel. 去噪扩散概率模型。Advances in Neural Information Processing Systems, 33:6840-6851, 2020. 2, 5
- [19] 胡婧瑜, 许家希, 刘正哲, 李睿辉, 和傅志荣. 基于神经小波域扩散的 3 d 形状生成、反演与操作。arXiv 预印本 arXiv:2302.00190, 2023. 2
- [20] Jordan SK Hu 和 Steven L Waslander. 面向模式感知的数据增强用于激光雷达 3D 目标检测。载于 2021 年 IEEE 国际智能交通系统会议 (ITSC), 页码 2703-2710. IEEE, 2021. 2
- [21] Phillip Isola, Jun-Yan Zhu, Tinghui Zhou, 和 Alexei A. Efros. 基于条件对抗网络的图像到图像翻译。载于 IEEE 计算机视觉与模式识别大会论文集, 页码 1125-1134, 2017. 4, 7
- [22] Kanishk Jain, Varun Chhangani, Amogh Tiwari, K Madhava Krishna, 和 Vineet Gandhi. Ground then navigate: 在动态场景中的语言引导导航。发表于 2023 年 IEEE 国际机器人与自动化会议 (ICRA), 第 4113-4120 页。IEEE, 2023. 4
- [23] Tero Karras, Timo Aila, Samuli Laine, 和 Jaakko Lehtinen. 逐步成长的 GAN 以提高质量、稳定性与多样性。arXiv 预印本 arXiv:1710.10196, 2017. 5
- [24] Tero Karras, Samuli Laine, 和 Timo Aila. 基于风格的生成对抗网络架构。发表于 IEEE/CVF 计算机视觉与模式识别会议论文集, 第 4401-4410 页, 2019.
- [25] Tero Karras, Samuli Laine, Miika Aittala, Janne Hellsten, Jaakko Lehtinen 和 Timo Aila. 分析并改进 StyleGAN 的图像质量。载于 IEEE/CVF 计算机视觉与模式识别会议论文集, 页码 8110-8119, 2020. 5
- [26] Diederik Kingma, Tim Salimans, Ben Poole 和 Jonathan Ho. 变分扩散模型。载于 Advances in Neural Information Processing Systems, 34:21696-21707, 2021. 2
- [27] Nathan Koenig 和 Andrew Howard. Gazebo 的设计与使用范式——一款开源多机器人模拟器。载于 2004 年 IEEE/RSJ 国际智能机器人与系统大会 (IROS)(IEEE Cat. No. 04CH37566), 页码 2149-2154. IEEE, 2004. 2
- [28] Bo Li, Tianlei Zhang, and Tian Xia. 使用全卷积网络的 3D 激光雷达车辆检测。arXiv 预印本 arXiv:1608.07916, 2016. 2
- [29] Muheng Li, Yueqi Duan, Jie Zhou, and Jiwen Lu. Diffusion-sdf: 基于体素化扩散的文本到形状。arXiv 预印本 arXiv:2212.03293, 2022. 2

- [30] 李雨涵, 窦一顺, 陈轩宏, 倪兵兵, 孙一琳, 刘宇天, 与 王甫臻. 3dqd: 通过零件离散化扩散过程的广义 deep3d 形状先验. arXiv 预印本 arXiv:2303.10406, 2023. 2
- [31] 廖一一, 谢军, 与 安德烈亚斯·盖格. Kitti-360: 一个用于二维和三维城市场景理解的新数据集与基准. IEEE 模式分析与机器智能学报, 45(3):3292-3310, 2022. 5, 7, 8
- [32] 刘珍, 冯尧, Michael J. Black, Derek Nowrouzezahrai, Liam Paull, 与 刘慰阳. Meshd-iffusion: 基于得分的生成三维网格建模. 收录于国际学习表征会议, 2023. 2
- [33] 罗世通 和 胡威. 用于三维点云生成的扩散概率模型. 载于 IEEE/CVF 计算机视觉与模式识别会议 (CVPR) 论文集, 第 2837-2845 页, 2021. 2
- [34] 吕照阳、王金益、安雨伟、张雅、林大华 与 戴博. 通过稀疏潜在点扩散模型实现可控网格生成. arXiv 预印本 arXiv:2303.07938, 2023. 2
- [35] Sivabalan Manivasagam、Shenlong Wang、Kelvin Wong、Wenyuan Zeng、Mikita Sazanovich、Shuhan Tan、Bin Yang、Wei-Chiu Ma 与 Raquel Urtasun. LidarSim: 通过利用真实世界实现逼真激光雷达模拟. 载于 IEEE/CVF 计算机视觉与模式识别会议论文集, 第 11167-11176 页, 2020. 2, 3
- [36] Luke Melas-Kyriazi、Christian Rupprecht 与 Andrea Vedaldi. Pc2: 用于单幅图像三维重建的投影条件点云扩散. 在 Arxiv, 2023. 2
- [37] Gregory P Meyer、Ankit Laddha、Eric Kee、Carlos Vallespi-Gonzalez 与 Carl K Wellington. Lasernet: 一种用于自动驾驶的高效概率性三维目标检测器. 在 IEEE/CVF 计算机视觉与模式识别会议论文集中, 页码 12677-12686, 2019. 2
- [38] Andres Milioto、Ignacio Vizzo、Jens Behley 与 Cyrill Stachniss. Rangenet++: 快速且精确的激光雷达语义分割. 在 2019 IEEE/RSJ 国际智能机器人与系统会议 (IROS), 页码 4213-4220. IEEE, 2019. 2, 5
- [39] Alex Nichol、Prafulla Dhariwal、Aditya Ramesh、Pranav Shyam、Pamela Mishkin、Bob McGrew、Ilya Sutskever 和 Mark Chen. 《GLIDE: 面向光真实感图像生成与基于文本引导的扩散模型编辑》. arXiv 预印本 arXiv:2112.10741, 2021. 2
- [40] Alex Nichol、Heewoo Jun、Prafulla Dhariwal、Pamela Mishkin 和 Mark Chen. 《Point-e: 从复杂提示生成三维点云的系统》. arXiv 预印本 arXiv:2212.08751, 2022. 2
- [41] Alec Radford、Jong Wook Kim、Chris Hallacy、Aditya Ramesh、Gabriel Goh、Sandhini Agarwal、Girish Sastry、Amanda Askell、Pamela Mishkin、Jack Clark 等人. 《从自然语言监督学习可迁移的视觉模型》. 载于国际机器学习大会, 页8748-8763. PMLR, 2021. 4、7
- [42] Aditya Ramesh、Mikhail Pavlov、Gabriel Goh、Scott Gray、Chelsea Voss、Alec Radford、Mark Chen 和 Ilya Sutskever. 零样本文本到图像生成. 载于国际机器学习大会 (International Conference on Machine Learning), 页码 8821-8831. PMLR, 2021. 4
- [43] Aditya Ramesh、Prafulla Dhariwal、Alex Nichol、Casey Chu 和 Mark Chen. 基于 CLIP 潜在空间的分层文本条件图像生成. arXiv 预印本 arXiv:2204.06125, 1(2):3, 2022. 2, 4
- [44] Robin Rombach、Andreas Blattmann、Dominik Lorenz、Patrick Esser 和 Björn Ommer. 基于潜在扩散模型的高分辨率图像合成. 载于 IEEE/CVF 计算机视觉与模式识别会议论文集, 页码 10684-10695, 2022. 1, 2, 3, 4, 5, 6, 7, 8
- [45] Olaf Ronneberger、Philipp Fischer 和 Thomas Brox. U-net: 用于生物医学图像分割的卷积网络. 收录于 Medical Image Computing and Computer-Assisted Intervention–MICCAI 2015: 第18届国际会议, 德国慕尼黑, 2015年10月5-9日, 论文集, 第三部分, 第18卷, 第234-241页. Springer, 2015. 5
- [46] Chitwan Saharia、William Chan、Saurabh Saxena、Lala Li、Jay Whang、Emily L Denton、Kamyar Ghasemipour、Raphael Gontijo Lopes、Bircu Karagol Ayan、Tim Salimans 等. 具有深度语言理解的逼真文本到图像扩散模型. Advances in Neural Information Processing Systems, 35: 36479-36494, 2022. 5
- [47] J Ryan Shue、Eric Ryan Chan、Ryan Po、Zachary Ankner、Jiajun Wu 和 Gordon Wetzstein. 使用三平面扩散的3D神经场生成. arXiv preprint arXiv:2211.16677, 2022. 2
- [48] Jascha Sohl-Dickstein、Eric Weiss、Niru Maheswaranathan 和 Surya Ganguli. 使用非平衡热力学的深度无监督学习. 载于国际机器学习会议, 页码 2256-2265. PMLR, 2015. 2,5
- [49] Colton Stearns、Jiateng Liu、Davis Rempe、Despoina Paschalidou、Jeong Joon Park、Sebastien Mascha 和 Leonidas J Guibas. Curvecloudnet: 处理具有一维结构的点云. arXiv 预印本 arXiv:2303.12050, 2023. 2,3
- [50] Christian Szegedy、Vincent Vanhoucke、Sergey Ioffe、Jon Shlens 和 Zbigniew Wojna. 重新思考用于计算机视觉的 Inception 架构. 载于 IEEE 计算机视觉与模式识别大会论文集, 页码 2818-2826, 2016. 5
- [51] 唐昊天, 刘志坚, 赵盛宇, 林玉军, 林吉, 王涵睿, 和 韩松. 使用稀疏点-体素卷积搜索高效的 3D 架构. 在欧洲计算机视觉大会, 页 685-702. Springer, 2020.5
- [52] Michał J Tyszkiewicz, Pascal Fua, 和 Eduard Trulls. Gecco: 几何条件点扩散模型. arXiv 预印本 arXiv:2303.05916, 2023. 2
- [53] Aaron Van Den Oord, Oriol Vinyals, 等. 神经离散表示学习. Advances in Neural Information Processing Systems, 30, 2017. 4
- [54] Tsun-Hsuan Wang, Alexander Amini, Wilko Schwarting, Igor Gilitschenski, Sertac Karaman, 和 Daniela Rus. 通过数据驱动仿真学习交互式驾驶策略. 在 2022 年国际机器人与自动化会议 (ICRA), 页 7745-7752. IEEE, 2022. 2

- [55] 吴必辰, Alvin Wan, 岳向宇, 和 Kurt Keutzer. Squeezeseg: 用于实时从 3D 激光雷达点云进行道路物体分割的卷积神经网络与递归 CRF. 载于 2018 年 IEEE 国际机器人与自动化会议 (ICRA), 页 1887-1893. IEEE, 2018. 2
- [56] 徐虎, Gargi Ghosh, Po-Yao Huang, Dmytro Okhonko, Armen Aghajanyan, Florian Metze, Luke Zettlemoyer, 和 Christoph Feichtenhofer. Videoclip: 用于零样本视频-文本理解的对比预训练. arXiv 预印本 arXiv:2109.14084, 2021. 4
- [57] 杨冠道, 黄勋, 赵坤皓, Ming-Yu Liu, Serge Belongie, 和 Bharath Hariharan. Pointflow: 基于连续正规化流的 3D 点云生成. 载于 IEEE/CVF 国际计算机视觉会议论文集, 页 4541-4550, 2019. 3
- [58] 杨耀庆, 冯晨, 沈怡如, 田东. FoldingNet: 通过深度网格变形的点云自编码器. 载于《IEEE 计算机视觉与模式识别会议论文集》, 页 206-215, 2018. 3
- [59] 曾晓辉, Arash Vahdat, Francis Williams, Zan Gojcic, Or Litany, Sanja Fidler, Karsten Kreis. LION: 用于三维形状生成的潜在点扩散模型. 载于《神经信息处理系统大会 (NeurIPS)》, 2022. 2
- [60] 张吕民, Rao Anyi, Maneesh Agrawala. 在文本到图像扩散模型中添加条件控制. 载于《IEEE/CVF 国际计算机视觉大会论文集》, 页 3836-3847, 2023. 1, 2, 4
- [61] 周林琪, 杜一伦, 吴家骏. 通过点-体素扩散进行 3D 形状生成与补全. 载于 IEEE/CVF 国际计算机视觉大会 (ICCV) 论文集, 第 5826-5835 页, 2021. 2
- [62] 弗拉斯·兹里亚诺夫, 朱锡玥, 王神龙. 学习生成逼真的激光雷达点云. 载于欧洲计算机视觉大会, 第 17-35 页. 施普林格, 2022. 2, 3, 5, 6, 7, 8