

将扩散模型蒸馏到高效的 3D 激光雷达场景补全


张胜源¹ 赵安¹ 杨凌³ 李泽骏^{2,*} 孟晨烨¹

郝然 Xu⁴ 陈天润¹ 魏安阳⁴ 顾鹏云⁴ 孙岭云¹

¹ 浙江大学计算机科学与技术学院 ² 浙江大学软件技术学院 ³ 北京大学 ⁴ 浙江绿智行科技有限公司

^{1,2}{ zhangshengyuan,zhaoan040113,zejianlee,mengcy,tianrun.chen,sunly } @zju.edu.cn ³{ yangling0818 } @163.com ⁴{ Haoran.Xu5,weianyang,gupengyun } @geely.com * 通讯作者

SemanticKITTI



KITTI360




图1。LiDAR 场景补全示例演示。给定 (a) 中的稀疏 LiDAR 扫描，模型旨在恢复如 (b) 所示的真实密集场景。在这些示例中，扫描来自 SemanticKITTI [1] 和 KITTI360 [20] 数据集。在两种情况下，作为最新方法的 LiDiff [28] 如 (c) 所示大约需要 30 秒。相比之下，我们提出的 ScoreLiDAR 在 (d) 中仅需约 5 秒，实现超过 5 倍的加速，并通过更低的 Chamfer 距离 (CD) 表现出更好的补全质量。

摘要

由于训练稳定性强且完成质量高，扩散模型已被用于 3D LiDAR 场景补全。然而，采样速度慢限制了基于扩散的场景补全模型的实际应用，因为自动驾驶需高效感知周围环境。本文提出一种针对 3D LiDAR 场景补全模型的新蒸馏方法，称为 ScoreLiDAR，可实现高效且高质量的场景补全。ScoreLiDAR 使蒸馏后模型在显著更少步数内完成采样。为提升补全质量，我们还引入一种新型结构损失 (Structural Loss)，以促使蒸馏模型捕捉 3D LiDAR 场景的几何结构。

损失包含一个约束整体结构的场景级项和一个约束关键地标点及其相对配置的点级项。大量实验表明，ScoreLiDAR 将 SemanticKITTI 每帧完成时间从 30.55 秒显著加速到 5.37 秒 (>5×)，并在性能上优于最先进的 3D LiDAR 场景完成模型。我们的模型和代码已公开于 <https://github.com/happyw1nd/ScoreLiDAR>。

1. 引言

使用车载传感器准确且高效地识别周围环境对于自动驾驶车辆的安全运行至关重要 [17, 18]。




图 2. 在 SemanticKITTI [1] 数据集上不同模型的 LiDAR 场景完形性能可视化。总体而言，我们提出的 ScoreLiDAR 在场景完形性能与速度之间取得了更好的权衡。

在不同类型的传感器中，3D LiDAR 因其更广的探测范围和更高的探测精度而成为最广泛采用的传感器之一 [25, 28]。然而，驾驶场景通常复杂，LiDAR 收集的 3D 点云通常稀疏，尤其在遮挡区域 [16, 38]。这种稀疏性导致对 3D 场景的理解能力下降 [3, 28]。因此，推断并补全稀疏的 3D LiDAR 场景是必要的，以提供更密集且更全面的场景表示。

由于训练稳定性强且生成质量高等优势，现有工作采用扩散模型来完成 3D LiDAR 场景并取得了卓越成果 [27, 28]。然而，扩散模型通常需要多次网络迭代才能获得稠密、完整且高质量的 LiDAR 场景，因而耗时较多 [13, 54]。自动驾驶车辆需要对周围环境进行快速高效的感知与识别，故采样速度慢限制了扩散模型的实际应用。尽管已有工作提出了扩散模型的加速方法 [22, 33, 37, 40, 49]，但鉴于 3D LiDAR 场景与图像数据的差异——LiDAR 场景通常包含复杂的几何结构信息——这些技术尚未在基于扩散的 LiDAR 场景完成模型加速方面得到探索。

在本工作中，我们提出了 ScoreLiDAR，一种为 3D LiDAR 场景补全扩散模型量身定制的新型蒸馏方法，能够实现高效且高质量的场景补全（图 1 和图 2）。ScoreLiDAR 致力于应对 LiDAR 场景补全中独特的 3D 分布对齐挑战。

通过利用双向梯度引导机制，学生模型在稀疏点云条件下的补全结果得以逐步接近教师模型的多步迭代重建质量。对于学生模型生成的已补全场景，教师模型预测该场景的得分作为梯度以增强真实感，同时设计的辅助模型预测场景的另一个得分作为梯度以抑制不真实的补全。随后根据这两种梯度的差异更新学生模型。该更新促使补全过程朝向结构更连贯的 LiDAR 场景。最后，我们引入由场景项和点项构成的结构损失，以约束关键地标点及其相对配置。先前研究 [19, 23, 41, 42] 证明双向梯度引导机制能有效加速 3D 渲染速度。在本工作中，我们认为类似方法可直接应用于基于扩散的 LiDAR 场景补全模型的蒸馏。

我们的贡献可总结为：(1) 我们提出 ScoreLiDAR，一种针对基于扩散的 3D LiDAR 场景补全模型的全新蒸馏方法，实现高效的场景补全。(2) 我们引入结构损失，在蒸馏过程中有效捕捉 3D 点云的几何结构信息，确保高质量的场景补全。(3) 大量实验表明，ScoreLiDAR 在实现快速高效的场景补全的同时，相较现有模型达到最佳的生成质量。

2. 相关工作

3D 激光雷达场景补全 3D 激光雷达场景补全是指在自动驾驶等应用中从稀疏、不完整的激光雷达扫描中恢复完整场景 [38, 46]。当前主流的激光雷达场景补全方法包括基于深度补全和基于符号距离场 (SDF) 的方法。基于深度补全的方法旨在从稀疏深度测量恢复稠密深度图 [9, 43, 47]。这些方法通常采用深度学习技术 [4, 7]，也可结合 RGB 图像的引导以获得更高质量的补全结果 [32, 50, 53]。基于 SDF 的方法将场景表示为体素网格，核心思想是利用符号距离场来补全稀疏的激光雷达场景 [16, 38]。这些方法受限于体素分辨率，易导致场景细节丢失 [6, 28]。此外，也有方法引入语义信息以增强激光雷达场景补全 [31, 44]。这些方法能够生成稠密且完整的场景，同时为每个点提供语义标签，从而具有更广泛的应用潜力 [39, 48]。

基于扩散的 3D LiDAR 场景补全

由于扩散模型具有较强的训练稳定性和高质量的生成能力，许多方法将扩散模型用于 LiDAR 场景补全任务 [3, 14, 27-29]。Lee 等人 [14] 的工作首次场景尺度上将扩散模型应用于 LiDAR 场景补全，使得可以在稀疏点云的部分观测条件下生成逼真的场景。类似地，R2DM [27] 利用基于距离和反射强度的图像表示的扩散模型来生成各种高保真度的 3D LiDAR 场景。LiDiff [28] 指出在场景尺度上向点云数据添加噪声会导致细节丢失。因此，LiDiff 提出直接在单个点上操作并重新定义噪声调度与去噪过程，以生成具有更丰富细节的场景。在 LiDiff 基础上，DiffSSC [3] 进一步通过在点和语义空间中分别执行去噪和分割来完成语义场景补全任务。此外，LiDMs [29] 从模式真实感、几何真实感和物体真实感的角度构建流水线，实现了在不同条件下的生成。

由于扩散模型固有的采样缓慢，基于扩散的 3D LiDAR 场景补全在推理时速度较慢，限制了其在自动驾驶车辆中的应用。因此，本文提出了一种针对基于扩散的 3D LiDAR 场景补全模型的蒸馏方法，以实现更快且更高质量的补全。

3. 预备知识

3.1. 扩散模型简要介绍

扩散模型有两个过程：正向扩散和反向去噪过程 [10, 34]。在正向扩散过程中，给定来自训练分布的数据 $\mathbf{x}^0 \sim q(\mathbf{x})$ ，扩散模型根据不同时间步 $t \in [1, T]$ 向 $\mathbf{x}^0$ 添加不同尺度的噪声以得到噪声数据 $\{\mathbf{x}^1, \mathbf{x}^2, \dots, \mathbf{x}^T\}$ 。当 T 足够大时， $\mathbf{x}^T$ 趋近于标准高斯分布，即 $q(\mathbf{x}^T) \approx \mathcal{N}(0, I)$ 。该过程由一系列预定义的噪声因子 β^t 参数化。通过定义 $\alpha^t = 1 - \beta^t$ ，扩散过程表示为 [10]：

$$\mathbf{x}^t = \sqrt{\alpha^t} \mathbf{x}^0 + \sqrt{1 - \alpha^t} \boldsymbol{\epsilon}^t \quad (1)$$

这里 $\bar{\alpha}^t = \prod_{s=1}^t \alpha^s$, $p(\mathbf{x}^t | \mathbf{x}^0) = \mathcal{N}(\sqrt{\bar{\alpha}^t}, (1 - \bar{\alpha}^t)I)$ 。

在训练过程中，扩散模型尝试在不同时间步预测所添加的噪声 t 。给定输入 $\mathbf{x}^0$ 和条件 c （可选），噪声数据 $\mathbf{x}^t$ 可由等式 (1) 计算。扩散模型 ϵ_θ 根据 $\mathbf{x}^t, c, t$ 预测噪声，并通过计算预测噪声与真实噪声之间的 ℓ_2 损失来进行优化。

$$\mathcal{L}_{DM} = \mathbb{E}_{t, \epsilon} [\|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta(\mathbf{x}^t, c, t)\|^2] \quad (2)$$

这里 θ 是 ϵ_θ 的可训练参数。

在反向去噪过程中，扩散模型从时间步 T 开始，逐步去除预测噪声以获得生成样本。

将 $\mathbf{x}^t$ 去噪以得到 $\mathbf{x}^{t-1}$ 的过程可写为文献 [10] 中的形式。

$$\mathbf{x}^{t-1} = \frac{1}{\sqrt{\alpha^t}} \left(\mathbf{x}^t - \frac{1 - \alpha^t}{\sqrt{1 - \bar{\alpha}^t}} \boldsymbol{\epsilon}_\theta(\mathbf{x}^t, c, t) \right) + \sigma^t \mathbf{z} \quad (3)$$

这里 $\mathbf{z} \sim \mathcal{N}(0, I)$ 。在此过程中，所需的推理步数因不同采样方法而异。例如，DDPM [10] 需要 1000 个时间步，而 DDIM [34] 和 DPM solver [21] 可将其减少到不超过 100 个时间步。

3.2. 三维 LiDAR 场景补全扩散模型

三维 LiDAR 场景补全扩散模型接受不完整的扫描

$\mathcal{P} = \{\mathbf{p}_1, \mathbf{p}_2, \dots, \mathbf{p}_N\}$ ($p_i \in \mathbb{R}^3$) 并尝试生成完整场景

$\mathcal{G}^0 = \{\mathbf{p}_1^0, \mathbf{p}_2^0, \dots, \mathbf{p}_M^0\}$ 。给定输入 LiDAR 扫描 $\mathcal{P}$ 与真实标签 $\mathcal{G}$ ，可训练扩散模型执行三维 LiDAR 场景补全。时步 t 的带噪场景 $\mathcal{G}^t$ 是从点级别的真实标签 $\mathcal{G}$ 计算得到的 [3, 28]，

$$\mathbf{p}_m^t = \sqrt{\bar{\alpha}^t} \mathbf{p}_m + \sqrt{1 - \bar{\alpha}^t} \boldsymbol{\epsilon}^t, \forall \mathbf{p}_m \in \mathcal{G} \quad (4)$$

这里 $\mathcal{G}^t = \{\mathbf{p}_1^t, \mathbf{p}_2^t, \dots, \mathbf{p}_M^t\}$ 。由于 LiDAR 点云稀疏，噪声数据几乎不保留原始数据的信息。为了生成更真实的点云场景，可以将 LiDAR 扫描 $\mathcal{P}$ 用作扩散模型的条件 [28]。在这种情况下，扩散模型的训练损失表示为：

$$\mathcal{L}_{DM} = \mathbb{E}_{t, \epsilon} [\|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta(\mathcal{G}^t, \mathcal{P}, t)\|^2] \quad (5)$$

然后，如第 3.1 节所述，完成的场景 $\mathcal{G}^0$ 可以通过从 $\mathcal{G}^T$ 的逐步去噪生成。由于 LiDAR 场景尺度大且各点云轴的数据范围不同，直接对整个场景归一化会把数据压缩到更小范围，可能导致关键细节丢失 $\mathbf{x}^0$ [3, 28]。为解决此问题，LiDiff [28] 通过向每个点 $\mathbf{p}_m$ 添加局部噪声偏移来修改扩散过程，在每个时间步逐渐扰动点云。对于式 (1)，将 $\mathbf{x}^0$ 设为 0，并向每个点 $\mathbf{p}_m$ 添加 $\mathbf{x}^t$ ，

$$\mathbf{p}_m^t = \mathbf{p}_m + \left(\sqrt{\bar{\alpha}^t} \mathbf{0} + \sqrt{1 - \bar{\alpha}^t} \boldsymbol{\epsilon}^t \right) = \mathbf{p}_m + \sqrt{1 - \bar{\alpha}^t} \boldsymbol{\epsilon}^t \quad (6)$$

由于这一特殊情况，初始噪声场景 $\mathcal{G}^T$ 在采样过程中不能直接从标准高斯噪声开始。相反，使用 LiDAR 扫描 $\mathcal{P}$ 来获得 $\mathcal{G}^T$ [28]。首先，给定初始的不完整扫描 $\mathcal{P}$ ，通过将原始点复制 K 倍以增加点云数量，得到伪密集扫描 $\mathcal{P}^* = \{\mathbf{p}_1^*, \mathbf{p}_2^*, \dots, \mathbf{p}_M^*\}$ ，其中我们假设 $M = KN$ 。然后，依据公式 (6) 计算噪声点云 $\mathcal{P}^T$ 。由于 $\mathcal{P}^T$ 已足够嘈杂，可在训练中视作 $\mathcal{G}^T$ 。之后，采用逐步去噪过程以得到完成的场景 $\mathcal{G}^0$ 。




图3。ScoreLiDAR的整体结构。(1) 学生模型基于稀疏扫描生成完成场景。(2) 将稀疏扫描和带噪声的完成场景输入到 ϵ_θ 和 ϵ_ϕ 。(3) 使用 ϵ_θ 和 ϵ_ϕ 的预测得分计算KL散度。(4) 基于完成场景与真实值计算结构损失。(5) 用KL散度与结构损失计算总损失。(6) 根据总损失优化学生模型。(7) 用完成场景更新扩散模型 ϵ_ϕ 。

4. 方法

我们的目标是将一个预训练的 3D 激光雷达场景补全扩散模型蒸馏为采样步骤显著减少的学生模型，从而实现高效且高质量的场景补全。首先，我们在第 4.1 节介绍了针对 3D 激光雷达场景补全扩散模型的蒸馏方法。然后，我们在第 4.2 节引入结构损失，通过场景级损失和点级损失来改进蒸馏过程。最后，我们在第 4.3 节描述了 ScoreLiDAR 的优化流程。

ScoreLiDAR 的整体结构如图 3 所示。

4.1. 用于 3D 激光雷达场景补全的蒸馏

理想情况下，最终的学生模型应以更快的速度实现与教师模型相当的场景完成结果。在 3D LiDAR 场景完成情形中，设 q^0 为真实分布 $\mathcal{G}$ ， ϵ_θ 为预训练的场景完成扩散模型，其多步生成分布近似于 q^0 。设 G_{stu} 为能以生成分布 p_G^0 高效执行 LiDAR 场景完成的学生模型。ScoreLiDAR 的目标是最小化教师模型分布与学生模型生成分布之间的 KL 散度 [42, 52]。

$$\min_{\eta} D_{KL}(p_G^0(\mathcal{G}^0; \eta) \| q^0(\mathcal{G}^0)) \quad (7)$$

这里 $\mathcal{G}^0$ 是通过对以 $\mathcal{P}$ 为条件的 G_{stu} 进行一步采样所生成的完整场景，出于简化起见，我们在表示分布时省略了 $\mathcal{P}$ ， η 是 G_{stu} 的可训练参数。然而， q^0 的高密度区域在数据空间中稀疏，因此很难直接求解式 (7)。根据 [42] 中的定理 1，我们通过最小化不同噪声水平下两种分布之间的 KL 散度来展开式 (7) 中的优化问题，如下：

$$\min_{\eta} \mathcal{L}_{KL} = \mathbb{E}_{t, \epsilon} [D_{KL}(p_G^t(\mathcal{G}^t) \| q^t(\mathcal{G}^t))] \quad (8)$$

这里 t 是控制噪声强度的时间步， ϵ 是随机噪声， $\mathcal{G}^t = \{\mathbf{p}_1^t, \mathbf{p}_2^t, \dots, \mathbf{p}_M^t\}$ 是在时间步 t 对完成场景的带噪版本 $\mathcal{G}^0$ 。方程 (8) 中 G_{stu} 的梯度被近似为

$$\begin{aligned} \nabla_{\eta} D_{KL}(p_G^t(\mathcal{G}^t) \| q^t(\mathcal{G}^t)) \\ = \mathbb{E}_{t, \epsilon} [\nabla_{\mathcal{G}^t} \log p_G^t(\mathcal{G}^t) - \nabla_{\mathcal{G}^t} \log q^t(\mathcal{G}^t)] \frac{\partial \mathcal{G}^t}{\partial \eta} \end{aligned} \quad (9)$$

我们使用预训练扩散模型 ϵ_θ 来近似 $-\sqrt{1 - \bar{\alpha}^t} \nabla_{\mathcal{G}^t} \log q^t(\mathcal{G}^t)$ ，如补充材料第 5 节 (Sec S5) 所述。同样， $-\sqrt{1 - \bar{\alpha}^t} \nabla_{\mathcal{G}^t} \log p_G^t(\mathcal{G}^t)$ 由辅助扩散模型 ϵ_ϕ 近似，该模型在生成样本 $\mathcal{G}^0$ 上独立以去噪损失式 (Eq. (5)) 训练。然后，按 [10, 42] 的简化， $\mathcal{L}_{KL}$ 被估计为

$$\mathcal{L}_{KL} \approx \mathbb{E}_{t, \epsilon} [\|\epsilon_\theta(\mathcal{G}^t, \mathcal{P}, t) - \epsilon_\phi(\mathcal{G}^t, \mathcal{P}, t)\|_2^2] \quad (10)$$

因此，式 (9) 中的梯度可近似为

$$\begin{aligned} \nabla_{\eta} D_{KL}(p_G^t(\mathcal{G}^t) \| q^t(\mathcal{G}^t)) \\ \approx \mathbb{E}_{t, \epsilon} [\epsilon_\theta(\mathcal{G}^t, \mathcal{P}, t) - \epsilon_\phi(\mathcal{G}^t, \mathcal{P}, t)] \frac{\partial \mathcal{G}^t}{\partial \eta} \end{aligned} \quad (11)$$

直观地， $-\epsilon_\theta(\mathcal{G}^t, \mathcal{P}, t)$ 的方向指向预训练分布，而 $-\epsilon_\phi(\mathcal{G}^t, \mathcal{P}, t)$ 的方向指向学生模型的生成分布。因此，沿双向梯度 $[\epsilon_\theta(\mathcal{G}^t, \mathcal{P}, t) - \epsilon_\phi(\mathcal{G}^t, \mathcal{P}, t)]$ 下行更新学生模型的生成分布以朝向预训练分布，使得补全更为准确。附录 S2.1 讨论了蒸馏过程的效率。

4.2. 结构损失

尽管第4.1节中的蒸馏过程在训练模型时有效果[22, 54], 我们发现直接将其应用于 LiDAR 场景补全扩散模型会导致局部细节丢失和真实感下降。这是因为 LiDAR 场景中的点云包含扩散模型未显式捕捉的复杂几何信息。因此, 我们引入结构损失以进一步完善蒸馏过程并提高补全质量。该结构损失包括场景级损失和点级损失, 能够帮助学生模型有效捕捉 3D 点云的几何结构信息。

场景级损失。在第4.1节提到的蒸馏过程中, 式(11)中的梯度 $\nabla_{\eta} D_{KL}$ 在 $t \gg 0$ 时是良定义的, 即生成的样本被高斯噪声完全破坏。然而, 当 t 较小时, $\nabla_{\eta} D_{KL}$ 变得不可靠[52,54]。这是因为学生模型在早期通常会生成次优结果, 原因是点云数据的复杂性。噪声生成的样本容易落在教师模型训练分布之外, 导致教师模型的网络预测不可靠[52,54]。

为了解决此问题, 我们引入场景级损失, 以最小化真实场景 $\mathcal{G}$ 与完成场景 $\mathcal{G}^0$ 之间的距离,

$$\mathcal{L}_{scene} = \frac{1}{|\mathcal{G}^0|} \sum_{\mathbf{p}_i^0 \in \mathcal{G}^0} \min_{\mathbf{p} \in \mathcal{G}} \|\mathbf{p}_i^0 - \mathbf{p}\|^2 \quad (12)$$

该损失计算生成场景中每个点 $\mathbf{p}_i^0$ 与其在真值中最近对应点 $\mathbf{p}$ 之间的均方误差 $\mathcal{G}^0 \mathcal{G}$ 。它帮助学生模型捕捉整体结构, 避免在早期阶段优化方向偏离, 并增强训练稳定性。场景级损失使生成场景在全局上更接近真值, 从而提升补全质量和真实度。

逐点损失。如式 (11) 所示, 蒸馏过程仅约束补全场景的整体分布, 忽略不同点之间的相对位置。直接使用式 (11) 中的梯度去优化学生模型可能导致局部细节丢失。

因此, 我们引入点级损失以捕捉三维 LiDAR 场景中不同点之间的相对结构信息。点级损失计算完成场景与真实值之间的点间距离矩阵差异。由于场景中点数众多, 计算所有点的距离矩阵计算量很大。因此, 我们选择 n 个关键点并与 $n \ll M$ 一起计算距离矩阵。

基于每个点的局部几何特征, 我们选择对表示三维 LiDAR 场景结构至关重要的关键点。对于完成场景中的每个点 $\mathbf{p}_i^0$, 我们在 $\mathcal{G}^0$ 中找到其 K 个最近邻, 记为集合 $\mathcal{K}_i$ 。然后通过计算其曲率 κ_i 来选择关键点。具体步骤如下:

- 计算邻域的质心 $\bar{\mathbf{p}}_i^0 \mathcal{K}_i$

$$\bar{\mathbf{p}}_i^0 = \frac{1}{K} \sum_{\mathbf{p}_j^0 \in \mathcal{K}_i} \mathbf{p}_j^0 \quad (13)$$

- 为 $\bar{\mathbf{p}}_i^0$ 计算邻域协方差矩阵 $\mathcal{C}_i$

$$\mathcal{C}_i = \frac{1}{K} \sum_{\mathbf{p}_j^0 \in \mathcal{K}_i} (\mathbf{p}_j^0 - \bar{\mathbf{p}}_i^0)(\mathbf{p}_j^0 - \bar{\mathbf{p}}_i^0)^T \quad (14)$$

- 对协方差矩阵 $\mathcal{C}_i$ 进行特征分解以获得特征值 $\lambda_1 < \lambda_2 < \dots < \lambda_m$ 。
- 可用特征值计算曲率 κ_i

$$\kappa_i = \frac{\lambda_1}{\sum_{j=1}^m \lambda_j} \quad (15)$$

较大的曲率 κ_i 表示更大的局部形状变化。具有较大局部变化的点通常位于角点、边缘或端点, 往往构成场景的主要结构。因此, 选取曲率值最高的前 n 个点作为关键点。

给定地面真实值 $\mathcal{G} = \{\mathbf{p}_1, \mathbf{p}_2, \dots, \mathbf{p}_M\}$, 我们从点云中选取 n 个关键点 ($n \ll M$) 来构建 $n \times n$ 距离矩阵 $\mathcal{D}$ 。 $d_{ij} \in \mathcal{D}$ 表示点 i 与 j 之间的两两欧氏距离。然后, 对于完成的场景 $\mathcal{G}^0$, 我们从 $\mathcal{G}$ 中选取与关键点最近的 n 个点作为对应关键点以获得距离矩阵 $\mathcal{D}_G$ 。因此, 逐点损失按下式计算

$$\mathcal{L}_{point} = \mathbb{E}_{t, \epsilon} [\|\mathcal{D} - \mathcal{D}_G\|_2^2] \quad (16)$$

逐点损失有助于学生模型捕捉关键点的相对构型, 进一步提升完成场景的几何精度与细节保留。这确保了诸如车辆、路锥和墙等关键物体能更好地被修复, 这对自动驾驶车辆准确识别周围环境至关重要。

结构损失。 G_{stu} 的最终结构损失为

$$\mathcal{L}_{structural} = \lambda_{scene} \mathcal{L}_{scene} + \lambda_{point} \mathcal{L}_{point} \quad (17)$$

此处 λ_{scene} 与 λ_{point} 分别为场景级损失与逐点损失的权重。

模型	CD ↓	JSD ↓	EMD ↓	时间 (秒) ↓
LMSCNet [30]	0.641	0.431	-	0.40
LODE [16]	1.029	0.451	-	1.76
MID [38]	0.503	0.470	-	6.42
PVD [55]	1.256	0.498	-	262.54
LiDiff [28]	0.434	0.444	22.15	30.38
LiDiff (精炼) [28]	0.375	0.416	23.16	30.55
ScoreLiDAR	0.406	0.425	23.14	5.16
ScoreLiDAR (精炼)	0.342	0.399	23.26	5.37

表1. SemanticKITTI 数据集上的补全性能。颜色表示第1、第2和第3名的模型。采样时间基于官方代码和提供的检查点估算。

模型	CD ↓	JSD ↓	EMD ↓	耗时 (秒) ↓
LMSCNet [30]	0.979	0.496	-	0.38
LODE [16]	1.565	0.483	-	1.64
MID [38]	0.637	0.476	-	6.23
LiDiff [28]	0.564	0.459	21.98	29.18
LiDiff (精炼) [28]	0.517	0.446	22.96	29.43
ScoreLiDAR	0.472	0.444	22.80	4.98
ScoreLiDAR (精炼)	0.452	0.437	23.02	5.14

表 2. 在 KITTI-360 数据集上的补全性能。符号含义与表 1 相同。

模型	SemanticKITTI			KITTI360		
	CD ↓	JSD ↓	EMD ↓	CD ↓	JSD ↓	EMD ↓
ScoreLiDAR (精炼版)	0.342	0.399	23.26	0.452	0.437	23.02
无结构损失 (精炼版)	0.419	0.430	24.61	0.549	0.445	24.56

表 3. 结构损失的消融研究。

4.3. 优化过程

在训练过程中, G_{stu} 和 ϵ_ϕ 使用教师模型 ϵ_θ 初始化, 并交替优化。辅助扩散模型 ϵ_ϕ 根据学生模型完成的场景, 按等式 (5) 进行训练。至于 G_{stu} , 我们遵循所提出的方法, 从整个点云中选择 $\frac{1}{30}$ 个点作为计算点距离矩阵的关键点。然后, G_{stu} 按以下目标进行优化

$$\mathcal{L}_{stu} = \mathcal{L}_{KL} + \mathcal{L}_{structural} \quad (18)$$

我们将 $\lambda_{scene} = 0.5$ 和 $\lambda_{point} = 0.01$ 设为默认。实现细节见附录 Sec S1。

5. 实验

在这一部分, 我们进行了一系列实验以评估所提出的 ScoreLiDAR 的有效性。我们将 ScoreLiDAR 与包括 LMSC-Net [30]、LODE [16]、MID [38]、PVD [55] 和 LiDiff [28] 在内的先进模型进行比较。我们首先在场景补全任务中评估 ScoreLiDAR 的性能 (第 5.1 节)。

模型	CD ↓	JSD ↓	EMD ↓	时间 (秒) ↓
LiDiff (50 步) [28]	0.434	0.444	22.15	30.38
LiDiff (50 步 精炼) [28]	0.375	0.416	23.16	30.55
LiDiff (8 步) [28]	0.447	0.432	24.90	5.69
LiDiff (8 步 精炼) [28]	0.411	0.406	25.74	5.92
ScoreLiDAR (8 步 精炼)	0.342	0.399	23.14	5.37
ScoreLiDAR (4 步 细化)	0.326	0.386	23.98	3.23
ScoreLiDAR (2 步 细化)	0.403	0.379	-	1.85
ScoreLiDAR (1 步 细化)	0.548	0.384	-	1.10

表 4. SemanticKITTI 数据集上不同采样步数的消融研究。

其次, 我们给出消融研究结果, 展示结构损失的有效性以及在不同采样步数下 ScoreLiDAR 的性能 (第 5.2 节)。最后, 我们通过定性分析对 ScoreLiDAR 进行进一步评估 (第 5.3 节)。

5.1 场景补全

我们在 SemanticKITTI [1] 与 KITTI-360 [20] 数据集上验证了 ScoreLiDAR。现有的最先进 LiDAR 场景补全模型 LiDiff [28] 被选为教师模型。学生模型与教师模型共享网络结构, 并由教师模型初始化。此外, 我们还使用 LiDiff [28] 中的精炼网络来优化学生模型生成的补全场景。我们计算 Chamfer Distance (CD) [2]、Jensen-Shannon Divergence (JSD) [24] 和 Earth Mover's Distance (EMD) [8] 来评估补全场景与真实场景的相似度。这些指标的值越小, 补全场景越接近真实场景。

表 1 显示, 在 SemanticKITTI 数据集上, ScoreLiDAR 在大多数情况下相比现有模型取得了最佳完成效果。与需 30.55 秒完成一帧场景的 SOTA 方法 LiDiff [28] (含细化) 相比, ScoreLiDAR 仅需 5.47 秒完成一帧 (速度提升约五倍), 但在 CD 上提升了 8%、JSD 提升了 4%, EMD 则相当。细化后 EMD 上升的原因是 $\mathcal{G}^0$ 与 $\mathcal{G}$ 间点数不匹配, 导致匹配代价增高。细化过程优化了局部细节但改变了全局点云分布, 从而延长了总体迁移路径。尽管 LM-SCNet [30] 和 LODE [16] 完成速度更快, 但其完成质量明显较低。ScoreLiDAR 的表现优于教师模型 LiDiff [28], 这是因为 ScoreLiDAR 引入了包含场景级项与点级项的结构化损失, 使学生模型在训练中能有效捕捉 LiDAR 点云数据的几何结构信息。KITTI-360 的结果见表 2。




图 4. 在 KITTI-360 上的定性结果。ScoreLiDAR 在更少采样步骤下比 LiDiff [29] 实现了更好的补全。

ScoreLiDAR 在大多数情况下也达到了最优性能，并在速度上实现五倍加速，在 CD 上有 12% 提升，在 JSD 上有 2% 提升，相较于 LiDiff [28]。

5.2. 消融研究

在本部分中，我们进行消融研究以验证结构损失在所提 ScoreLiDAR 训练中的有效性。我们将所提 ScoreLiDAR 与不包含结构损失的变体在场景补全性能上进行了对比。结果见表 3。结果表明，不含结构损失的变体在两个数据集上的场景补全性能均较低。然而，在加入结构损失后，ScoreLiDAR 的性能显著提升，在所有度量上均取得更好表现。这支持我们在第 4.3 节中的讨论：引入结构损失使学生模型能够捕捉 3D 点云的几何结构特征，从而有助于学生模型的有效蒸馏。

此外，我们比较了 ScoreLiDAR 在不同采样步数下的场景补全性能，结果见表 4。可以看出，随着采样步数从 8 减少到 1，ScoreLiDAR 完成一个场景所需的时间也随之减少，单步采样可在仅 1.1 秒内完成一个场景。在 8 步和 4 步采样下，ScoreLiDAR 的表现优于 LiDiff。

所有指标在 2 步和 1 步采样时都有所下降，但在 JSD 上我们的结果仍优于 LiDiff。总之，尽管随着采样步数减少场景补全质量下降，但其性能仍与现有模型相当或更优，如图 2 所示在性能与速度上取得了更好的权衡。

此外，我们比较了关于结构损失项、不同关键点选择方法、不同关键点数量以及不同 λ_{scene} 和 λ_{point} 值等的消融结果，详见附录 Sec. S4。

5.3. 定性分析

图 4 显示了在 KITTI-360 上我们提出的 ScoreLiDAR 与 LiDiff [28] 的完成场景。与 LiDiff 相比，ScoreLiDAR 在更短时间内取得了质量更高、保真度更好的补全结果。例如，如图 4(c) 所示，在左侧区域应当如图 4(b) 所示有两辆车，而 LiDiff 补全的场景只包含一辆。相比之下，ScoreLiDAR 在仅 8 步的情况下（图 4(d)）补全了两辆车，并且车辆结构更清晰、更完整，更接近真实情况。

为进一步证明 ScoreLiDAR 及结构损失的有效性，我们计算了补全场景中的点与其在真实值中对应点之间的距离，以评估整体差异。




图5. 结构损失的定性分析。条形图显示了已补全场景与真值场景中对应点之间距离的分布。更多小距离的点表明已补全场景更接近真值。热图表示已补全场景与真值场景之间距离矩阵的差异。热图上更小的值表示已补全场景更接近真值。

我们在图5的柱状图中展示了计算结果。ScoreLiDAR 在与真值对应点的距离更小的点数量上最高。结果表明，ScoreLiDAR 完成的场景总体上更接近真值，表现出更高的保真度。此外，我们按第4.2节所述方法从真值与用该方法完成的场景中各选取了36个对应关键点，并计算了点距离矩阵 $\mathcal{D}$ 与 $\mathcal{D}_G$ 。然后我们将 $\mathcal{D}$ 与 $\mathcal{D}_G$ 的差异以热图形式可视化。如图5所示，在两个数据集上，LiDiff [28] 所完成场景与真值之间的点距离矩阵差异最大，其次是去掉结构损失的 ScoreLiDAR 变体，而差异最小的是 ScoreLiDAR。这也表明 ScoreLiDAR 完成的场景更接近真值。

我们还进行了一项用户研究来评估 ScoreLiDAR 的性能。我们使用 ScoreLiDAR 与 LiDiff [28] 在相同的输入扫描上完成场景，并请用户选择他们认为更接近真实场景的结果。ScoreLiDAR 获得了比 LiDiff [28] 高 65% 的用户偏好。这表明对于大多数用户而言，ScoreLiDAR 完成的场景在细节和逼真度上更接近真实场景。

用户研究的详细内容见补充材料。

6. 结论

总结。本文提出了 ScoreLiDAR，一种针对 3D LiDAR 场景补全扩散模型的新型蒸馏方法，基于双向梯度引导机制。通过引入包含场景级项和点级项的结构化损失，ScoreLiDAR 训练学生模型有效捕捉整体结构与关键点的相对配置，并实现高效且高质量的场景补全。

限制。尽管 ScoreLiDAR 实现了高效且高质量的 LiDAR 场景补全，但其性能受限于教师模型。随着教师模型性能的提升，学生模型的能力也会提升。虽然我们在补充材料中对语义场景补全进行了初步实验，但仍需更全面的探索。因此，需要进一步研究更有效的方法来改进 ScoreLiDAR 的训练过程，避免教师模型的局限性，从而实现更高效的语义 LiDAR 场景补全。

致谢

本文得到浙江省重点研发计划（编号2024C01250(SD2)）、国家自然科学基金（编号62006208）及“筑梦启航·鲲鹏与飞升种子计划”的资助。

参考文献

- [1] Jens Behley, Martin Garbade, Andres Milioto, Jan Quenzel, Sven Behnke, Cyrill Stachniss, and Jurgen Gall. SemanticKITTI: A Dataset For Semantic Scene Understanding Of Lidar Sequences. In ICCV, pages 9297-9307, 2019. 1, 2, 6, 11
- [2] M Akmal Butt and Petros Maragos. Optimum Design of Chamfer Distance Transforms. TIP, 7(10):1477-1484, 1998. 6, 11
- [3] Helin Cao and Sven Behnke. DiffSSC: Semantic LiDAR Scan Completion Using Denoising Diffusion Probabilistic Models. arXiv preprint arXiv:2409.18092, 2024. 2, 3
- [4] Nathaniel Chodosh, Chaoyang Wang, and Simon Lucey. 深度卷积压缩感知用于激光雷达深度补全。发表于 ACCV, 页码 499-513, 2019. 2
- [5] Christopher Choy, JunYoung Gwak, and Silvio Savarese. 四维时空卷积网络: Minkowski 卷积神经网络。发表于 CCPR, 页码 3075-3084, 2019. 17
- [6] Angela Dai, Daniel Ritchie, Martin Bokeloh, Scott Reed, Jürgen Sturm, and Matthias Nießner. ScanComplete: 用于三维扫描的大规模场景补全与语义分割。发表于 CVPR, 页码 4578-4587, 2018. 2
- [7] Abdelrahman Eldesokey, Michael Felsberg, and Fahad Shahbaz Khan. 通过 CNN 的置信度传播用于引导稀疏深度回归。PAMI, 42(10):2423-2436, 2019. 2
- [8] Haoqiang Fan, Hao Su 和 Leonidas J Guibas. 《用于从单张图像进行三维物体重建的点集生成网络》。载 CVPR, 页 605-613, 2017. 6
- [9] Chen Fu, Christoph Mertz 和 John M Dolan. 《激光雷达与单目相机融合: 用于自动驾驶的道路深度补全》。载 ITCS, 页 273-278, 2019. 2
- [10] Jonathan Ho, Ajay Jain 和 Pieter Abbeel. 《去噪扩散概率模型》。NIPS, 33:6840-6851, 2020. 3, 4, 12, 13
- [11] Edward J Hu, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, Weizhu Chen 等. 《LoRA: 大规模语言模型的低秩适配》。载 ICLR, 2021. 17
- [12] Jaehoon Jung, Michael J Olsen, David S Hurwitz, Alireza GKashani, and Kamilah Buker. 使用 LiDAR 数据的三维交叉视距分析。Transportation research part C: emerging technologies, 86:563-579, 2018. 13
- [13] Dongjun Kim, Chieh-Hsin Lai, Wei-Hsiang Liao, Naoki Murata, Yuhta Takida, Toshimitsu Uesaka, Yutong He, Yuki Mitsufuji, and Stefano Ermon. 一致性轨迹模型: 学习扩散的概率流 ODE 轨迹。In ICLR, 2024. 2
- [14] Jumin Lee, Woobin Im, Sebin Lee, and Sung-Eui Yoon. 面向场景尺度三维类别数据的扩散概率模型。arXiv preprint arXiv:2301.00527, 2023. 3, 13
- [15] Jumin Lee, Sebin Lee, Changho Jo, Woobin Im, JuhyeonSeon, and Sung-Eui Yoon. Semcity: Semantic Scene Generation With Triplane Diffusion. In CVPR, pages 28337-28347, 2024. 15
- [16] Pengfei Li, Ruowen Zhao, Yongliang Shi, Hao Zhao, JiruiYuan, Guyue Zhou, and Ya-Qin Zhang. Lode: Locally Conditioned Eikonal Implicit Scene Completion From Sparse Li-dar. In ICRA, pages 8269-8276, 2023. 2, 6, 13, 15
- [17] You Li, Julien Moreau, and Javier Ibanez-Guzman. Emergent Visual Sensors For Autonomous Vehicles. IEEE Transactions on Intelligent Transportation Systems, 24(5):4716-4737, 2023. 1, 13
- [18] 李翌鸣, 余志定, Christopher Choy, 肖朝伟, Jose M Alvarez, Sanja Fidler, 冯晨, 和 Anima Anand-kumar. Voxformer: 基于相机的稀疏体素变换器用于三维语义场景补全。载于 CVPR, 页码 9087-9098, 2023. 1, 13
- [19] 梁逸迅, 杨欣, 林建涛, 李浩东, 许晓刚, 和 陈颖聪. Luciddreamer: 通过区间分数匹配迈向高保真文本到三维生成。载于 CVPR, 页码 6517-6526, 2024. 2
- [20] 廖怡怡, 解俊, 和 Andreas Geiger. Kitti-360: 一个用于二维和三维城市场景理解的新数据集与基准。PAMI, 45(3):3292-3310, 2022. 1, 6, 11
- [21] 程璐, 周宇浩, 包凡, 陈建飞, 李崇轩, 朱俊. Dpm-solver: 一种用于扩散概率模型采样的快速常微分方程求解器, 约 10 步完成。NIPS, 35:5775-5787, 2022. 3
- [22] 罗伟坚, 胡天阳, 张世峰, 孙佳成, 李征国, 张志华. Diff-Instruct: 一种将知识从预训练扩散模型通用迁移的方法。NIPS, 36:76525-76546, 2023. 2, 5, 12
- [23] 马志远, 魏雨翔, 张亚彬, 朱祥宇, 雷震, 张磊. Scaledreamer: 可扩展的文本到 3D 合成, 采用异步分数蒸馏。In ECCV, pages 1-19, 2024. 2
- [24] María Luisa Menéndez, JA Pardo, L Pardo, and MC Pardo. The Jensen-Shannon Divergence. Journal of the Franklin Institute, 334(2):307-318, 1997. 6, 11
- [25] Amir Meydani. 在极端条件下用于自动驾驶车辆的传感器性能的最新分析。载于《国际人工智能与智能车辆会议论文集》, 第137-166页, 2023年. 2
- [26] Ben Mildenhall, Pratul P Srinivasan, Matthew Tancik, Jonathan T Barron, Ravi Ramamoorthi, and Ren Ng. Nerf: 将场景表示为用于视图合成的神经辐射场。Communications of the ACM, 65(1):99-106, 2021. 16
- [27] Kazuto Nakashima and Ryo Kurazume. 使用去噪扩散概率模型的激光雷达数据合成。载于ICRA, 第14724-14731页, 2024年. 2, 3
- [28] Lucas Nunes, Rodrigo Marcuzzi, Benedikt Mersch, Jens Behley 和 Cyrill Stachniss. 将扩散模型扩展到真实世界的 3D LiDAR 场景补全。发表于 CVPR, 页码14770-14780, 2024. 1, 2, 3, 6, 7, 8, 11, 12, 13, 14, 15

- [29] Haoxi Ran, Vitor Guizilini 与 Yue Wang. 使用 LiDAR 扩散模型迈向真实场景生成. 发表于 CVPR, 页码 14738-14748, 2024. 3、7、13
- [30] Luis Roldao, Raoul de Charette 与 Anne Verroust-Blondet. Lmscnet: 轻量级多尺度 3D 语义补全. 收录于国际 3D 视觉会议论文集, 页码 111-119, 2020. 6、15
- [31] Luis Roldao, Raoul De Charette 与 Anne Verroust-Blondet. 3D 语义场景补全: 综述. 发表于国际计算机视觉期刊, 130(8): 1978-2005, 2022. 2
- [32] Kwonyoung Ryu, Kang-il Lee, Jegyeong Cho 与 Kuk-Jin Yoon. 基于单张图像与稀疏 LiDAR 点云的扫描线分辨率不变深度补全. IRAL, 6(4): 6961-6968, 2021. 2
- [33] Tim Salimans and Jonathan Ho. 用于快速采样扩散模型的渐进蒸馏. 发表于 ICLR, 2021. 2
- [34] Jiaming Song, Chenlin Meng, and Stefano Ermon. 去噪扩散隐式模型. arXiv 预印本 arXiv:2010.02502, 2020. 3, 12
- [35] Shuran Song, Fisher Yu, Andy Zeng, Angel X Chang, Manolis Savva, and Thomas Funkhouser. 从单幅深度图的语义场景补全. 发表于 CVPR, 页码 1746-1754, 2017. 15
- [36] Yang Song, Jascha Sohl-Dickstein, Diederik P Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. 通过随机微分方程的基于分数的生成建模. 发表于 ICLR, 2021. 16
- [37] Yang Song, Prafulla Dhariwal, Mark Chen, and Ilya Sutskever. 一致性模型. 发表于 ICML, 页码 32211-32252, 2023. 2, 12
- [38] Ignacio Vizzo, Benedikt Mersch, Rodrigo Marcuzzi, Louis Wiesmann, Jens Behley, and Cyrill Stachniss. Make ItDense: 自监督几何补全大尺度户外环境中稀疏 3D 激光雷达扫描. IRAL, 7(3):8534-8541, 2022. 2, 6, 13, 15
- [39] Fengyun Wang, Dong Zhang, Hanwang Zhang, Jinhui Tang, and Qianru Sun. Semantic Scene Completion With CleanerSelf. 见 CVPR, 页 867-877, 2023. 2
- [40] Fu-Yun Wang, Ling Yang, Zhaoyang Huang, Mengdi Wang, and Hongsheng Li. Rectified diffusion: Straightness is not your need in rectified flow. arXiv preprint arXiv:2410.07303, 2024. 2
- [41] Peihao Wang, Dejia Xu, Zhiwen Fan, Dilin Wang, Sreyas Mohan, Forrest Iandola, Rakesh Ranjan, Yilei Li, Qiang Liu, Zhangyang Wang, et al. 在分数蒸馏中驯服模式崩溃以实现文本到 3D 生成. 载于 CVPR, 第 9037-9047 页, 2024. 2
- [42] Zhengyi Wang, Cheng Lu, Yikai Wang, Fan Bao, Chongxuan Li, Hang Su, 和 Jun Zhu. ProlificDreamer: 通过变分分数蒸馏实现高保真且多样的文本到 3D 生成. NIPS, 36:8406-8441, 2023. 2, 4, 16, 17
- [43] Cho-Ying Wu 和 Ulrich Neumann. 面向驾驶场景的场景完整性感知激光雷达深度补全. 载于 ICASSP, 第 2490-2494 页, 2021. 2
- [44] 夏照阳, 刘有全, 李鑫, 朱兴戈, 马岳新, 李一康, 侯越南, 和 乔宇. Scpnet: 点云语义场景完成. 载于 CVPR, 页码 17642-17651, 2023. 2
- [45] 熊宇文, Wei-Chiu Ma, 王经康, 和 Raquel Urtasun. 学习用于激光雷达补全与生成的紧凑表示. 载于 CVPR, 页码 1074-1083, 2023. 11
- [46] 熊宇文, Wei-Chiu Ma, 王经康, 和 Raquel Urtasun. 学习用于激光雷达补全与生成的紧凑表示. 载于 CVPR, 页码 1074-1083, 2023. 2
- [47] 徐岩, 朱兴戈, 石建平, 张国锋, 鲍虎军, 和 李宏生. 带有深度-法线约束的稀疏激光雷达数据深度补全. 载于 ICCV, 页码 2811-2820, 2019. 2
- [48] 薛宇杰, 李瑞辉, 吴帆, 唐卓, 李肯立, 与段明兴. Bi-SSC: 基于相机的三维语义场景补全的几何-语义双向融合. 载于 CVPR, 页码 20124-20134, 2024. 2
- [49] 杨凌, 张子翔, 张智龙, 刘兴潮, 徐铭凯, 张文涛, 孟晨林, Stefano Ermon, 与崔斌. 一致性流匹配: 通过速度一致性定义直线流. arXiv 预印本 arXiv:2407.02398, 2024. 2
- [50] 杨燕超, Alex Wong, 与 Stefano Soatto. 单幅图像与稀疏测距的密集深度后验 (DDP). 载于 CVPR, 页码 3353-3362, 2019. 2
- [51] 尹天威, Michaël Gharbi, Taesung Park, Richard Zhang, Eli Shechtman, Fredo Durand, 和 Bill Freeman. 改进的分布匹配蒸馏用于快速图像合成. NIPS, 37:47455-47487, 2024. 12
- [52] 尹天威, Michaël Gharbi, Richard Zhang, Eli Shechtman, Fredo Durand, William T Freeman, 和 Taesung Park. 一步扩散与分布匹配蒸馏. In CVPR, pages 6613-6623, 2024. 4, 5, 12
- [53] 余庆阳, 朱磊, 吴琦, 和 裴玲. 灰度与法线引导的低成本 LiDAR 深度补全. In ICIP, pages 979-983, 2021. 2
- [54] 张胜远, 杨凌, 李泽健, 赵安, 孟晨烨, 杨长远, 杨光, 杨志远, 孙令云. 分布回溯为一步扩散蒸馏构建更快的收敛轨迹. 载于 ICLR, 2025. 2, 5, 12
- [55] 周林奇, 杜怡伦, 吴佳俊. 通过点-体素扩散进行三维形状生成与补全. 载于 ICCV, 页码 5826-5835, 2021. 6, 15

A. 实验协议

A.1. 数据集设置

SemanticKITTI [1] 数据集是用于自动驾驶中三维语义分割的大规模基准，将 KITTI 里程计数据集扩展为对超过 43,000 个激光雷达扫描进行密集语义标注。它为 25 类提供标签，如“car”、“road”和“building”，涵盖多样的城市与乡村场景。

SemanticKITTI 数据集由 22 个序列组成，其中序列 00-10 对每次扫描进行了密集标注，可用于基于序列扫描的语义分割和语义场景补全等任务。序列 11-21 用作测试集，展示了多样且具有挑战性的交通情形和环境类型，以评估模型在真实世界自动驾驶场景中的性能。SemanticKITTI 在研究中被广泛使用，是推动基于激光雷达感知系统发展的关键资源。

KITTI-360 [20] 数据集是用于自动驾驶三维场景理解的综合基准，采集了多样城市环境中的 360 度全景影像和三维点云。它包含超过 73 km 的驾驶数据，并对 2D（图像）和 3D（点云）进行了密集语义标注，涵盖“车辆”、“建筑”和“植被”等类别。KITTI-360 提供高分辨率传感器数据，包括 LiDAR、GPS/IMU 和立体相机记录，适合用于三维语义分割、全景分割和真实驾驶场景的建图等任务。

A.2. 评估指标

Chamfer 距离 (CD) [2] 是用于衡量两组点相似性的指标，常用于评估生成点云或几何形状的质量。对于两点集 P 和 Q ，Chamfer 距离定义为：

$$CD(P, Q) = \frac{1}{|P|} \sum_{p \in P} \min_{q \in Q} \|p - q\|^2 + \frac{1}{|Q|} \sum_{q \in Q} \min_{p \in P} \|q - p\|^2 \quad (19)$$

第一项计算 P 中每个点到 Q 中最近邻点的平均平方距离。第二项计算 Q 中每个点到 P 中最近邻点的平均平方距离。Chamfer Distance 通过在两个方向上考虑最近邻距离来评估两点集相互逼近的程度。CD 有效捕捉局部几何特征，并在局部形状匹配上表现出较强的鲁棒性，常用于评估 3D 点云的匹配和重建。

Jensen-Shannon Divergence (JSD) [24] 是一种对称的两个概率分布相似性度量。

它是 Kullback-Leibler (KL) 散度的一种变体，广泛用于信息论、统计学和机器学习。给定在相同域上的两个概率分布 P 和 Q ，JSD 定义为：

$$JSD(P \parallel Q) = \frac{1}{2} KL(P \parallel M) + \frac{1}{2} KL(Q \parallel M) \quad (20)$$

这里 $M = \frac{1}{2}(P + Q)$ 是平均分布，

$KL(P \parallel M)$ 是 Kullback-Leibler 散度。

JSD 衡量 P 与 Q 相对于它们的平均分布 M 的偏离程度。它是对称的 ($JSD(P \parallel Q) = JSD(Q \parallel P)$)，并且在使用以 2 为底的对数时始终在区间 $[0, 1]$ 内给出有限值。与 KL 散度不同，JSD 避免了在某一分布的概率为零时出现未定义值的问题。JSD 是评估两个分布相似性的高效度量。本文中 JSD 的计算遵循 Xiong 等人 [45]。

A.3. 实现细节

我们选择预训练的 LiDiff [28] 模型作为教师模型 ϵ_θ ，学生模型 G_{stu} 与辅助扩散模型 ϵ_ϕ 与教师模型共享相同的网络结构，并由教师模型初始化。ScoreLiDAR 在 SemanticKITTI 数据集上训练。预训练的扩散模型由 LiDiff [28] 官方发布提供。为公平比较，我们遵循 LiDiff [28] 的训练策略。ScoreLiDAR 在 SemanticKITTI 的序列 00-07 和 09-10 上训练（不在 KITTI-360 上训练），并在 SemanticKITTI 的序列 08 和 KITTI-360 的序列 00 上评估。

为了优化，我们使用具有默认参数的随机梯度下降 (SGD) 优化器。学习率设置为 $3e-5$ ，批量大小设置为 1。学生模型与辅助扩散模型之间的训练比保持为 1:1。为降低计算开销，在计算点级损失时，我们先从真实场景中随机选择 $\frac{1}{10}$ 的点。然后，按照所提出的方法，从这些点中选取曲率最高的前 $\frac{1}{3}$ 个点作为计算距离矩阵的关键点。也就是说，关键点最终数量是真实场景总点数的 $\frac{1}{30}$ 。在计算 K -近邻时，我们将 $K = 180$ 设置为。场景级损失的权重 λ_{scene} 和点级损失的权重 λ_{point} 分别设置为 0.5 和 0.01。ScoreLiDAR 仅需 50 次迭代即可收敛，在单块 A40 GPU 上大约耗时 10 分钟，效率很高。我们的模型和代码已公开发布于

<https://github.com/happyw1nd/ScoreLiDAR>。

B. 讨论

B.1. 蒸馏在提高采样效率方面的有效性

本部分对所提出蒸馏方法的效率进行详细讨论。

为什么用 teacher 模型来初始化 student 模型和辅助扩散模型是合理的？首先，这种初始化方法在现有方法中常被采用 [22, 37, 51, 52, 54]。其次，预训练的 teacher 模型 ϵ_θ 包含关于训练分布的信息，用 teacher 模型初始化 student 模型并进行蒸馏，本质上是对 teacher 模型的微调，这能加速蒸馏的效率。第三，尽管 student 模型在参数和网络结构上与 teacher 模型相同，但由于采样步数不同，其采样分布与 teacher 模型不同。此处的 teacher 模型 ϵ_θ （在本例中为 LiDiff [28]）采用多步采样。

$$G^{t-1} = \frac{1}{\sqrt{\alpha^t}} \left(G^t - \frac{1 - \alpha^t}{\sqrt{1 - \alpha^t}} \epsilon_\theta(G^t, \mathcal{P}, t) \right) + \sigma^t z \quad (21)$$

教师模型 ϵ_θ （来自 LiDiff [28]）通过重复式 (21) 进行 50 步采样。学生模型 G_{stu} 执行单步采样。当 G_{stu} 预测噪声后，按式 (22) 进行一次去噪，以直接得到完成的场景 G^0 。

$$G^0 = \frac{1}{\sqrt{\alpha^t}} \left(G^t - \frac{1 - \alpha^t}{\sqrt{1 - \alpha^t}} \epsilon_\theta(G^t, \mathcal{P}, t) \right) \quad (22)$$

因此，学生模型的单步采样场景与教师模型的多步采样场景不同。

蒸馏损失为何有效？学生模型为何会被优化？首先，我们的蒸馏损失不同于诸如 DDPM [10] 的扩散模型的标准损失。DDPM 的损失是直接预测加到训练样本上的噪声。与之不同，在所提出的 ScoreLiDAR 中，蒸馏损失利用学生模型 G_{stu} 预测的噪声进行一步采样，得到一个与教师模型的多步采样不同的完整场景 G^0 。然后对该完整场景 G^0 在随机时刻扰动噪声 t 以得到有噪声的场景 G^t ，并根据 G^t 计算两个得分函数之间的差异，作为优化学生模型的梯度，如式 (23) 所示。

$$\mathcal{L}_{KL} \approx \mathbb{E}_{t, \epsilon} [\| \epsilon_\theta(G^t, \mathcal{P}, t) - \epsilon_\phi(G^t, \mathcal{P}, t) \|_2^2] \quad (23)$$

其次，尽管辅助扩散模型 ϵ_ϕ 是从教师模型 ϵ_θ 初始化的，式 (23) 中的梯度仍然非零且有效。回想辅助扩散模型 ϵ_ϕ 与学生模型 G_{stu} 是交替训练的。辅助扩散模型 ϵ_ϕ 首先在 G^0 上训练以拟合一步采样分布，该分布不同于教师模型的预训练分布。虽然辅助扩散模型 ϵ_ϕ 也从教师模型初始化，但其参数在一次优化后会更新并与教师模型不同。然后，当使用式 (23) 的梯度优化 G_{stu} 时，由于对 ϵ_ϕ 的优化， $\epsilon_\theta(G^t, \mathcal{P}, t)$ 的输出自然会不同于 $\epsilon_\phi(G^t, \mathcal{P}, t)$ 的输出。因此，正如主文第 4.1 节所述，式 (23) 中的非零梯度会将 G_{stu} 的分布朝向教师模型的预训练分布优化。随后， ϵ_ϕ 与 G_{stu} 交替优化直至收敛。

为什么训练阶段使用一步采样而推理阶段使用少步采样？首先，在传统扩散模型如 DDPM [10] 和 DDIM [34] 中，训练时直接预测扩散过程中加入的全部噪声，而采样时则执行多步采样。同时，不同的采样方法允许使用不同步数的采样。直观上，这表明尽管训练目标不变，采样可以用不同步数来完成。更深层的解释来自于将扩散模型视作求解随机微分方程。此外，Consistency Model [37] 也有类似设置；其学生模型在训练时进行一步生成，但在采样时进行多步生成。我们采用了与 Consistency Model 类似的原理。训练中的一步采样旨在提高在不同噪声样本条件下生成结果的保真度，而推理中的多步采样则会逐步细化最终结果。因此，尽管学生模型在训练时进行一步采样，通过在推理时增加采样步数仍可提升场景补全的质量。更直观地，Consistency Model 的一步生成过程是“噪声 $\rightarrow$ 图像”，而多步生成过程是“噪声 $\rightarrow$ 噪声图像 $\rightarrow \dots \rightarrow$ 图像”。在本文中，学生模型训练时的一步采样 G_{stu} 为“噪声 $\rightarrow$ 预测噪声 $\rightarrow$ 完成场景”，而推理时的少步采样为“噪声 $\rightarrow$ 预测噪声 $\rightarrow$ 噪声场景 $\rightarrow$ 预测噪声 $\rightarrow$ 噪声场景 $\rightarrow$ 预测噪声 $\rightarrow \dots \rightarrow$ 完成场景”。总之，训练阶段使用一步采样而推理阶段使用多步采样是合理的。

B.2. 场景级损失与 Chamfer 距离的差异

场景级损失形式如下

$$\mathcal{L}_{scene} = \frac{1}{|\mathcal{G}^0|} \sum_{p_i^0 \in \mathcal{G}^0} \min_{p \in \mathcal{G}} \|p_i^0 - p\|^2 \quad (24)$$

场景级损失是 Chamfer 距离的一部分。之所以只使用 Chamfer 距离的部分项，是因为场景级损失的优化目标是确保生成场景中的点 $\mathcal{G}^0$ 尽可能接近对应的真实点。Chamfer 距离中未使用的那一项是将每个真实点与生成场景中其最近的点匹配，这可能导致 $\mathcal{G}^0$ 中的点被推向真实中不存在的匹配点的平均位置。这一效应对场景补全有害。

B.3. 关于本研究意义的讨论

首先，我们讨论这项研究的意义。对于自动驾驶车辆而言，在运行过程中准确识别和感知其周围环境至关重要 [17, 18]。这对于识别可能影响车辆行驶的物体尤为重要，例如其他车辆、行人、交通锥和路标 [12]。准确高效地识别这些物体对于自动驾驶车辆的安全运行至关重要。然而，车载激光雷达获取的扫描数据是稀疏的 [16, 38]，并且很难从稀疏扫描的放大区域中识别出车辆等关键物体。自动驾驶车辆无法从这些稀疏的激光雷达扫描中获得足够的驾驶环境信息 [14, 29]。因此，有必要使用适当的方法来完善稀疏的激光雷达扫描。

LiDiff [28] 使用 DDPM [10] 模型来完成 3D 激光雷达场景，取得了令人印象深刻的结果。然而，由于扩散模型的固有特性，LiDiff [28] 需要大约 30 秒才能完成单个场景，限制了其在自动驾驶车辆中的适用性。相比之下，所提出的 ScoreLiDAR 能在几乎 5 秒内完成一个场景，比 LiDiff [28] 快超过 5 倍，同时实现更高的补全质量。因此，借助所提出的 ScoreLiDAR 完成的场景，自动驾驶车辆可以更容易识别驾驶环境中的关键物体，从而实现更安全、更有效的导航。

C. 额外的补全场景

图 7 和图 8 展示了所提出的 ScoreLiDAR 额外补全的场景，并将其与 LiDiff [28] 补全的场景进行了比较。

模型	SemanticKITTI			KITTI360		
	CD↓	JSD↓	EMD↓	CD↓	JSD↓	EMD↓
ScoreLiDAR	0.342	0.399	23.26	0.452	0.437	23.02
去除逐点损失	0.351	0.414	23.37	0.485	0.486	23.29
去除场景级损失	0.367	0.422	24.89	0.477	0.451	24.69
去除结构损失	0.419	0.430	24.13	0.549	0.445	24.56

表5. 场景级与逐点损失的消融研究。度量为经精炼后的性能。颜色分别表示第1、第2和第3名的模型。

ScoreLiDAR	SemanticKITTI			KITTI360		
	CD↓	JSD↓	EMD↓	CD↓	JSD↓	EMD↓
$\lambda_{scene} = 0.5, \lambda_{point} = 0.01$	0.342	0.399	23.26	0.452	0.437	23.02
$\lambda_{scene} = 0.05, \lambda_{point} = 0.01$	0.354	0.409	23.40	0.494	0.457	23.21
$\lambda_{scene} = 0.5, \lambda_{point} = 0.1$	0.358	0.419	23.27	0.539	0.474	23.09

表 6. 不同场景级与点级损失权重的消融研究。首行为 ScoreLiDAR 的默认配置。指标为经细化后的性能。

模型	SemanticKITTI		KITTI360	
	CD↓	JSD↓	CD↓	JSD↓
LiDiff (精炼版)	0.375	0.416	0.517	0.446
含结构损失	0.399	0.426	0.535	0.450

表 7. 在含结构损失下对 LiDiff [28] 的训练消融研究。

附录 D. 额外实验结果

D.1. 结构损失的更多消融研究

为了进一步验证结构损失的有效性，我们评估了仅用点级损失或场景级损失训练的变体的性能，并与默认的 ScoreLiDAR 进行比较。如表 5 所示，与默认 ScoreLiDAR 相比，仅用场景级损失或点级损失训练的变体性能都有所下降。然而，与没有结构损失的变体相比，仅使用单一类型损失的变体仍然表现出改进的补全性能。这些结果证明了结构损失在蒸馏过程中的有效性。

此外，我们还研究了场景级损失和点级损失不同权重对补全质量的影响。结果如表 6 所示。可以观察到，减小 λ_{scene} 或增大 λ_{point} 会导致 ScoreLiDAR 性能下降，但仍能达到相当的表现。这验证了所提结构损失在提升学生模型补全性能方面的有效性。

最后，我们使用结构损失训练 LiDiff 以探究结构损失是否能提升 LiDiff 的性能。结果如表 7 所示。用结构损失训练 LiDiff [28] 并未带来性能提升。

ScoreLiDAR	SemanticKITTI			KITTI360		
	CD↓	JSD↓	EMD↓	CD↓	JSD↓	EMD↓
$n = 1/20$	0.329	0.392	24.35	0.528	0.475	24.01
$n = 1/30$	0.342	0.399	23.26	0.452	0.437	23.02
$n = 1/60$	0.346	0.409	25.19	0.452	0.471	25.05
$n = 1/70$	0.428	0.454	25.60	0.466	0.479	25.44

表 8. 不同关键点数量的消融研究。 $n = 1/30$ 的结果指 ScoreLi-DAR 的默认配置。度量指标指的是带有细化后的性能。

模型	CD↓	JSD↓	EMD↓
随机选择	0.384	0.433	23.23
最远选择	0.442	0.459	23.63
ScoreLiDAR	0.342	0.399	23.26

表9. 在 SemanticKITTI 数据集上不同选择方法的比较。所提出的选择方法的性能优于其他方法。

这可能是由于结构损失不适合直接加入到 LiDiff [28] 的训练损失中，即传统扩散模型的训练损失。

D.2. 不同关键点数量的消融实验

如附录 A.3 所述，关键点的最佳数量设置为地面真实点总数的 $\frac{1}{30}$ 。为研究不同关键点数量对 ScoreLiDAR 完成性能的影响，我们在模型训练中减少了关键点数量并评估了完成性能。如表 8 所示，ScoreLiDAR 的最终性能与关键点数量呈正相关。关键点数量减少时，ScoreLiDAR 的性能下降。这是因为关键点数量不足导致逐点损失无法有效捕捉关键点之间的相对位置信息，使学生模型无法学习局部几何结构，从而降低了完成质量。然而，当关键点数量过多时，容易引发内存不足问题并降低训练效率。因此，本文设置为 $n = \frac{1}{30}$ 。

D.3. 不同关键点选择方法的消融实验

我们比较了不同的关键点选择方法，包括随机选择和最远点选择，以及基于曲率的所提选择方法。表 9 的结果表明，基于曲率的所提选择方法比其他选择方法具有更优的性能。

模型	CD↓	JSD↓	EMD↓	时间 (s)↓
LiDiff (50 步) [28]	0.564	0.549	21.98	29.18
LiDiff (50 步 精炼) [28]	0.517	0.446	22.96	29.43
LiDiff (8 步) [28]	0.619	0.471	24.85	5.46
LiDiff (8 步 精炼) [28]	0.550	0.462	25.49	5.77
ScoreLiDAR (8 步)	0.452	0.437	23.02	5.14
ScoreLiDAR (4 步)	0.482	0.461	23.76	3.16
ScoreLiDAR (2 步)	0.525	0.457	-	1.69
ScoreLiDAR (1 步)	0.750	0.478	-	1.03

表 10. 在 KITTI-360 数据集上不同采样步数的消融研究。ScoreLiDAR 的指标指带有细化的性能。

模型	用户偏好↑
LiDiff [28]	35%
ScoreLiDAR	65%

表11. 用户研究结果。我们的 ScoreLiDAR 优于现有的 SOTA 模型。

D.4. 在 KITTI-360 上不同采样步数的消融研究

我们还在 KITTI-360 数据集上进行了不同采样步数的消融研究。结果列于表10。与 SemanticKITTI 数据集上的结果类似，随着采样步数减少，ScoreLiDAR 完成一帧场景所需的时间减少。尽管完成性能略有下降，但仍与现有 SOTA 模型相当。

D.5. 用户研究

进行用户研究以进一步验证 ScoreLiDAR 的完成性能。我们首先使用 ScoreLiDAR 与当前 SOTA 方法 LiDiff [28] 对同一 30 个输入 LiDAR 扫描进行补全，得到 30 对补全后的场景。随后随机招募七名志愿者，引导每位对这 30 对场景图像的细节与逼真度进行评估，选择他们认为更接近真实的那一幅。七名志愿者中包含五名男性和两名女性，年龄 24-30 岁；五名参与者具有与自动驾驶或 LiDAR 场景补全相关的研究背景，剩余两名参与者具有与人工智能相关的背景。评估时间不限，但所有志愿者的平均完成时间为 30 分钟。

用户研究结果如表11所示。与LiDiff相比，ScoreLiDAR获得了65%的用户偏好，超过多数阈值。这表明在大多数用户看来，ScoreLiDAR完成的场景在细节和逼真度上更接近真实场景。用户研究结果进一步证明了ScoreLiDAR在LiDAR场景补全方面的有效性。

模型	SemanticKITTI (IoU) % ↑		
	0.5m	0.2m	0.1m
LMSCNet [30]	32.23	23.05	3.48
LODE [16]	43.56	47.88	6.06
MID [38]	45.02	41.01	16.98
PVD [55]	21.20	7.96	1.44
LiDiff [28]	42.49	33.12	11.02
LiDiff (精炼) [28]	40.71	38.92	24.75
ScoreLiDAR	38.43	25.75	8.34
ScoreLiDAR (精炼)	37.33	29.57	15.63

表 12. 在 SemanticKITTI 数据集上的 IoU 评估结果。

模型	KITTI-360 (IoU) % ↑		
	0.5m	0.2m	0.1m
LMSCNet [30]	25.46	16.35	2.99
LODE [16]	42.08	42.63	5.85
MID [38]	44.11	36.38	15.84
LiDiff [28]	42.22	32.25	10.80
LiDiff (精炼) [28]	40.82	36.08	21.34
ScoreLiDAR	36.82	25.49	9.70
ScoreLiDAR (精炼)	33.29	28.60	15.95

表13. KITTI-360 数据集上的 IoU 评估结果。

D.6. 关键点可视化

为了验证所提关键点选择方法的可行性，我们在真实场景中可视化了所选关键点。如图6所示，红色关键点主要分布在墙面、路锥、车辆和转角处，而路面等平滑区域没有关键点。这些关键点对表达3D LiDAR场景的细节至关重要。选择这些点来计算逐点损失可以使学生模型更容易捕捉关键点之间的相对位置信息，从而更好地补全场景中的关键物体。

D.7. 语义场景补全实验

本文旨在提出一种用于加速蒸馏的基础方法，适用于各种 Li-DAR 场景补全扩散模型。语义场景补全不在本文所述基础实验的范围内。尽管如此，为验证所提方法的泛化性，我们仍使用 SemCity [15] 作为教师模型，以检验 ScoreLiDAR 在语义场景补全任务上的有效性。

模型	FID ↓	KID ↓
SemCity [15]	88.52	0.11
ScoreLiDAR	81.76	0.09

表 14. 语义场景补全结果。我们的 ScoreLiDAR 显示出更好的性能。

由于 SemCity 的预训练模型和度量计算代码未公开，我们基于官方实现重新训练了 SemCity 并自行重现了度量计算。表 14 显示了结果。在语义场景补全任务中，所提出的 ScoreLiDAR 仍然表现出比教师模型更好的补全质量。

D.8. 场景占据实验

我们计算交并比 (IoU) [35] 来评估完成场景相对于真实场景的占据情况。IoU 表示完成场景中的体素与真实场景中体素的重叠程度。更高的 IoU 值表示完成场景更完整。评估中我们考虑了三种不同的体素分辨率：0.5 m, 0.2 m 和 0.1 m。体素分辨率越小，评估指标考虑的细节越精细，反之亦然。然而，IoU 是一种基于体素的度量，在某些基于体素的 LiDAR 场景完成方法中，它可以作为衡量完成质量的准确指标。相比之下，ScoreLiDAR 是一种基于点云的完成方法，与传统的基于体素的方法不同。因此，IoU 在评估完成质量时可能引入偏差。基于此，我们仅将 IoU 结果作为相对参考。

表12和表13展示了 ScoreLiDAR 与现有模型的 IoU。在低体素分辨率下，ScoreLiDAR 取得了可比的 IoU 值，说明 ScoreLiDAR 能生成密集且精确的点云。当体素分辨率变高时，ScoreLiDAR 的性能下降。如上所述，现有方法主要基于符号距离场，使用体素表示来实现场景补全。ScoreLiDAR 则是在点级别进行场景补全，输入为来自 LiDAR 扫描的点云，在较小体素分辨率下效果更好。

E. 理论证明

学生模型的梯度为等式(25)。

$$\begin{aligned} & \nabla_{\eta} D_{\text{KL}}(p_G^t(\mathcal{G}^t) \| q^t(\mathcal{G}^t)) \\ &= \mathbb{E}_{t, \epsilon} [\nabla_{G^t} \log p_G^t(\mathcal{G}^t) - \nabla_{G^t} \log q^t(\mathcal{G}^t)] \frac{\partial \mathcal{G}^t}{\partial \eta} \quad (25) \end{aligned}$$




图6. 所选关键点的可视化。红点表示由所提方法选择的关键点。

如 ScoreSDE [36] 所述, 似然对数 $\nabla_{\mathcal{G}^t} \log q^t(\mathcal{G}^t)$ 可由预测噪声 $\hat{\epsilon}$ 与 $\nabla_{\mathcal{G}^t} \log q^t(\mathcal{G}^t) \approx -\frac{\hat{\epsilon}}{\sqrt{1-\alpha^t}}$ 近似。因此, 式(25) 中的梯度可写为

$$\begin{aligned} & \nabla_{\eta} D_{\text{KL}}(p_G^t(\mathcal{G}^t) \| q^t(\mathcal{G}^t)) \\ &= \mathbb{E}_{t, \epsilon} [\nabla_{\mathcal{G}^t} \log p_G^t(\mathcal{G}^t) - \nabla_{\mathcal{G}^t} \log q^t(\mathcal{G}^t)] \frac{\partial \mathcal{G}^t}{\partial \eta} \\ &\approx \mathbb{E}_{t, \epsilon} \left[-\frac{\epsilon_{\phi}(\mathcal{G}^t, \mathcal{P}, t)}{\sqrt{1-\alpha^t}} - \left(-\frac{\epsilon_{\theta}(\mathcal{G}^t, \mathcal{P}, t)}{\sqrt{1-\alpha^t}} \right) \right] \frac{\partial \mathcal{G}^t}{\partial \eta} \quad (26) \\ &= \mathbb{E}_{t, \epsilon} \left[\frac{\epsilon_{\theta}(\mathcal{G}^t, \mathcal{P}, t)}{\sqrt{1-\alpha^t}} - \frac{\epsilon_{\phi}(\mathcal{G}^t, \mathcal{P}, t)}{\sqrt{1-\alpha^t}} \right] \frac{\partial \mathcal{G}^t}{\partial \eta} \end{aligned}$$

此处可忽略 $\sqrt{1-\alpha^t}$ 。因此, G_{stu} 的梯度可近似为

$$\begin{aligned} & \nabla_{\eta} D_{\text{KL}}(p_G^t(\mathcal{G}^t) \| q^t(\mathcal{G}^t)) \\ &\approx \mathbb{E}_{t, \epsilon} [\epsilon_{\theta}(\mathcal{G}^t, \mathcal{P}, t) - \epsilon_{\phi}(\mathcal{G}^t, \mathcal{P}, t)] \frac{\partial \mathcal{G}^t}{\partial \eta} \quad (27) \end{aligned}$$

F. 使用方法简介

F.1. 变分谱分馏

变分评分蒸馏 (VSD), 由 Prolific-Dreamer [42] 提出, 旨在利用预训练扩散模型训练 NeRF [26], 从而渲染高质量的 3D 对象。

给定文本提示 y , 所有可能 3D 表示的概率分布可由参数为 θ 的 NeRF 模型建模为概率密度 $\mu(\theta \| y)$ 。设 $q_0^{\mu}(\mathbf{x}_0 \| c, y)$ 为在相机 c 给定下 NeRF 渲染图像 $\mathbf{x}_0$ 的分布, $p_0(\mathbf{x}_0 \| y)$ 为在 $t=0$ 处预训练文本到图像扩散模型的分布。为生成高质量 3D 对象, Prolific-Dreamer [42] 通过最小化以下 KL 散度来优化 μ 的分布

$$\min_{\mu} D_{\text{KL}}(q_0^{\mu}(\mathbf{x}_0 \| y) \| p_0(\mathbf{x}_0 \| y)) \quad (28)$$

然而, 直接求解该变分推断问题具有挑战性, 因为 p_0 很复杂, 且其高密度区域在高维空间中可能极为稀疏。

因此, ProlificDreamer 将其重新表述为不同时间步的优化问题 t , 将这些问题称为变分分数蒸馏 (VSD)

$$\min_{\mu} \mathbb{E}_{t,c} [(\sigma_t/\alpha_t) \omega(t) D_{\text{KL}}(q_t^{\mu}(\mathbf{x}_t | c, y) \| p_t(\mathbf{x}_t | y))] \quad (29)$$

文献[42]的定理1证明了引入额外的 t 不影响式(28)的全局最优解。文献[42]的定理2给出了优化式(29)中问题的方法。

$$\begin{aligned} \frac{d\theta_{\tau}}{d\tau} = & -\mathbb{E}_{t,\epsilon,c} [\omega(t) \underbrace{(-\sigma_t \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t | y))}_{\text{score of noisy real images}} \\ & - \underbrace{(-\sigma_t \nabla_{\mathbf{x}_t} \log q_t^{\mu_{\tau}}(\mathbf{x}_t | c, y))}_{\text{score of noisy rendered images}}] \frac{\partial \mathbf{g}(\theta_{\tau}, c)}{\partial \theta_{\tau}} \end{aligned} \quad (30)$$

此处真实噪声图像的分值由预训练的扩散模型 $\epsilon_{\text{pretrain}}(\mathbf{x}_t, t, y)$ 近似, 而渲染噪声图像的分值由另一个在渲染图像上以标准扩散目标训练的扩散模型 $\epsilon_{\phi}(\mathbf{x}_t, t, c, y)$ 近似。

$$\min_{\phi} \sum_{i=1}^n \mathbb{E}_{t,\epsilon,c} \left[\left\| \epsilon_{\phi}(\alpha_t \mathbf{g}(\theta^{(i)}, c) + \sigma_t \epsilon, t, c, y) - \epsilon \right\|_2^2 \right] \quad (31)$$

在实践中, $\epsilon_{\phi}(\mathbf{x}_t, t, c, y)$ 由一个小型 UNet 或教师模型的低秩适配 (LoRA) [11] 参数化。通过 NeRF 与 $\epsilon_{\phi}(\mathbf{x}_t, t, c, y)$ 的交替训练, ProlificDreamer [42] 最终能够生成高质量的 3D 物体。

F.2. MinkowskiEngine

稀疏张量计算在 3D 点云处理、计算机视觉和物理模拟等领域中起关键作用。与稠密张量不同, 稀疏张量包含大量零值, 直接应用传统张量运算会导致计算资源低效使用。Minkowski Engine [5] 通过提供一个为稀疏张量计算量身定制的高性能框架来应对这些挑战, 从而在高维稀疏数据上实现高效运算。本文中, 我们使用 Minkowski Engine 处理稀疏点云数据。

Minkowski Engine 引入了若干创新方法来处理稀疏张量。

- 高效的稀疏张量表示。稀疏张量采用坐标-值对表示, 省去存储零值的需要, 从而减少内存占用和计算开销。
- 稀疏卷积操作。该框架支持高维稀疏卷积, 卷积核设计可适应不同的稀疏模式。

优化的内存访问模式和并行计算策略确保了高效性。

- 快速坐标映射。Minkowski Engine 使用哈希表实现快速坐标映射, 加速张量索引和稀疏模式匹配。
- 自动微分支持。该框架内置自动微分支持, 便于基于稀疏张量的机器学习模型训练。

- 多维能力: Minkowski Engine 能处理任意维度的稀疏张量, 适用于从二维图像处理到五维仿真的广泛应用。

Minkowski Engine 已在包括三维点云处理、物理仿真和医学成像等多个领域被广泛采用。通过显著提高计算效率和可扩展性, Minkowski Engine 已成为研究和工业界处理中稀疏张量计算的首选。

G. 伦理声明

我们的工作可能带来的伦理影响涉及公平性。由于“人”被视为 LiDAR 场景中的一种对象, 在场景补全时可能需要补全人像。与人相关的对象可能存在与公平性相关的数据偏差, 例如对性别或肤色的偏见。这样的偏差可能会在训练中被学生模型捕捉到。

G.1. 向受试者的通知

在我们的用户研究中, 我们在实验前向受试者展示通知, 告知数据的收集与使用。

亲爱的志愿者, 感谢您支持我们的研究。我们提出了 ScoreLiDAR, 一种为 3D LiDAR 场景补全量身定制的新型蒸馏方法, 该方法引入结构损失以帮助学生模型捕捉几何结构信息。您参与研究的所有信息将记录在研究档案中。所有信息将根据当地隐私法律和政策进行处理与存储。您的姓名不会出现在最终报告中。引用您提供的数据时仅会提及分配给您的个人编号。

我们尊重您是否愿意成为本研究的志愿者的决定。如果您决定参加本研究, 您可以签署本知情同意书。

伦理审查委员会批准使用主要作者所在机构的用户数据。

H. 失败示例

图9给出了一些ScoreLiDAR的失败案例。从这些示例可以看出，ScoreLiDAR在一定程度上存在过度补全，会补全出不存在的区域。如主文Sec.3所述，补全前将输入稀疏扫描的点数 $\mathcal{P}$ 通过拼接其点 K 倍以增加，得到密集输入 $\mathcal{P}^*$ 。若 $\mathcal{P}^*$ 的点数超过了真实标注的点数，可能导致补全场景中出现冗余点。这些冗余点可能分布在不需要补全的区域，从而产生失败案例中观察到的情况。




图 7. 来自 KITTI-360 数据集的 ScoreLiDAR 完成样本。




图 8. 来自 SemanticKITTI 数据集的 ScoreLiDAR 完成样本。




图 9. ScoreLiDAR 的失败示例。