

用于新视角合成的神经 LiDAR 场

Shengyu Huang^{1,2} Zan Gojcic² Zian Wang^{2,3,4} Francis Williams²

Yoni Kasten² Sanja Fidler^{2,3,4} Konrad Schindler¹ Or Litany²

¹ ETH 苏黎世 ² NVIDIA ³ 多伦多大学 ⁴ Vector Institute

<https://research.nvidia.com/labs/toronto-ai/nfl/>

摘要

我们提出了用于 LiDAR 的神经场 (NFL)，一种从 LiDAR 测量数据优化神经场场景表示的方法，旨在从新视点合成逼真的 LiDAR 扫描。NFL 将神经场的渲染能力与对 LiDAR 传感过程的详细物理动机模型相结合，从而能够准确再现诸如光束发散、二次回波和射线丢弃等关键传感器行为。我们在合成和真实 LiDAR 扫描上评估了 NFL，并表明其在 LiDAR 新视点合成任务上优于显式先重建后模拟的方法以及其他 NeRF 风格的方法。此外，我们还表明，合成视图逼真度的提升缩小了与真实扫描的域差距，并转化为更好的配准和语义分割性能。

虽然大多数先前工作侧重于合成摄像机视图，但自动驾驶场景下的三维感知通常部分（甚至完全）依赖于激光雷达测量。从新视角合成逼真的激光雷达扫描因此在数据增强和自动驾驶系统的闭环测试方面具有很大潜力。

从新激光雷达视角合成的问题之前被分两步处理 [24]。首先，从扫描得到的点云中提取显式表面表示，如表面元素或三角网格。然后，通过投射光线并与表面模型求交来模拟来自新视点的激光雷达测量。与图像类似，显式重建（未针对后续合成步骤进行优化）会受到离散化伪影的影响并引入明显误差 [46]。此外，渲染假定了理想化的光线模型，忽略了激光雷达束的发散，这会导致来自远处表面的频繁二次回波。

1. 引言

新视角合成的目标是从未被真实传感器拍摄过的观点生成三维场景的视图。这使得能够从虚拟的、未观测的视角观察真实场景成为可能。在自动驾驶等诸多应用中，它具有巨大潜力：合成的新视角可用于在更广泛的观测条件下训练和测试感知算法，从而提升鲁棒性和泛化能力。此外，当所需视点事先未知时（例如在规划模块的训练中，其决策决定未来车辆位置），新视角合成便变得尤为关键。

神经辐射场 (NeRF) 在合成新相机视角时达到了前所未有的视觉质量 [2, 29, 30, 52]。这些方法以连续的密度和辐射场形式表示三维场景，可通过体渲染生成图像，模拟图像采集过程。神经网络的归纳偏置赋予 NeRF 高度真实地内插复杂光照和反射行为的能力。

在此，我们改以 NeRF [29] 的一个主要洞见为基础：直接优化用于新视角合成的隐式场景表示，比先重建再模拟的方法能产生更真实的结果。具体而言，我们提出了用于 LiDAR 的神经场 (NFL)，一种用于合成新 LiDAR 视点的 NeRF 风格表示。

若干 NeRF 扩展将测程测量作为额外监督，并表明更紧密约束场景几何能带来更好的（相机）视角合成 [8, 38]。然而，这些方法的输出是合成图像，而非 LiDAR 扫描，因此未关注 LiDAR 感测特有的效应：激光扫描器并不直接测量距离，而是对每条光线返回的光能进行测量并根据波形确定距离。这包括发射光线可能产生多次回波¹或根本无回波的可能性。

我们的表述严格遵循 LiDAR 测量过程的原理，并将其融入神经场框架。

¹原则上可以有 > 2 个回波，但汽车用 LiDAR 传感器通常记录前两个回波。

具体而言，我们 (i) 为LiDAR 传感器设计体积渲染；(ii) 考虑光束发散；并且 (iii) 提出截断体积渲染以考虑二次回波并改进距离预测。

我们在合成和真实 LiDAR 数据上评估我们的方法。为此，我们 (iv) 开发一个 LiDAR 仿真器，用以从3D 资产合成场景，作为远离原始扫描位置的视点测试平台，并研究不同扫描模式的影响。使用 Waymo [43] 数据集的真实数据来在保留视点上评估 NFL 与真实扫描的表现，包括真实世界的强度、光线丢失和二次回波。此外，我们 (v) 提出一种新的闭环评估协议，利用真实数据评估具有挑战性视点的视图合成。作为对下游任务的端到端测试，我们还评估当在真实扫描上训练并在由 NFL 生成的新视图上测试时，最先进的分割和配准网络的性能。

2. 相关工作

LiDAR 仿真。模拟真实 LiDAR 数据对于训练感知模型很有用。与需要人工标注的真实世界 LiDAR 数据不同，模拟数据可以自动生成并附带真实标签，例如目标边界框和语义分割。若 LiDAR 仿真不够真实，会阻碍训练模型向真实数据的泛化。传统的仿真引擎（如文献 [9, 19] 所述）要求指定传感器参数和 3D 场景资源，并使用光线投射方法进行仿真。尽管这些点云可以准确表示场景几何，但由于未对传感器噪声（如射线丢失和高斯光束）建模，它们通常与真实数据存在差异或“域间隙”。此外，这种方法高度依赖 3D 场景资源的创建，既耗时又昂贵。为了解决这些挑战，LiDARsim [24] 使用 surfel [34] 表示从真实数据重建静态和动态场景资源，并对射线丢失模式建模以提高逼真度。BaiduSim [10] 提出使用概率图来建模场景组成以减少域间隙。最近的大多数工作 [11] 学习增强现有模拟 LiDAR 的强度和射线丢失模式，利用可用的对应 RGB 图像。

天气状况，如雾或雨，会显著影响 LiDAR 数据质量，仅在理想天气下训练的下游模型可能无法对这些影响泛化。近期方法和数据集 [5, 12, 13, 17] 已被提出以解决此问题。SnowSIM [12] 和 FogSIM [13] 分别通过采样雪粒子和建模大气衰减的脉冲响应，来改变每条光线的测距。

其他方法 [17,20,42] 以类似方式模拟雨天的 LiDAR 数据及喷溅效应。

NeRF 用于新视角合成。NeRF [29] 将 5D 位置与方向映射到密度和辐射值，并使用体积渲染 [25, 26] 估计像素颜色。该技术已被证明能在未知相机视角生成逼真图像。许多方法被提出以提高对相机位姿的鲁棒性 [7, 21]、处理动态场景 [32, 35]、抗锯齿 [2, 3, 53]、以及加速优化 [22,30,52] 等。尽管在高质量新视角合成方面表现优异，NeRF 的底层几何被认为不精确且噪声较多 [31]，使其在几何重建中不被青睐，尤其在稀疏视图设置下。[31,48,51] 通过使用隐式表面表示并基于其定义密度函数以实现体积渲染来应对这一挑战。DS-NeRF [8] 和 DenseDS-NeRF [39] 使用来自 SfM [41] 点的稀疏深度监督来正则化密度场。Urban Radiance Field [38] 利用 LiDAR 数据进行深度监督。

超出常规相机的神经场。神经场是用于时空信息（包括 SDFs [33]、占据 [27] 和辐射场 [29] 等）的自然且连续的特征 [50]。在其原始形式中，NeRF [29] 使用经色调映射的低动态范围图像进行新视图合成，RawNeRF [28] 将其扩展到高动态范围图像，使其能够额外调整焦距、曝光和色调映射。Törf [1] 将连续波飞行时间 (ToF) 相机的成像模型并入 NeRF，使其能够联合处理 RGB 与 ToF 传感器数据并提高对大幅运动的重建鲁棒性。EventNeRF [40] 与 ENeRF [18] 针对包含异步逐像素亮度变化信号的稀疏事件流，优化场景表征以用于新视图合成 (NVS)。其他工作 [23,36] 探索使用声学信号进行表面重建或 NVS。

3. 背景

我们首先回顾体渲染的原理（第3.1节）和 LiDAR的传感器模型（第3.2节）。这为提出的神经LiDAR场表述（第4节）奠定基础。

3.1. 被动传感器的体渲染

下面我们简要总结NeRF [29,44] 中使用的基于相机的体渲染。这将作为推导用于主动LiDAR传感器的体渲染方程的基础。

密度与透射率。




图1。左：真实 LiDAR 扫描展示关键回波特性：单回波和双回波（第一回波为蓝色，第二回波为橙色）。右：NFL 对波形建模并准确再现这些特性。(a) 上：LiDAR 能量被第一表面完全散射。下：NFL 先对计算出的权重进行峰值检测以估计距离 w ，然后通过基于体积渲染的距离细化。(b) 上：射束击中两表面产生的二次回波。下：NFL 利用光束发散和截断体积渲染来估计第二回波。(c) 上：未击中表面的射束不会返回可检测信号。下：NFL 使用几何和语义特征来预测射线丢失概率。详见第4.3节。

对于从原点 $\mathbf{o} \in \mathbb{R}^3$ 沿方向 $\mathbf{d} \in \mathbb{R}^3$ 发射的光线 $\mathbf{r}(\mathbf{o}, \mathbf{d})$ ，在距离 ζ 处的密度 σ_ζ 是一个标量函数，它表示在位置 $\mathbf{r}_\zeta = \mathbf{o} + \zeta \mathbf{d}$ 处击中反射粒子的微分概率。透射率 T_ζ 表示在不击中任何物体的情况下穿过区间 $[0, \zeta]$ 的概率。沿着光线取一个微分步长 $d\zeta$ ，不击中任何物体的概率是 $T_{\zeta+d\zeta} = T_\zeta \cdot (1 - \sigma_\zeta d\zeta)$ 。对区间 $[\zeta_0, \zeta]$ 进行积分，得到无障碍穿过该区间的概率 $T_{\zeta_0 \rightarrow \zeta}$

$$T_{\zeta_0 \rightarrow \zeta} \equiv \frac{T_\zeta}{T_{\zeta_0}} = \exp\left(-\int_{\zeta_0}^{\zeta} \sigma_t dt\right), \quad (1)$$

导致分解： $T_\zeta = T_{0 \rightarrow \zeta_0} \cdot T_{\zeta_0 \rightarrow \zeta}$ 。

在均匀介质上的积分。假定沿光线段 $[\zeta_j, \zeta_{j+1}]$ 的介质均匀，具有常数辐亮度 $\mathbf{c} \in \mathbb{R}^3$ 和密度 σ ，该段的累计辐亮度计算为

$$\mathbf{c}(\zeta_j \rightarrow \zeta_{j+1}) = \mathbf{c}_{\zeta_j} \int_{\zeta_j}^{\zeta_{j+1}} T_{\zeta_j \rightarrow \zeta} \cdot \sigma_\zeta d\zeta = \alpha_{\zeta_j} \mathbf{c}_{\zeta_j}, \quad (2)$$

其中 $\alpha_{\zeta_j} = 1 - \exp(-\sigma_{\zeta_j}(\zeta_{j+1} - \zeta_j))$ 为不透明度。

体渲染。将光线离散为 N 段、每段具有分段常数密度和辐亮度值，可得总照度（待渲染的颜色）：

$$\mathbf{c} = \sum_{j=1}^N \int_{\zeta_j}^{\zeta_{j+1}} T_\zeta \cdot \sigma_\zeta \mathbf{c}_\zeta d\zeta = \sum_{j=1}^N w_j \mathbf{c}_{\zeta_j}, \quad (3)$$

其中 w_j 是第 j 段的权重：

$$w_j = \alpha_{\zeta_j} \prod_{k=1}^{j-1} (1 - \alpha_{\zeta_k}). \quad (4)$$

3.2. 激光雷达模型

激光雷达发射激光脉冲，并通过测量飞行时间来确定传感器到最近反射表面的距离。通常将激光雷达的光束描述为在三维表面点处终止的理想直线段，但现实更为复杂：真实激光器发出的脉冲具有非零发散角和有限脉冲宽度，真实接收器则采用辐射阈值、分箱等信号处理技术来检测回波。这会导致离散化误差、过高或过低估计偏差（参见图2），以及单束产生多重回波（或根本无回波）等现象。下面我们讨论激光雷达采集过程的关键方面并解释由此产生的效应，这些效应启发了我们的模型设计。我们还构建了一个考虑这些机制的激光雷达模拟器，见第5.1节。

光束发散。LiDAR 光束在远离传感器时会发生发散。激光光束的尺寸随距离增大而变宽，在街景中通常不可忽略。因此，被照亮的区域增大，其辐照度（单位面积辐射功率）随距离增加而降低。光束足迹的大小由发散角 ($2\gamma_0$) 和测距 ζ 表征。设 $\mathbf{r}^\gamma$ 为光束横截面内的理想光线， $\gamma \leq \gamma_0$ ，则其在距离 ζ 处的照度 $E(\zeta, \gamma)$ 可在光线坐标系中近似为高斯函数 [47]：

$$E(\zeta, \gamma) = \frac{2I_0}{\pi(\gamma_0\zeta)^2} g(\gamma), \quad g(\gamma) = \exp\left(-2\frac{\gamma^2}{\gamma_0^2}\right), \quad (5)$$

其中 I_0 为脉冲峰值功率。

脉冲波形。当发射的 LiDAR 脉冲返回到传感器时，可从其传播时间和光速 c 确定到反射表面的距离。

由于脉冲有有限持续时间 τ_H ，返回时间通过分析接收的强度轮廓确定。发射脉冲随时间的功率可表征为 [6]:

$$P_e(t) \propto \left(\frac{t}{\tau}\right)^2 \exp\left(-\frac{t}{\tau}\right), \quad \tau = \frac{\tau_H}{1.75}. \quad (6)$$

与距离相关的接收辐射功率 $P(\zeta)$ 是将脉冲功率与系统脉冲响应 $H(\zeta)$ [12, 13, 37] 卷积的结果:

$$P(\zeta) = \int_0^{2\zeta/c} P_e(t)H(\zeta - \frac{ct}{2}) dt, \quad (7)$$

其中脉冲响应 $H(\zeta)$ 由目标与接收器响应组合而成: $H(\zeta) = H_T(\zeta)H_C(\zeta)$ 。假设朗伯表面, 位于距离 ζ_0 的表面对入射角 θ 和反射率 ρ 的响应为:

$$H_T(\zeta) = \frac{\rho}{\pi} \cos(\theta) \delta(\zeta - \zeta_0), \quad (8)$$

与 $\delta(\cdot)$ 狄拉克 δ 函数。接收器响应 $H_C(\zeta)$ 通过对接收器有效面积所覆盖的立体角 A_e 进行积分计算:

$$H_C(\zeta) = T_\zeta^2 \frac{A_e}{\zeta^2}, \quad (9)$$

其中 $T_\zeta \in [0, 1]$ 为单程透射率, 平方以考虑来回两程。

光束离散化。实际上, 我们遵循 [49] 并用 $M = 37$ 条射线近似高斯光束剖面, 这些射线在中心射线周围径向分布并具有不同的发散角 γ_i 。总辐射功率

$P(\zeta)$ 是这些射线的加权和: $P(\zeta) = \sum_{i=1}^M g(\gamma_i) P_i(\zeta)$

。考虑光束发散对于再现两个重要现象很重要: 测距偏差和多重回波, 见图 1 和图 2。由于不同射线以不同距离撞击倾斜表面, 积分波形峰值可能移动, 导致高估或低估。在物体边缘, 同一光束内的射线可能撞击不同表面, 造成回波波形中的多个峰值 (即多个测距读数)。

距离估计。估计接收波形对应表面距离的一种常见方法是定位其峰值。为此将信号在时间上离散化以得到直方图, 并将高于某一阈值的局部极大值判为检测到的目标[49]。随后对关联的距离值进行校正以消除由脉冲波形导致的已知偏差 (参见式(6)), 并可选择性地消除由辐射功率导致的偏差[49]。通过对分箱与阈值处理建模, 可以再现更多 LiDAR 行为: 距离分辨率的系统性离散化误差 (参见图2), 以及返回功率低的光线被丢弃 (参见图1)。




图 2。LiDAR 传感器的测距精度受波形离散化和光束发散的影响。在高入射角情况下, LiDAR 传感器倾向于高估距离, 且在更远距离时这一现象更加明显 (左)。TownReal 数据集上也能观察到相同现象 (右)。

4. LiDAR 新视角合成

下面我们构建一个针对 LiDAR 扫描的神经场模型, 并设计一个可微分的体渲染方案以实现 LiDAR 新视角合成。首先给出问题设定, 然后建立相应的神经场景表示 (第 4.1 节), 并推导用于主动感知的体渲染方法 (第 4.2 节)。最后描述用于合成新视角的渲染流程 (第 4.3 节) 及我们的优化方案 (第 4.4 节)。

问题设定。考虑一组由移动传感器 (如安装在车辆上) 采集的 LiDAR 扫描 $\mathcal{X} = \{\mathbf{X}_v\}_{v=1}^{n_v}$ 。每次扫描 $\mathbf{X}_v$ 都对应一个传感器位姿 $\mathbf{T}_v \in \text{SE}(3)$, 并由 n_r 条光束组成。每条光束 $\mathbf{r}(\mathbf{o}, \mathbf{d})$ 记录观测 $(\zeta_1, e_1, p_d, p_s, \zeta_2, e_2)$: 第一回波的距离 ζ_1 和强度 e_1 ; 光束丢失标志 $p_d \in \{0, 1\}$; 双回波掩码 $p_s \in \{0, 1\}$; 以及第二回波的距离 ζ_2 和强度 e_2 值。我们的目标是重建场景的 (连续) 体积表示, 表示为密度 σ 和反射率 ρ , 从而可以从新颖的传感器位姿 $\mathbf{T}_{tgt}$ 渲染出虚拟 LiDAR 扫描 $\mathbf{X}_{tgt}$ 。

4.1. 神经场景表示

我们将场景编码为一个神经场 $F: (\mathbf{x}, \mathbf{d}) \mapsto (\sigma, \rho, p_d)$, 该神经场以位置 $\mathbf{x} \in \mathbb{R}^3$ 和视线方向 $\mathbf{d} \in \mathbb{R}^3$ 为输入, 输出密度 σ 、反射率 ρ 和光线丢失概率 p_d 。我们发现额外返回一个对光线丢失概率的局部贡献 $p_d \in [0, 1]$ 有益, 下面将讨论。技术上, 我们使用哈希编码 [30] 将坐标 $\mathbf{x}$ 映射为位置特征 $\mathbf{f}_{\text{pos}} \in \mathbb{R}^{32}$, 并将视线方向投影到球谐函数基的前 16 个系数 $\mathbf{f}_{\text{dir}} \in \mathbb{R}^{16}$ 。该神经场由四个多层感知器 (MLP) 参数化: $[\sigma; \mathbf{f}_{\text{geo}}] = f_\sigma(\mathbf{f}_{\text{pos}})$ 回归密度并提取支持其他网络的额外几何特征 $\mathbf{f}_{\text{geo}} \in \mathbb{R}^{15}$; $\rho = f_\rho(\mathbf{f}_{\text{geo}}, \mathbf{f}_{\text{dir}})$ 回归反射率; $p_d = f_{\text{drop}}(\mathbf{f}_{\text{geo}}, \mathbf{f}_{\text{dir}})$ 判断是否发生光线丢失; $p_s = f_{\text{sr}}(\mathbf{f}_{\text{beam}})$ 判断是否存在第二次返回。

特征 $\mathbf{f}_{\text{beam}}$ 的详细说明见第 4.3 节。

4.2. LiDAR 光线的体积渲染

与依赖环境光的被动传感器（如相机）不同，LiDAR 主动照亮场景并测量回散辐亮。这种双向透射改变了体积渲染的公式。

辐射功率积分。如第 3.2 节所述，沿 LiDAR 光线的辐射功率为只在反射表面非零的 δ 函数。为将该前向模型纳入体积表示，我们将 Eq. (8) 与 Eq. (9) 结合，得到概率性辐射功率：

$$P_{\zeta} = C \frac{T_{\zeta}^2 \cdot \sigma_{\zeta} \rho_{\zeta}}{\zeta^2} \cos(\theta), \quad (10)$$

其中 C 是系统常数， ρ_{ζ} 是可微反射率， θ 是入射角。在具有常数反射率 ρ 和密度 σ 的均匀介质中，积分的 $P(\zeta_j \rightarrow \zeta_{j+1})$ 计算为：

$$P(\zeta_j \rightarrow \zeta_{j+1}) = \int_{\zeta_j}^{\zeta_{j+1}} C \frac{T_{\zeta}^2 \cdot \sigma_{\zeta} \rho_{\zeta}}{\zeta^2} \cos(\theta_j) d\zeta \approx \alpha_{\zeta_j} \rho'_{\zeta_j}, \quad (11)$$

在此我们用 $\frac{\zeta_j + \zeta_{j+1}}{2}$ 近似 $\zeta \in [\zeta_j, \zeta_{j+1}]$ 并且

$$\alpha_{\zeta_j} = \frac{1}{2} \left(1 - e^{-2\sigma_{\zeta_j} \delta_j} \right), \quad \rho'_{\zeta_j} = C \rho_{\zeta_j} \frac{4 \cos(\theta_j)}{(\zeta_j + \zeta_{j+1})^2}. \quad (12)$$

体积渲染。将等式 (11) 代入等式 (3) 后，可计算到达活动传感器的观测功率：

$$P = \sum_{j=1}^N \int_{\zeta_j}^{\zeta_{j+1}} C \frac{T_{\zeta}^2 \cdot \sigma_{\zeta} \rho_{\zeta}}{\zeta^2} \cos(\theta_j) d\zeta = \sum_{j=1}^N w_j \rho'_{\zeta_j}, \quad (13)$$

此处权重 w_j 现在按（参见等式 (4)）评估为：

$$w_j = 2\alpha_{\zeta_j} \cdot \prod_{k=1}^{j-1} (1 - 2\alpha_{\zeta_k}). \quad (14)$$

4.3. 从多条射线组装光束

接着，我们将改编的体积渲染公式应用于单个 LiDAR 光束内的多条射线。

首次距离估计。我们采用两阶段方法从神经场中提取距离值，² 如图 1(a) 所示。为了估计理想光线的距离 $\mathbf{r}$ ，我们均匀采样 N^c 点并查询其密度值，然后使用公式 (14) 计算权重 $\left\{ w_j^c \right\}_{j=1}^{N^c}$ 。

² 注意其与仪器中探测器的相似性：该探测器先找到波形的峰值，然后对脉冲形状进行校正。

通过沿射线找到权重最高的点获得粗略峰值估计 ζ_p ：

$p = \arg \max_j \left\{ w_j^c \right\}_{j=1}^{N^c}$ 。接着，我们从局部区间均匀采样 N^f 个点 $\zeta_j \in [\zeta_p - \epsilon, \zeta_p + \epsilon]$ 。在这些点处重算并归一化权重 w_j^f ，从而得到最终精细化的距离估计 ζ_f ： $\zeta_f = \sum_{j=1}^{N^f} w_j^f \cdot \zeta_j$ 。

第二次距离估计。如第 3.2 节所述，如果从比第一个回波更远的表面反射回足够能量，单束 LiDAR 可能会产生多个回波。为在场景表示中捕捉此行为，我们采用截断体积渲染来估计第一个回波之外的辐射功率（见图 1(b)）。

具体到每根光束，我们首先预测一个二次回波掩码 p_s ，通过对其特征进行分类

$\mathbf{f}_{\text{beam}} = (\bar{\mathbf{f}}_{\text{geo}}, \mathbf{f}_{\text{dir}}, \mathbf{f}_{\text{range}})$ ，其中 $\bar{\mathbf{f}}_{\text{geo}}$ 是体渲染的几何特征， $\mathbf{f}_{\text{range}}$ 描述了首次回波处距离估计的标准差和最大差异。直观上， $\bar{\mathbf{f}}_{\text{geo}}$ 描述了局部几何（例如边缘）， $\mathbf{f}_{\text{dir}}$ 编码了光束与该几何的关系， $\mathbf{f}_{\text{range}}$ 则刻画了光束与场景的先验交互。

对于有两次回波的光束，我们按如下方式执行截断体积渲染。我们先在第一回波的估计距离 ζ_1 上加一个缓冲 ξ ³。然后通过将 $(\zeta_1 + \xi)$ 的密度清零把透射率 $T_{\zeta_1 + \xi}$ 复位为 1，并重新计算权重以确保它们满足公式 (14)。最后，我们重复上述距离估计来估算第二回波的距离 ζ_2 。注意，对于有两次回波的光束，估计距离 ζ_1 表示光束直径内所有射线的最小距离，即我们对光束的所有射线进行体渲染并选择最接近的一条作为第一回波。这不同于只有一次回波的光束，后者我们直接使用中心射线来估算 ζ_1 。

反射率估计。在每个检测到的表面点，我们也可以从神经场中检索反射率，使用关系 $\rho = \sum_{j=1}^{N^f} w_j^f \cdot \rho_j$ 。

光线丢弃概率。在真实的 LiDAR 传感器中，某些发射光束根本不会返回距离测量。当观测到的回波信号振幅过低或无明显峰值时会发生这种情况（图 1(c)）。然而，这一效应很难用完全基于物理的方式建模，⁴ 因为它依赖于（通常未公开的）检测逻辑细节。我们经验证明，光线丢弃概率可以从 LiDAR 测量中学习。为此，我们在神经场景表示中增加了一个专门变量，用于表示局部不发生回向散射辐射功率的概率 $p_d(\zeta) \in \{0, 1\}$ ⁵。

³ 缓冲区 ξ 与传感器相关，描述两个不同回波之间的最小间距。

⁴ 超出简单阈值处理——我们的波束模型可支持此类处理。

⁵ 请参见补充材料中关于此设计选择的讨论。

体积渲染将该量整合为光线丢弃概率： $p_d(\mathbf{r}) = \sum_{j=1}^{N_c} w_j^c \cdot p_d(\zeta_j)$.

4.4. 训练神经 LiDAR 场

给定一组带位姿的 LiDAR 扫描，我们通过最小化损失来优化我们的神经场模型

$$\mathcal{L} = \mathcal{L}_{\text{range}} + \lambda_e \mathcal{L}_e + \lambda_d \mathcal{L}_d + \lambda_s \mathcal{L}_s, \quad (15)$$

该损失由用于距离估计的重建损失 $\mathcal{L}_{\text{range}}$ 、反射率损失 $\mathcal{L}_e$ ，以及用于光线丢弃的分类损失 $\mathcal{L}_d$ 和用于双回波的分类损失 $\mathcal{L}_s$ 组成。

范围重建。我们为粗糙范围 ζ_p 和精细范围

ζ_f , $\mathcal{L}_{\text{range}} = \mathcal{L}_{\text{range}}^c + \mathcal{L}_{\text{range}}^f$ 分别添加两个损失。对于粗糙范围，我们在真实值周围施加了高斯分布 [38] $\hat{\zeta}$,

$$\mathcal{L}_{\text{range}}^c = \frac{1}{|\mathcal{R}|} \sum_{\mathbf{r} \in \mathcal{R}} \left(1 - \sum_{w_j \in \mathcal{X}_c^n} w_j \hat{w}_j + \sum_{w_k \in \mathcal{X}_c^e} w_k^2 \right), \quad (16)$$

其中 $\mathcal{R}$ 是 LiDAR 光线的集合， $\mathcal{X}_c^n$ 和 $\mathcal{X}_c^e$ 表示在区间 $[\hat{\zeta} - \epsilon, \hat{\zeta} + \epsilon]$ 内外采样的点。真实权重 $\hat{w}_j$ 通过对高斯分布积分计算。范围精化损失定义为：

$$\mathcal{L}_{\text{range}}^f = \frac{1}{|\mathcal{R}|} \sum_{\mathbf{r} \in \mathcal{R}} |\hat{\zeta} - \zeta_f|.$$

反射率重建通过最小化相对于真实强度的 L2 损失来优化 $\hat{e}$: $\mathcal{L}_e = \frac{1}{|\mathcal{R}|} \sum_{\mathbf{r} \in \mathcal{R}} (\hat{e} - e)^2$.

射线丢失和双返回掩码作为分类任务训练，通过最小化二元交叉熵损失 $\mathcal{L}_{bce}$ 与 Lovasz 损失 $\mathcal{L}_{ls}$ [4] 的组合

$$\mathcal{L}_* = \frac{1}{|\mathcal{R}|} \sum_{\mathbf{r} \in \mathcal{R}} (\mathcal{L}_{bce}(p_*, \hat{p}_*) + \mathcal{L}_{ls}(p_*, \hat{p}_*)) . \quad (17)$$

5. 实验

我们先在第 5.1 节描述我们的 LiDAR 仿真器、数据集、评估指标和基线。在第 5.2 节，我们在 LiDAR 新视角合成任务上直接评估 NFL。最后在第 5.3 节，我们评估合成 LiDAR 数据用于两项低层任务的适用性：点云配准和语义分割。

5.1. 数据集与评估设置

LiDAR 模拟器 - TownReal 数据集。为了在受控环境中进行定量评估，我们构建了一个 LiDAR 模拟器，允许我们对以三角网格或表面片表示的合成 3D 资产进行虚拟扫描。

具体来说，我们遵循第 3.2 节中描述的 LiDAR 模型，并允许控制角分辨率、光束发散和 LiDAR 传感器的脉冲形状。

我们将该模拟器与一个城镇的 3D 资产 [16] 结合使用以合成 Town 数据集。我们通过将 3D 资产划分为四个不重叠区域来生成四个场景。训练和测试扫描由不同轨迹创建。我们使用两种不同配置的 LiDAR 传感器：(i) TownClean，其中 LiDAR 扫描使用理想化、无发散的光线模拟；以及 (ii) TownReal，其具有通过 37 条子光线近似的发散光束轮廓。更多细节见补充材料。

Waymo 开放数据集。为了在真实世界数据上进行评估，我们使用了 Waymo 开放数据集 [43]，该数据由一台 64 光束 LiDAR 传感器在 10 Hz 采集。这里我们选择了四个静态场景（序列 ID 见补充材料），并从每个场景中截取一个五秒片段，得到每个场景 50 帧扫描。我们将每 5 帧保留一帧作为测试视图，剩余 40 帧用于训练（Waymo Interp.）

为了在更具挑战性的环境中评估方法，我们提出了基于闭环仿真的新评估协议（Waymo NVS）。该协议涉及对场景的所有扫描进行训练和测试：首先在输入视图上优化以从改变后的轨迹（将传感器移动 [1.5, 1.5, 0.5] 米⁶）合成新视图。然后使用该新视图重新优化方法，在原始视角合成扫描并与原始扫描比较以衡量性能。该表述使我们能够控制任务难度，也可用于评估基于相机的新视图合成方法。

评估指标。为评估距离精度，我们报告四项指标：平均绝对误差和中位绝对误差（MAE[cm]，MedAE[cm]）、双向 Chamfer 距离（CD[cm]）以及 recall@50，表示距离误差低于 50 cm 的光线百分比。我们还测量两返回分割的召回率（Seg. recall）和精确率（Seg. precision）。强度使用平均绝对误差（MAE）评估。对于光线丢弃分割，我们报告召回率和精确率 [%] 及交并比（IoU[%]）。对于点云配准，我们报告旋转误差（RE[°]）和平移误差（TE[cm]）。

基线方法。我们将 NFL 与四种基线进行比较。与我们的任务设置最接近的是 LiDARsim [24]，它基于表面重建和光线-面元投射来合成 LiDAR。我们重新实现了 LiDARsim，并通过引入发散的光束剖面来实现第二回波的合成。此外，我们调整了三种最初为图像合成提出的类 NeRF 方法 i-NGP [30]、DS-NeRF [8] 和 URF [38]，通过修改它们的体渲染来提升距离预测。更多细节见补充材料。

⁶ 请参见补充材料中关于不同传感器位移配置的消融实验。




图 3. Waymo Interp. 数据集上 LiDAR 新视角合成的定性结果。左侧，我们用有无回波对光线进行颜色编码。右侧，LiDAR 强度值按颜色编码为：0 □ □ 0.25。

方法	第一距离范围			第二范围			强度		射线下降		
	召回率@50↑	平均绝对误差↓	中位绝对误差↓	分割召回↑	分割精度↑	召回@50↑	平均绝对误差↓	中位绝对误差↓	MAE ^{1st} ↓	MAE ^{2nd} ↓	召回率↑ 精确率↑ IoU↑
LiDARsim [24]	74.1	105.4	18.5	3.5	11.5	1.0	2258.0	1898.2	0.013	0.018	32.5 85.5 30.5
中心射线	92.8	32.8	5.6	79.8	62.9	61.1	589.1	21.8	0.004	0.009	64.3 81.7 57.1
我们的 发散光束	92.3	36.1	5.7	82.1	55.6	67.4	505.1	13.4	0.004	0.008	65.1 78.0 56.1
真实遮罩	93.2	29.7	5.6	100.0	100.0	79.8	116.0	8.1	0.004	0.011	65.1 78.0 56.1

表 1. 针对 Waymo Interp. 数据集的 LiDAR 新视角合成的全面光线测量评估。

方法	TownClean			TownReal			Waymo interp.			Waymo NVS		
	平均绝对误差↓	中位绝对误差↓	结构相似性↑	平均绝对误差↓	中位绝对误差↓	结构相似性↑	MAE↓	MedAE↓	CD↓	MAE↓	MedAE↓	CD↓
i-NGP [30]	42.2	4.1	17.4	49.8	4.8	19.9	26.4	5.5	11.6	30.4	7.3	15.3
DS-NeRF [8]	41.7	3.9	16.6	48.9	4.4	18.8	28.2	6.3	14.5	30.4	7.2	16.8
URF [38]	43.1	4.2	16.8	52.1	5.1	20.7	28.2	5.4	12.9	41.1	10.0	21.2
LiDARsim [24]	119.6	0.8	23.5	162.8	3.8	27.4	116.3	15.2	27.6	189.2	16.2	36.7
我们的	32.0	2.3	9.0	39.2	3.0	11.5	30.8	5.1	12.1	32.6	5.5	13.2

表 2. 第一个范围的 LiDAR 新视点合成结果。

方法	城市清理			Waymo 插值		
	平均绝对误差↓	中位绝对误差↓	结构相似性↑	平均绝对误差↓	MedAE↓	CD↓
i-NGP [30]	41.0 (-1.2)	4.1 (0.0)	17.6 (0.2)	25.3 (-1.1)	4.5 (-1.0)	10.5 (-1.1)
DS-NeRF [8]	37.4 (-4.2)	3.0 (-0.9)	14.4 (-2.2)	27.4 (-0.8)	5.4 (-1.0)	13.6 (-0.9)
URF [38]	46.4 (3.0)	4.5 (0.3)	18.4 (1.6)	28.3 (0.1)	5.3 (-0.1)	13.1 (0.2)
我们的	32.0 (-2.1)	2.3 (-2.5)	9.0 (-3.9)	30.8 (-2.1)	5.1 (-2.0)	12.1 (-2.3)

表 3. 用于主动感知的体渲染消融研究。




图4. 光束发散建模提高了具有双回波光线的距离精度。这在第一回波（左）和第二回波（右）的距离误差分布改善中可见。

5.2. LiDAR 新视角合成的评估

射线测量。使用 Waymo Interp. 数据集，我们对所有射线测量进行了全面分析，结果列于表 1 和图 3。

本实验仅使用 NFL 和 LiDARsim [24]，因为其他基线仅支持单回波。LiDAR-sim 的表面表示是显式的，既未针对新视角合成进行优化，也未考虑视角相关效应，导致距离预测较差且难以恢复二次回波。相反，NFL 直接优化用于视图合成的神经场并考虑 LiDAR 采集过程的特性，从而显著降低距离误差并在强度与射线丢失概率估计上表现更佳。值得注意的是，为模型配备发散光束表示可提升对双回波射线的第一回波和第二回波的距离估计（参见图 4）。然而，发散光束略微降低了整体的第一回波距离精度，可能是由于双回波掩码估计不精确。使用真实的双回波掩码（GT mask）的结果支持该假设。图 5 展示了 NFL 在新视角合成上的更多定性结果。

第一个距离。所有数据集上第一个回波距离估计结果见表2和图6。TownClean、TownReal和 Waymo NVS 的结果表明，所提出的基于体渲染的 NFL 表达有效地对密度场进行正则化，在困难情况下表现更佳。即便在类似过拟合的更简单设置（Waymo Interp. 数据集）中，我们的方法也取得了有竞争力的表现。相比之下，NeRF 类方法（i-NGP [30]、DS-NeRF [8] 和 URF [38]）在真实新视图评估中表现较差，因其不能考虑主动感测原理。LiDARsim 在几何简单且 LiDAR 测量干净的数据集上取得良好结果，TownClean 和 TownReal 上较低的 MedAE 分数即为证明。




图5. 通过改变传感器仰角 $\theta [^\circ]$ 、位姿 $(x, y, z) [m]$ 和波束数量进行 LiDAR 新视点合成。放大区域按强度值着色。




图6. 首次距离估计的定性比较。存在严重误差 (-100 1100 cm) 的区域已高亮显示。

方法	TownClean			TownReal			Waymo NVS		
	查全@5 $\uparrow$	RE $\downarrow$	TE $\downarrow$	查全@5 $\uparrow$	RE $\downarrow$	TE $\downarrow$	Rec@2 $\uparrow$	RE $\downarrow$	TE $\downarrow$
i-NGP [30]	70.3	0.1	4.2	76.0	0.1	4.2	60.2	0.1	1.9
DS-NeRF [8]	58.3	0.2	5.1	56.2	0.2	5.1	42.3	0.1	2.4
URF [38]	61.5	0.2	5.0	59.9	0.1	4.7	32.1	0.1	2.7
LiDARsim [24]	82.8	0.1	3.4	<u>79.2</u>	0.1	3.4	<u>62.8</u>	0.1	<u>1.8</u>
Ours	<u>80.2</u>	0.1	<u>3.7</u>	85.9	0.1	3.4	71.9	0.1	1.7

表 4. 三个数据集上的点云配准结果。

方法	车辆			背景		
	召回率 $\uparrow$	精确度 $\uparrow$	IoU $\uparrow$	召回率 $\uparrow$	精确度 $\uparrow$	IoU $\uparrow$
i-NGP [30]	<u>93.2</u>	85.9	<u>80.9</u>	98.3	<u>99.2</u>	<u>97.6</u>
DS-NeRF [8]	90.7	87.1	80.2	98.5	98.9	97.4
URF [38]	87.8	81.7	73.7	98.0	98.4	96.5
Lidarsim [24]	90.5	70.5	65.9	94.9	99.0	94.0
我们的	95.9	<u>87.0</u>	83.9	<u>98.3</u>	99.5	97.8

表 5. Waymo NVS 数据集上的语义分割结果。

然而，其显式表示在噪声较多的真实场景中难以处理复杂几何，例如 Waymo 数据集中的植被区域，导致 MedAE 值较高。

体渲染在主动感知中的消融研究。为评估我们提出的针对主动传感器的体渲染表述的有效性，我们在所有基于 NeRF 的基线中将最初为被动感知开发的体渲染 [29] 表述替换为本方法，并在表 3 中报告性能差异。我们的表述在各项设置下均提升了距离精度，且无需任何超参数调优。

5.3. 下游评估新视图

在通过多种指标证明 NFL 在合成高质量 LiDAR 扫描方面的改进能力后，我们继续评估其感知质量，将其作为两个低级感知任务的输入：点云配准 [15] 和语义分割 [45]。




图 7. 合成 WaymoNVS 数据集上的语义分割结果。几何不准确 (-100 到 1100 厘米) 导致错误的语义分割 (射线丢失、车辆、行人、背景)。

点云配准。为评估合成扫描在多大程度上保留局部几何特征，我们对真实 GT LiDAR 扫描和使用不同方法合成的扫描均应用了同一在 Waymo [43] 上预训练的点云配准模型 [14]。

表 4 显示，在几何结构复杂且噪声更高（TownReal 和 Waymo NVS）的数据集上，NFL 在易受 LiDAR 采集过程产生伪影影响的情况下优于基线方法。

语义分割。为探查真实扫描与合成扫描之间可能存在的域差异，我们对两者都应用相同的预训练语义分割模型 [45] 并比较预测结果。表 5 展示了车辆与背景类别的性能。值得注意的是，NFL 在车辆类别上取得了最高召回率，该类别强烈受双重回波和射线丢失影响。示例预测见图 7。

6. 局限与未来工作

我们提出了 NFL，一种基于神经场的方法，用于从新视点合成 LiDAR 扫描。NFL 将体渲染的优势与 LiDAR 获取过程的物理模型相结合，忠实地模拟了束发散、二次回波和射线丢弃等 LiDAR 特性。尽管 NFL 显著优于显式重建再模拟的方法以及其他 NeRF 风格的方法，但仍存在一些我们希望在未来工作中解决的局限性。首先，在 NFL 中，我们努力在遵循 LiDAR 物理原理与引入语义特征与学习之间寻求平衡。尽管我们的表述已较基线显示出改进，但仍有进一步提升的空间。例如，尽管真实世界的 LiDAR 传感器对积分束辐射进行距离检测，我们实际发现对每条射线分别使用基于密度的权重能带来更好的性能。第二回波掩码的预测使我们能够建模二次回波并进一步改善第一回波的估计。然而，正如 oracle 研究所示，改进掩码预测可能带来更多提升。最后，我们的方法基于 NeRF 风格的表示，因此需要针对每个场景进行优化。跨场景泛化和处理动态环境是我们计划在未来工作中解决的关键挑战。

致谢。我们衷心感谢 Benjamin Nau-joks、Steven Butrimas、Tomislav Medić、Yu Han 及 Andreas Wieser 教授就 Li-DAR 模型进行的有益讨论。感谢 Rodrigo Caye Daudt 对图表的反馈。同时感谢 Zvi Greenstein 的组织支持。

参考文献

- [1] Benjamin Attal, Eliot Laidlaw, Aaron Gokaslan, ChangilKim, Christian Richardt, James Tompkin, 和 Matthew O'Toole. TöRF: 用于动态图景视图合成的飞行时间辐照度场。NeurIPS, 2021。
- [2] Jonathan T Barron, Ben Mildenhall, Matthew Tancik, Peter Hedman, Ricardo Martin-Brualla, 和 Pratul P Srinivasan. Mip-NeRF: 用于抗锯齿的多尺度神经辐照度场表示。发表于 CVPR, 2021。
- [3] Jonathan T Barron, Ben Mildenhall, Dor Verbin, Pratul P Srinivasan, 和 Peter Hedman. Mip-NeRF 360: 无界抗锯齿神经辐照度场。发表于 CVPR, 2022。
- [4] Maxim Berman, Amal Rannen Triki, 和 Matthew B Blaschko. Lovász-softmax 损失: 用于优化交并比指标的可处理代理损失在神经网络中的应用。发表于 CVPR, 2018。
- [5] Mario Bijelic, Tobias Gruber, Fahim Mannan, Florian Kraus, Werner Ritter, Klaus Dietmayer, 和 Felix Heide. Seeing through fog without seeing fog: 深度多模态传感器融合用于未见恶劣天气。In CVPR, 2020。
- [6] Tomas Carlsson, Ove Steinvall, 和 Dietmar Letalick. Signature simulation and signal analysis for 3-d laser radar. 技术报告, 瑞典国防研究机构, 2001。
- [7] Shin-Fang Chng, Sameera Ramasinghe, Jamie Sherrah, 和 Simon Lucey. GARF: Gaussian activated radiance fields 用于高保真重建和位姿估计。arXiv preprint arXiv:2204.05735, 2022。
- [8] Kangle Deng, Andrew Liu, Jun-Yan Zhu, 和 Deva Ramanan. Depth-supervised NeRF: 更少视角、更快训练的免费方法。arXiv preprint arXiv:2107.02791, 2021。
- [9] Alexey Dosovitskiy, German Ros, Felipe Codevilla, Antonio Lopez, 和 Vladlen Koltun. CARLA: 一个开源城市驾驶模拟器。In CoRL, 2017。
- [10] Jin Fang, Dingfu Zhou, Feilong Yan, Tongtong Zhao, Feihu Zhang, Yu Ma, Liang Wang, 和 Ruigang Yang. 增强型 LiDAR 自动驾驶模拟器。IEEE RA-L, 5(2):1931-1938, 2020。
- [11] Benoît Guillard, Sai Vemprala, Jayesh K Gupta, Ondrej Miksik, Vibhav Vineet, Pascal Fua, 和 Ashish Kapoor. 学习模拟真实 LiDAR。arXiv preprint arXiv:2209.10986, 2022。
- [12] Martin Hahner, Christos Sakaridis, Mario Bijelic, Felix Heide, Fisher Yu, Dengxin Dai, 和 Luc Van Gool. LiDAR 降雪模拟以提升 3D 目标检测的鲁棒性。arXiv preprint arXiv:2203.15118, 2022。
- [13] Martin Hahner, Christos Sakaridis, Dengxin Dai 和 Luc Van Gool. 用于恶劣天气下三维目标检测的真实 LiDAR 点云雾化模拟。发表于 CVPR, 2021。
- [14] Shengyu Huang, Zan Gojic, Jiahui Huang, Andreas Wieser 和 Konrad Schindler. 通过点云累积的动态三维场景分析。发表于 ECCV, 2022。
- [15] Shengyu Huang, Zan Gojic, Mikhail Usvyatsov, Andreas Wieser 和 Konrad Schindler. Predator: 低重叠三维点云配准。发表于 CVPR, 2021。
- [16] Kasiopy. 《城镇与郊区》。
<https://www.turbosquid.com/3d-models/town-suburb-3d-max/1085661>。最后访问 2023。
- [17] Velat Kilic, Deepti Hegde, Vishwanath Sindagi, A Brinton Cooper, Mark A Foster, 和 Vishal M Patel. Lidar lightscattering augmentation (LISA): 基于物理的 3D 目标检测恶劣天气条件仿真。arXiv 预印本 arXiv:2107.07004, 2021。
- [18] Simon Klenk, Lukas Koestler, Davide Scaramuzza, 和 Daniel Cremers. E-NeRF: 来自移动事件相机的神经辐射场。arXiv 预印本 arXiv:2208.11300, 2022。
- [19] Nathan Koenig and Andrew Howard. Gazebo 的设计与使用范式, 一款开源多机器人仿真器。发表于 IROS, 2004。
- [20] Akhil Kurup and Jeremy Bos. DSOR: 一种可扩展的统计滤波器, 用于去除严重冬季天气中 LiDAR 点云的降雪。arXiv 预印本 arXiv:2109.07078, 2021。
- [21] 林晨莹, 馬偉秋, Antonio Torralba, 及 Si-mon Lucey. BARF: 束调神经辐射场。发表于 ICCV, 2021。
- [22] 刘岭杰, 顾家涛, Kyaw Zaw Lin, 蔡达胜, 及 Christian Theobalt. 神经稀疏体素场。NeurIPS, 2020。
- [23] Andrew Luo, 杜义伦, Michael J. Tarr, Joshua B. Tenenbaum, Antonio Torralba, 及 Chuang Gan. 学习神经声场。arXiv 预印本 arXiv:2204.00628, 2022。
- [24] Sivabalan Manivasagam, 王深龙, Kelvin Wong, 曾文远, Mikita Sazanovich, 谭书翰, 杨斌, 馬偉秋, 及 Raquel Urtasun. LiDARsim: 通过利用现实世界的真实数据进行逼真 LiDAR 仿真。发表于 CVPR, 2020。
- [25] Nelson Max. 直接体绘制的光学模型。IEEE Transactions on Visualization and Computer Graphics, 1(2):99-108, 1995。
- [26] Nelson Max 和 Min Chen. 体渲染积分中的局部与全局照明。技术报告, 劳伦斯利物浦国家实验室, 利物浦, CA, 2005。
- [27] Lars Mescheder, Michael Oechsle, Michael Niemeyer, Sebastian Nowozin 和 Andreas Geiger. 占用网络: 在函数空间中学习 3D 重建。收录于 CVPR, 2019。
- [28] Ben Mildenhall, Peter Hedman, Ricardo Martin-Brualla, Pratul P Srinivasan 和 Jonathan T Barron. 黑暗中的 NeRF: 从有噪声原始图像合成高动态范围视图。收录于 CVPR, 2022。
- [29] Ben Mildenhall, Pratul P Srinivasan, Matthew Tancik, Jonathan T Barron, Ravi Ramamoorthi 和 Ren Ng. NeRF: 将场景表示为用于视图合成的神经辐射场。收录于 ECCV, 2020。
- [30] Thomas Müller, Alex Evans, Christoph Schied, 和 Alexander Keller. 具有多分辨率哈希编码的即时神经图形基元。arXiv 预印本 arXiv:2201.05989, 2022。
- [31] Michael Oechsle, Songyou Peng, 和 Andreas Geiger. UNISURF: 将神经隐式表面与辐射场统一用于多视图重建。发表于 CVPR, 2021。
- [32] Julian Ost, Fahim Mannan, Nils Thuerey, Julian Knodt, 和 Felix Heide. 用于动态场景的神经场景图。发表于 CVPR, 2021。

- [33] Jeong Joon Park, Peter Florence, Julian Straub, Richard Newcombe 和 Steven Lovegrove. DeepSDF: 用于形状表示的连续有符号距离函数学习。发表于 CVPR, 2019.
- [34] Hanspeter Pfister, Matthias Zwicker, Jeroen Van Baar 和 Markus Gross. Surfels: 作为渲染基元的表面元素。发表于 Computer Graphics and Interactive Techniques, 2000.
- [35] Albert Pumarola, Enric Corona, Gerard Pons-Moll 和 Francesc Moreno-Noguer. D-NeRF: 用于动态场景的神经辐射场。发表于 CVPR, 2021.
- [36] Mohamad Qadri, Michael Kaess 和 Ioannis Gkioulekas. 使用声纳成像的神经隐式表面重建。arXiv 预印本 arXiv:2209.08221, 2022.
- [37] Ralph H Raschhofer, Martin Spies 和 Hans Spies. 天气现象对汽车激光雷达系统的影响。Advances in Radio Science, 9:49-60, 2011.
- [38] Konstantinos Rematas, Andrew Liu, Pratul P Srinivasan, Jonathan T Barron, Andrea Tagliasacchi, Thomas Funkhouser, and Vittorio Ferrari. 城市辐射场。arXiv 预印本 arXiv:2111.14643, 2021.
- [39] Barbara Roessle, Jonathan T Barron, Ben Mildenhall, Pratul P Srinivasan, and Matthias Nießner. 来自稀疏输入视图的神经辐射场的稠密深度先验。arXiv 预印本 arXiv:2112.03288, 2021.
- [40] Viktor Rudnev, Mohamed Elgharib, Christian Theobalt, and Vladislav Golyanik. EventNeRF: 来自单色事件相机的神经辐射场。arXiv 预印本 arXiv:2206.11896, 2022.
- [41] Johannes Lutz Schönberger and Jan-Michael Frahm. 结构光束运动 (Structure-from-motion) 再探。载于 CVPR, 2016.
- [42] 施依乾, 廖偉翔, 林文杰, 黃世強, 及王介志. 喷洒激光雷达点云的重建与合成. IEEE RA-L, 7(2):3765-3772, 2022.
- [43] 孫霏, Henrik Kretzschmar, Xerxes Dotiwalla, Aurelien Chouard, Vijaysai Patnaik, Paul Tsui, James Guo, 周尹, Yuning Chai, Benjamin Caine, 等. 自动驾驶感知的可扩展性: Waymo 开放数据集. 载于 CVPR, 2020.
- [44] Andrea Tagliasacchi 与 Ben Mildenhall. NeRF 的体渲染摘要. arXiv 预印本 arXiv:2209.02417, 2022.
- [45] 湯浩天, 劉智堅, 趙晟宇, 林郁俊, 林基, 王漢瑞, 及韓松. 使用稀疏点-体素卷积搜索高效 3D 架構. 载于 ECCV, 2020.
- [46] Michael Waechter, Nils Moehrl, and Michael Goesele. 让世界有色彩! 大规模为 3d 重建生成贴图. In ECCV, 2014.
- [47] Wolfgang Wagner, Andreas Ullrich, Vesna Ducić, Thomas Melzer, and Nick Studnicka. 高斯分解与新型小足迹全波形数字化机载激光雷达的校准. ISPRS Journal of Photogrammetry and Remote Sensing, 60(2):100-112, 2006.
- [48] Peng Wang, Lingjie Liu, Yuan Liu, Christian Theobalt, Taku Komura, and Wenping Wang. NeuS: 通过体渲染学习神经隐式曲面以用于多视图重建. arXiv preprint arXiv:2106.10689, 2021.
- [49] Lukas Winiwarter, Alberto Manuel Esmorís Pena, Hannah Weiser, Katharina Anders, Jorge Martínez Sánchez, Mark Searle, and Bernhard Höfle. 使用 HE-LIOS++ 的虚拟激光扫描: 一种基于光线追踪的地形全波形三维激光扫描仿新的方法. Remote Sensing of Environment, 269:112772, 2022.
- [50] Yiheng Xie, Towaki Takikawa, Shunsuke Saito, Or Litany, Shiqin Yan, Numair Khan, Federico Tombari, James Tompkin, Vincent Sitzmann, and Srinath Sridhar. 可视计算及其延伸中的神经场。发表于 Computer Graphics Forum, 卷 41, 页 641-676. Wiley Online Library, 2022.
- [51] Lior Yariv, Jiatao Gu, Yoni Kasten, and Yaron Lipman. 神经隐式曲面体渲染. NeurIPS, 2021.
- [52] Alex Yu, Sara Fridovich-Keil, Matthew Tancik, Qinhong Chen, Benjamin Recht, and Angjoo Kanazawa. Plenox-els: Radiance fields without neural networks. arXiv preprint arXiv:2112.05131, 2021.
- [53] Kai Zhang, Gernot Riegler, Noah Snavely, and Vladlen Koltun. NeRF++: Analyzing and improving neural radiance fields. arXiv preprint arXiv:2010.07492, 2020.