

WeatherGen：基于Spider Mamba Diffusion的统一多样天气生成器用于LiDAR点云

吴扬¹ 朱云¹ 张凯华² 钱建军¹ 谢晋^{3,4*} 杨健¹

¹ 南京理工大学PCA实验室, 南京, 中国

² 东南大学自动化学院, 南京, 中国

³ 南京大学新型软件技术国家重点实验室, 南京, 中国 ⁴ 南京大学智能科学与技术学院, 苏州, 中国

{wuyang98, zhu.yun, csjqian, csjyang}@njust.edu.cn; zhkhua@gmail.com; csjxie@nju.edu.cn

摘要

3D 场景感知需要大量恶劣天气下的 LiDAR 数据, 但 LiDAR 数据采集成本高, 难以规模化扩展。为此, 提出了一系列 LiDAR 模拟器, 但它们通常只能用单一物理模型模拟单一恶劣天气, 生成数据的保真度有限。本文提出 WeatherGen, 这是第一个统一的多样化天气 LiDAR 数据扩散生成框架, 显著提升了保真度。具体地, 我们首先设计了基于地图的数据生成器, 能够为训练提供大量高质量的多样化天气数据。然后, 我们采用扩散去噪范式构建扩散模型。其中, 我们提出了 spider mamba 生成器以逐步恢复受扰动的多样化天气数据。spider mamba 通过扫描 LiDAR 波束圆或中心射线来建模特征交互, 出色地保持了 LiDAR 数据的物理结构。随后, 在生成器迁移真实世界知识后, 我们设计了潜在特征对齐器。之后, 我们提出了基于对比学习的控制器, 通过语言监督为天气控制信号赋予紧凑的语义信息, 引导扩散模型生成更具判别性的数据。大量评估表明 WeatherGen 的高生成质量。基于 WeatherGen, 我们构建了 mini-weather 数据集, 提升了下游任务在恶劣天气下的性能。代码可在: <https://github.com/wuyang98/weathergen>




图1. (a) 以往基于模拟的方法 [3, 9, 10, 15] 只能为单一天气提供一个不可学习的模拟器。由于光传播的复杂性, 先前的模拟数据普遍存在保真度不足的问题。(b) 我们的方法是首个统一的生成框架。通过学习, 生成的数据具有更高的保真度, 并能在多样天气下更有利于促进下游任务。

尽管经过了广泛的研究且在晴朗天气下表现令人满意, 但由于恶劣天气场景下大规模激光雷达数据集的稀缺, 恶劣天气下的三维场景感知研究较少[1, 16]。

在恶劣天气下, 激光散射和衍射, 导致点噪声和丢失 [29]。这引发了严重的可靠性问题, 限制了现有模型的应用扩展。不幸的是, 在恶劣天气下采集 LiDAR 数据非常耗时、耗力且成本高昂 [1, 9, 10]。一些基于仿真的方法试图通过不可学习的模拟器来改进这一问题 [3, 9, 10, 15]。如图 1 所示, 它们针对单一条件使用单一物理模型。由于传感器参数知识不完整和光传播的复杂性, 这些方法不可避免地遭受域偏移并且与真实世界数据相比保真度较差。

到目前为止, 一个不可避免的问题出现了: 我们能否构建一个统一且高保真、多样天气的 LiDAR 数据生成框架? 为实现此目标, 我们必须解决三大挑战点: (1) 高质量数据生成器。

1. 介绍

随着大规模自动驾驶数据集的出现, 针对检测和轨迹规划等 3D 感知任务出现了大量创新解决方案。

*通信作者。

在多种天气条件下，LiDAR 数据稀缺，无法满足生成模型对高保真训练的需求。(2) 高保真生成器。处于多种天气条件下的 LiDAR 数据具有噪声和点丢失特性，这给生成模型带来重大挑战。(3) 高判别力控制器。生成器缺乏获得具紧凑语义信息的控制信号的有效方式，导致在统一生成框架中生成多样化 LiDAR 数据时出现不匹配。

为此，我们提出了一个统一的 LiDAR 数据生成框架，名为 WeatherGen，能够以低成本生成高保真且高可区分性的 LiDAR 数据。首先，我们采用了先预训练再微调的训练策略。为模型预训练设计了基于地图的数据生成器（MDP），以提供多样化的天气 LiDAR 数据。不同于以往不可学习的模拟器 [3, 9, 10, 15]，MDP 使用可学习的参数将预训练数据对齐到真实世界的分布。预训练之后，我们微调除 MDP 以外的所有参数以进一步提升模型性能。其次，不同于以往破坏 LiDAR 结构信息的数据生成模型 [25, 33, 46, 54]，我们设计了采用 spider mamba 扫描的 spider mamba 生成器

（SMG），更好地适应 LiDAR 成像过程。与在图像补丁上建模的 vision mamba [21, 52] 不同，spider mamba 在波束圆和 LiDAR 点云的中心光线层面建模，有效保留了 LiDAR 数据的结构信息。基于 SMG，我们进一步设计了一个潜在特征对齐器

（LFA），利用真实世界数据共同约束 SMG 的预测，有利于生成器产生更逼真的数据。第三，我们设计了一个基于对比学习的控制器（CLC），利用风格化 LiDAR 数据实现可控生成。与其他控制信号相比，风格化 LiDAR 数据具有更好的特征一致性和可整合性 [43]。CLC 包含一个结合了 CLIP [32] 语言监督的对比学习机制，帮助天气控制信号学习更紧凑且更具判别性的语义信息。综上，我们的贡献如下：

- 我们提出了 WeatherGen，这是首个用于生成多样化天气 LiDAR 数据的统一框架。它包含专门设计的 MDP，以地图到地图的方式生成多样化天气 LiDAR 数据，用于 WeatherGen 的训练。
- 设计了 SMG，能够有效建模 LiDAR 特征交互，并尽可能保持 LiDAR 数据的物理结构。随后提出 LFA 将真实世界的知识迁移到 SMG。
- 提出 CLC 来指导模型更准确地生成，其中应用对比学习以赋予控制信号紧凑的知识。
- 大量实验表明 WeatherGen 在 LiDAR 数据生成质量方面的优越性。

此外，通过 WeatherGen 构建了一个多天气 LiDAR 数据集并应用于 3D 目标检测，结果表明生成的数据可以在恶劣天气条件下提升下游任务表现。

2. Related Work

LiDAR 数据模拟。恶劣天气会显著降低模型性能，在图像任务中，某些方法 [36, 37, 42] 通过模拟缓解该影响。在 LiDAR 任务中，早期方法 DROR [3] 提出了一种 3D 异常点检测算法，用于在恶劣天气下对数据去噪。近期，Seeing Through Fog [1] 提供了一个小规模多样化天气的 LiDAR 数据集，为多样天气 LiDAR 数据的研究与评估奠定了基础。此后，一些基于模拟的方法利用光学传播原理对单一天气条件下的数据进行仿真。FSRL [9] 提出了一种基于光学的雾模拟方法，并使用模拟数据训练 3D 目标检测模型，建立了数据有效性验证的可靠途径。LSS [10] 进一步考虑了湿地面的影响，提出了雪的模拟方法。LISA [15] 为雨、雪和雾设计了具有不同参数的模拟模型，均可辅助在多样天气条件下的 3D 目标检测任务。这些方法只能为单一天气设计单一模型，且由于光学传播的复杂性，模拟数据的真实感并不高。

LiDAR 数据生成。与面向物体和室内的点云相比，LiDAR 点云通常更稀疏且噪声更多 [12, 31, 49, 53]，常用做法是将 LiDAR 数据投影到距离图以获得更紧凑、规则的形式。该操作不会导致数据丢失 [22, 23]。在此基础上，提出了若干研究。Nakashima 等人 [24, 26] 设计了一种 drop 方法以辅助 GAN 的训练，实现了多样尺寸的生成。LiDARGen [54] 能模拟 LiDAR 中的射线丢失，并验证了使用扩散模型进行 LiDAR 数据生成的可行性。UltraLiDAR [47] 学习了用于 LiDAR 生成与补全的紧凑 3D 表示。近期工作 LiDM [33]、R2DM [25] 和 Text2LiDAR [46] 基于去噪扩散概率模型（DDPM）设计了更成熟的框架，显著提升了性能。迄今为止，尚无关于生成多样天气下 LiDAR 数据的系统性研究。

状态空间模型。状态空间模型（SSM）被广泛应用于各学科。其核心思想是通过潜在状态将输入与输出序列连接起来[48]。结构化 SSM [6] 优化了 SSM 的计算开销，催生了一系列新的 SSM 框架 [7, 8, 27, 40]。Mamba [5] 通过引入选择机制进一步改进了 SSM，使其能够有选择地传递或遗忘信息，从而带来性能飞跃。




图2. WeatherGen 的流程。它有三个核心组件。一个 MDP 用于生成更接近真实世界的高质量训练数据；一个 SMG 以符合 LiDAR 成像过程的方式对去噪特征建模。SMG 之后是一个 LFA，用于将真实世界数据的知识迁移到生成器。一个由天气编码器和 CLIP 文本编码器组成的 CLC，用于通过对比学习生成更紧凑且具判别力的控制信号。

自那以后，大量研究者尝试将 mamba 的成功转移到计算机视觉领域 [18, 21, 52]。Mamba 在生成领域也取得了显著成果 [14, 28, 50]，受益于其出色的去噪能力。一项鲁棒性研究 [4] 表明 mamba 比 transformer 具有更好的鲁棒性和泛化能力。将 mamba 用于 LiDAR 数据生成值得探索。

3. 方法

我们首先在第 3.1 节介绍 DDPM 和 SSM 的基础知识。然后在第 3.2 节说明获取多样天气 LiDAR 数据用于训练的方法。随后在第 3.3 节介绍专为 LiDAR 数据设计的生成器。接着在第 3.4 节介绍获取判别性控制信号的方法，在第 3.5 节介绍损失函数。

3.1. DDPM 与 SSM 的预备知识

我们提供了对 DDPM 和 SSM 的基础性介绍，图 2 展示了我们方法的训练过程。训练完成后，我们仅使用 CLC 和 SMG 进行推理以生成数据。

DDPM 的目标是学习一个分布，该过程分三部分进行 [11]。(1) 扩散过程：我们持续加入噪声直至接近纯噪声。单步加噪过程为： $\mathcal{R}_w^t = \sqrt{\alpha_t} \mathcal{R}_w^{t-1} + \sqrt{1 - \alpha_t} \epsilon_1$ ，其中 $\alpha_t = 1 - \beta_t$ ， β_t 为噪声权重， ϵ_1 为加入的噪声。通过迭代推导 [11]，我们可以得到 $\mathcal{R}_w^t = \sqrt{\alpha_t} \mathcal{R}_w^0 + \sqrt{1 - \alpha_t} \epsilon_t$ ，其中 $\bar{\alpha}_t = \alpha_t \cdot \alpha_{t-1} \dots \alpha_1$ ，且 $\epsilon_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。上述过程可进一步表示为： $q(\mathcal{R}_w^t | \mathcal{R}_w^0) = \mathcal{N}(\mathcal{R}_w^t; \sqrt{\bar{\alpha}_t} \mathcal{R}_w^0, (1 - \bar{\alpha}_t) \mathbf{I})$ 。(2) 推断过程：这是从高斯噪声中恢复数据的过程。

$$q(\mathcal{R}_w^{t-1} | \mathcal{R}_w^t, \mathcal{R}_w^0) = \mathcal{N}(\mathcal{R}_w^{t-1}; \tilde{\mu}_t(\mathcal{R}_w^t, \mathcal{R}_w^0), \tilde{\beta}_t \mathbf{I}), \quad (1)$$

其中， $\tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \cdot \beta_t$ ， $\tilde{\mu}_t(\mathcal{R}_w^t, \mathcal{R}_w^0) = \frac{1}{\sqrt{\alpha_t}} (\mathcal{R}_w^t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \hat{\epsilon}_t)$ ，并且 $\hat{\epsilon}_t$ 由我们的 SMG 预测。(3) 训练过程：训练目标是使用去噪网络来估计等式 1 中的噪声 $\hat{\epsilon}_t$ 。

连续系统启发了 SSM。通过隐藏状态 $h(s) \in \mathbb{R}^N$ [6, 52]，SSM 可以映射一维序列 $x(s) \in \mathbb{R} \rightarrow y(s) \in \mathbb{R}$ 。这些模型擅长用一组一阶微分方程表示系统，捕捉系统状态变量的动力学： $h'(s) = \mathbf{A}h(s) + \mathbf{B}x(s)$ ， $y(s) = \mathbf{C}h(s)$ ，其中 $h'(s)$ 是状态向量 $h(s)$ 的时间导数。 $\mathbf{A} \in \mathbb{R}^{N \times N}$ 是演化参数， $\mathbf{B} \in \mathbb{R}^{N \times 1}$ 和 $\mathbf{C} \in \mathbb{R}^{1 \times N}$ 指投影参数，用于衡量 $h(s)$ 、 $x(s)$ 与 $y(s)$ 之间的关系。为将其转换为离散形式，常用的方法是利用零阶保持，其定义为： $\bar{\mathbf{A}} = \exp(\Delta \mathbf{A})$ ， $\bar{\mathbf{B}} = (\Delta \mathbf{A})^{(-1)} (\exp(\Delta \mathbf{A}) - \mathbf{I}) \cdot \Delta \mathbf{B}$ ， Δ 是步长参数， $\bar{\mathbf{A}}$ 和 $\bar{\mathbf{B}}$ 是离散参数。使用 Δ 的离散化版本可重写为：

$$h_k = \bar{\mathbf{A}} h_{k-1} + \bar{\mathbf{B}} x_k, \quad y_k = \mathbf{C} h_k. \quad (2)$$

在这些之后，我们可以通过全局卷积获得输出， $\bar{\mathbf{K}} = (\mathbf{C}\bar{\mathbf{B}}, \mathbf{C}\bar{\mathbf{A}}\bar{\mathbf{B}}, \dots, \mathbf{C}\bar{\mathbf{A}}^{m-1}\bar{\mathbf{B}})$ ， $\mathbf{y} = \mathbf{x} * \bar{\mathbf{K}}$ ，其中 m 是输入序列的长度 $\mathbf{x}$ ，而 $\bar{\mathbf{K}}$ 是大小为 m 的结构化卷积核。

3.2. 基于映射的数据生成器

在本部分，我们旨在通过 MDP 获取多样的天气 LiDAR 数据以用于训练。在恶劣天气下，点云常表现出额外的噪声点或点丢失 [29]。不同天气状况有其特性。雪：雪花会引起不规则反射，导致随机噪声点的出现并丢失部分点 [39]。雾：雾中的液滴密集，导致所有激光被衰减，这在远距离尤为明显。




图 3. (a) 蜘蛛眼镰蛇沿 LiDAR 光束圆和中央射线扫描模型特征，出色地保持了 LiDAR 的物理结构；(b) 卷积只能在局部建模特征；(c) 自注意力无序地连接所有点，破坏了 LiDAR 数据的物理属性。

激光在雾中因不规则折射产生大量噪声[9]。雨：水滴也会导致噪点减少。由于地面变湿，远处的点可能因大角度反射而丢失[15]。这些导致激光传播过程异常复杂，难以用固定参数穷尽建模。

与之前不可学习的模拟器 [3, 9, 10, 15] 不同，我们额外提供可学习的掩码，使 MDP 具备从数据中学习的能力 [29]。具体地，给定晴天下具有坐标和强度的 LiDAR 数据 $\mathbf{P}_c^{\text{real}} \in \mathbb{R}^4 (p^x, p^y, p^z, p^i)$ ，我们首先将其转换为距离图 $\mathcal{R}_c$ 。通过一种图到图的方法，我们可以生成多种天气下的数据：

$$\begin{aligned} \mathcal{R}_w &= \text{MDP}(\mathcal{R}_c) \\ &= \begin{cases} \mathcal{R}_c \odot \text{BDF}(\mathcal{M}_{e1}, r_w) + \mathcal{R}_n + \mathcal{M}_d, d > r_w, \\ \mathcal{R}_c \odot \text{BDF}(\mathcal{M}_{e2}, r_w) + \mathcal{R}_n + \mathcal{M}_d, d < r_w, \end{cases} \quad (3) \end{aligned}$$

其中 $w \in [\text{snow}, \text{fog}, \text{rain}]$, $\mathcal{M}_e$ 为由0和1组成的掩码，用以模拟不同距离处激光的衰减。当点满足 $d > r_w$ 时，对应位置置为0，否则置为1， d 为距离值，可从 $\mathbf{P}$ 获得。此部分确保生成的数据具有最基本的多天气特性，从而实现可靠的初始化。 $\mathcal{M}_d$ 为通过等式9学习得到的掩码，用以自适应调整参数。此部分保证我们的MDP能够动态更新并自适应对齐真实分布。 $\mathcal{R}_n$ 为与 $r_w \cdot r_w$ 相关的随机噪声， $r_w \cdot r_w$ 是一个可调参数，用以反映恶劣天气的严重程度，值越小表示越恶劣，更多设置见附录。BDF 是用于随机丢弃的伯努利分布函数[34]，可模拟恶劣天气下更嘈杂的LiDAR数据，其丢弃率与 r_w 相关。

3.3. 蜘蛛蛟发生器

如第2节所述，量程图被证明是处理 LiDAR 数据的一种成功形式。

然而，以往在量程图上利用卷积和自注意力的方法 [25, 33, 46, 54]，并未充分适应 LiDAR 数据的环状结构。相比之下，在 SMG 中，我们设计了一种基于蛟的方式，沿 LiDAR 光束的圆周或中心射线建模，这恰好对应量程图的行或列，并且与 LiDAR 的成像方式更为一致。如图3所示，这一过程类似蜘蛛在网上捕猎，因此我们称之为“蜘蛛蛟”。

与在图像任务中基于补丁建模特征的成功 mamba 方法 [14, 21, 52] 不同，我们的 spider mamba 为 LiDAR 数据做了更合适的设计。我们遵循 UltraLight VM-UNet [44] 的做法，不再在补丁级别进行扫描，而是在点级别进行。深度图的行列分别对应 LiDAR 点云的光束圆和中心光线。深度图的补丁对应一簇点云，在稀疏的室外场景中，可能丧失 LiDAR 数据的几何意义。图 3 还比较了 spider mamba、卷积 (Conv) 和自注意力 (SA)。spider mamba 沿 LiDAR 的光束圆和中心光线建模，而 Conv 在局部建模，SA 则连接所有点，破坏了 LiDAR 的物理属性并稀释了大量光束圆信息。

如图2所示，我们设计的SMG采用U形去噪结构，编码器和解码器均由卷积块与spider mambablocks组成。更详细的结构示意图可见附录。具体地，我们先用卷积将 $\mathcal{R}_w^t$ 映射为潜在特征，并进一步展开成像素序列以得到 $\mathcal{F} \in \mathbb{R}^{J \times C}$ ，其中 J 为像素数。继承 UltraLight VM-UNet [44]，为节省计算开销，我们按通道将 $\mathcal{F}$ 分解为 $\mathcal{F}_i \in \mathbb{R}^{J \times (C/4)}, i \in (1, 4)$ 。然后，我们将每个 $\mathcal{F}_i$ 线性投影为大小为 D 的嵌入，表达为：

$$\mathbf{T}_i^0 = [\mathcal{F}_i^1 \mathbf{W}; \mathcal{F}_i^2 \mathbf{W}, \dots, \mathcal{F}_i^j \mathbf{W}], \quad (4)$$

其中 $\mathcal{F}_i^j$ 是第 j 个补丁的 $\mathcal{F}_i$, $\mathbf{W} \in \mathbb{R}^{(C/4) \times D}$ ，是可学习的投影矩阵。然后，我们将序列 $\mathbf{T}_i^{l-1}$ 送入第 l 层 mamba，得到输出 $\mathbf{T}_i^l$ 。关于 mamba 的逐步过程详见 vision mamba [52]。一旦得到输出序列 $\mathbf{T}_i^L$ ，我们对其归一化并送入多层感知机 (MLP) 头以得到最终预测 $\hat{\mathcal{F}}_i$ 。每个 $\hat{\mathcal{F}}_i$ 被拼接以形成最终潜在特征 $\hat{\mathcal{F}}$ 。通过去噪网络的解码器后，我们可以在对应时间步得到预测噪声 $\hat{\epsilon}_t$ 。我们使用均方误差损失函数来监督学习过程：

$$\begin{aligned} \mathcal{L}_{\text{SMG}} &= \mathcal{L}_{\text{MSE}}(\epsilon_t, \hat{\epsilon}_t) \\ &= \mathbb{E}_{t \sim U(0, T), \epsilon \sim \mathcal{N}(0, 1)} [\|\epsilon_t - \text{SMG}(\mathcal{R}_w^t, \mathbf{t}, \mathbf{w}; \boldsymbol{\theta})\|^2], \quad (5) \end{aligned}$$

其中 θ 是 SMG 的可学习参数， $\mathbf{t}$ 是时间步嵌入， $\mathbf{w}$ 是来自 CLC.Latent Feature Aligner 的控制信号。为利用真实世界数据驱动模型学习更真实的数据分布，我们进一步将 LFA 设计为紧随 SMG 的后续步骤以传递真实世界知识。我们利用预测噪声 $\hat{\epsilon}_t$ 进行一步生成 $\mathcal{R}_w^{\text{gen}} = \frac{1}{\sqrt{\alpha_t}} (\mathcal{R}_w^t - \sqrt{1 - \alpha_t} \hat{\epsilon}_t)$ 。一步生成可能无法完全恢复测距图，但其质量足以提供天气特征信息 [20, 41]。

然后，我们引入真实世界的多样化 LiDAR 数据 $\mathcal{R}_w^{\text{real}}$ ，并通过线性投影将 $\mathcal{R}_w^{\text{real}}$ 与 $\mathcal{R}_w^{\text{gen}}$ 投射到统一的潜在空间 $\mathcal{N}(\mu, \sigma)$ 以建模其天气模式。我们随机采样天气潜在变量 $\mathbf{z}^s \sim \mathcal{N}(\mu^s, \sigma^s)$, $s \in [\text{gen}, \text{real}]$ ，并使用 Kullback-Leibler 散度将它们对齐：

$$\begin{aligned} \mathcal{L}_{LFA} &= \mathcal{L}_{KL}(P_{\text{real}}(\mathbf{z}^{\text{real}} | \mathcal{R}_w^{\text{real}}) || Q_{\text{gen}}(\mathbf{z}^{\text{gen}} | \mathcal{R}_w^{\text{gen}})) \\ &= \sum P_{\text{real}}(\mathbf{z}^{\text{real}} | \mathcal{R}_w^{\text{real}}) \log \frac{P_{\text{real}}(\mathbf{z}^{\text{real}} | \mathcal{R}_w^{\text{real}})}{Q_{\text{gen}}(\mathbf{z}^{\text{gen}} | \mathcal{R}_w^{\text{gen}})}. \end{aligned} \quad (6)$$

$\mathbf{z}^s$ 是从一对 $(\mu^s, \sigma^s) : \mathbf{z}^s = \sigma^s \odot \eta + \mu^s$ 重参数化得到的， $\eta \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 是随机噪声。潜在空间的每个位置代表一种潜在的多样化数据，可将小规模真实世界数据的天气分布边界拓展[45, 51]，并增强迁移真实世界知识的效果。

3.4. 基于对比学习的控制器

为了实现统一的多样化天气生成框架，学习具有紧凑语义知识的控制信号也很重要，它可以指导模型在不同天气条件下具有判别性地生成。

为此，我们设计了一个基于对比学习的控制器，其中包含一个天气编码器 $\mathcal{W}$ 和一个已冻结的 CLIP 文本编码器 [32] $\mathcal{C}$ 。天气嵌入 $\mathbf{w}$ 与语义嵌入 $\mathbf{c}$ 通过以下方式获得：

$$\mathbf{w} = \mathcal{W}(\mathcal{R}_w^0), \mathbf{c}_i = \mathcal{C}(\text{"Weather text prompts"}). \quad (7)$$

我们预设了四个天气提示并将其输入 $\mathcal{C}$ 以获得用于知识锚定的相应文本嵌入 $\mathbf{c}_i, i = 1, \dots, 4$ 。此处， $\mathbf{c}_j$ 对应于与 $\mathcal{R}_w^0$ 天气状态一致的嵌入。该过程本质上是利用对比学习 [13] 概念的信息瓶颈过程：

$$\mathcal{L}_{CLC} = \text{IB}(\varphi) = I(\mathbf{w}, \mathbf{c}_{i \neq j}; \varphi) - \beta \cdot I(\mathbf{w}, \mathbf{c}_{i=j}; \varphi), \quad (8)$$

其中 I 表示互信息， $\mathbf{w}$ 表示压缩的天气嵌入， $\mathbf{c}$ 表示具有高判别能力的目标嵌入， β 是权重参数，经验上设为 0.2, φ 是 CLC 的可学习参数。

我们的优化目标是最小化 $I(\mathbf{w}, \mathbf{c}_{i \neq j}; \varphi)$ ，尽量减少 $\mathbf{w}$ 与无关天气嵌入 $\mathbf{c}_{i \neq j}$ 的冗余，确保与 $\mathcal{R}_w$ 相关的最关键信息得以保留。同时，最大化 $I(\mathbf{w}, \mathbf{c}_{i=j}; \varphi)$ 以帮助 $\mathbf{w}$ 实现更紧凑的语义表征，从而引导扩散网络生成信息更具辨识性的数据。 $\mathbf{w}$ 将与时间步 $\mathbf{t}$ 拼接，并沿通道维度与 SMG 中的特征融合。

3.5. 损失函数

用于预训练我们模型的最终损失函数为：

$$\mathcal{L} = \mathcal{L}_{SMG} + \mathcal{L}_{LFA} + \mathcal{L}_{CLC}, \quad (9)$$

其中 $\mathcal{L}_{SMG}$, $\mathcal{L}_{LFA}$ 和 $\mathcal{L}_{CLC}$ 分别来源于等式 5、等式 6 和等式 8。预训练完成后，我们使用真实世界数据和相同的损失函数对模型进行微调 (FT)，更新除 MDP 之外的所有参数。整个训练过程结束后，我们使用等式 1 生成数据。

4. 实验

4.1. 数据集与评估指标

我们在 KITTI-360 [19] (主要为晴朗天气) 和包含雪、雨、雾等恶劣天气的 Seeing Through Fog [1] 上评估模型。KITTI-360 [19] 拥有 50,348 帧用于训练与验证，及 26,367 帧用于测试 [25, 54]。Seeing Through Fog 的恶劣天气数据量 (每种天气约 200 到 3,000 帧) [1] 不足以支持训练，因此我们将其划分用于微调和测试。WeatherGen 可支持无条件和有条件生成。对无条件生成，移除 MDP 与 CLC。参照 LiDARGen [54]、R2DM [25] 与 Text2LiDAR [46]，我们在三种数据格式下计算 10,000 个生成样本与真实样本间的分布差异：距阵 (range map)、点云与鸟瞰图 (BEV)。距阵格式使用预训练的 RangeNet [23] 计算 Frechet 距阵距离 (FRD) [54]。点云格式使用预训练的 PointNet [30] 获得 Frechet 点云距离 (FPD)。BEV 格式使用 Jensen-Shannon 散度 (JSD) 和最小匹配距离 (MMD) 来衡量 BEV 占据网格边缘分布之间的差异。对于天气条件生成，我们计算来自 Seeing Through Fog 不同测试划分的 200 个生成样本与真实样本间的分布差异，所用指标与无条件生成相同。WeatherGen 还可执行 LiDAR 点云稠密化任务，更多实验细节见附录。




图4. 在 KITTI-360 [19] 数据集上与竞争生成方法的视觉比较。结果证明 WeatherGen 在生成清晰物体轮廓和小物体方面具有更强能力。

表1. 在 KITTI-360 [19] 数据集上与其他最新方法的定量无条件生成比较。

方法	点云	分布图	BEV 占据栅格	
	FPD ↓	FRD ↓	MMD $\times 10^{-4}$ ↓	JSD $\times 10^{-2}$ ↓
LiDARGAN [2]	-	3003.8	30.60	-
LiDARVAE [2]	-	2261.5	10.00	16.10
ProjectedGAN [38]	-	2117.2	3.47	8.50
LiDARGen [54]	90.29	579.39	7.39	7.38
LiDM [33]	34.36	334.55	1.07	4.77
R2DM [25]	6.24	149.66	1.91	3.05
Text2LiDAR [46]	4.81	164.16	0.49	2.01
WeatherGen	6.15	138.62	0.39	1.99

表2. 在 Seeing Through Fog [1] 数据集上与其他最先进仿真方法的定量比较。

方法& 天气	点云	深度图	鸟瞰占用栅格	
	FPD ↓	FRD $\times 10^1$ ↓	MMD $\times 10^{-4}$ ↓	JSD $\times 10^{-1}$ ↓
LSS(雪) [10]	106.37	142.17	3.59	2.11
FSRL(雾) [9]	319.32	210.51	8.56	3.69
LISA(雨) [15]	301.11	145.23	4.30	3.23
WeatherGen(雪)	59.28	124.17	1.71	0.77
WeatherGen(雾)	314.14	196.89	8.08	2.66
WeatherGen(雨)	86.40	127.06	4.15	0.93

4.2. 无条件 LiDAR 数据生成

通过移除天气控制信号 $\mathbf{w}$ ，WeatherGen 可作为无条件生成模型运行，专门生成晴朗天气条件下的数据。我们将方法与基于 GAN [2, 38]、VAE [2] 及扩散模型 [25, 33, 46, 54] 的方法进行了比较。其中，LiDM [33] 无法生成点云强度，因此在测试其 FRD 时我们以深度替代强度。如表 1 所示，WeatherGen 达到了令人印象深刻的性能。与 Text2LiDAR 那种庞大的 transformer 结构相比，WeatherGen 速度更快、参数更少，详见图 8。

图4展示了与真实世界数据[19]、R2DM 和 Text2LiDAR 的视觉对比。可以看到 R2DM 和 Text2LiDAR 生成的物体噪声更多，且大量点云穿透物体。相比之下，WeatherGen 的生成更符合 LiDAR 的物理特性。

例如，物体轮廓更清晰、内容更完整。这些事实证明我们的模型能生成分布更真实、差异性更好的 LiDAR 数据。更多无条件生成和去噪步骤的可视化见附录。

4.3. 有天气条件的 LiDAR 数据生成

通过统一框架在多种天气条件下生成 LiDAR 点云是 WeatherGen 的核心、独特且开创性的特征。在 SeeingThrough Fog 数据集[1]上，我们使用不同划分进行了测试：浓雾、暴雪和降雨，这些是最具代表性的天气数据[1]。

表 2 列出了 WeatherGen 与常见基于仿真的方法[9, 10, 15] 的定量对比。WeatherGen 生成的数据显著优于以往的仿真方法。这是因为与不可学习的模拟器相比，WeatherGen 能从真实世界数据中学习更复杂的光学传播过程，从而提高生成数据的逼真度。

图 5 显示了生成的与真实世界 LiDAR 数据的对比。我们可以看到，生成数据在成像特性和天气属性上与真实数据高度一致。关于定制化生成的更多分析见附录。第 4.5 节进一步介绍了我们生成结果的价值。

4.4. 消融研究

我们在 Seeing Through Fog 的“heavy snow”测试集上做了消融研究。当不使用 MDP 时，表示未采用可学习的 $\mathcal{M}_d$ 。当不使用 SMG 时，我们用 U-Net [25] 替代之。如果不采用 CLC，则只部署天气编码器 $\mathcal{W}$ 。从表 3 可见，不使用 MDP 会导致性能下降。在恶劣天气下，引入可学习的仿真参数能更好地迁移真实世界的知识，提升生成质量。图 6 进一步表明，当完全不使用真实世界数据时，生成数据的偏差更大。不使用 SMG 时，性能会以不同程度下降。




图 5. 在 Seeing Through Fog [1] 数据集上，真实世界多样天气 LiDAR 数据与生成结果的可视化对比。

这是因为雪景中的 LiDAR 数据噪声更多且存在点丢失。网络受到严重干扰，无法在没有我们 SMG 设计的情况下很好地保持 LiDAR 线的物理特性。当不使用 CLC 时，控制信号的质量下降，导致目标天气与生成天气不匹配，从而使所有指标下降。LFA 对我们的模型也有帮助。WeatherGen 可以利用 LFA 直接与真实世界数据的分布对齐，这是基于仿真的方法无法实现的关键信息。使用 "*" 表示在 Seeing Through Fog 上用小规模多样天气数据进行训练，由于数据量不足，性能不佳。这些结果证明了我们先预训练再微调的策略以及各个设计的有效性。

4.5. 促进 3D 目标检测

为验证生成数据的实际价值，我们首先使用生成的数据构建一个小型天气数据集，为每种天气类型提供 256 帧数据，并利用 LabelCloud [35] 对其中的对象进行标注。图 7 展示了小型天气数据集的详细构成。

然后，我们使用 mini-weather 训练 3D 目标检测模型，并将结果与基于仿真的数据增强方法 [3, 9, 10, 15] 进行对比。其中，DROR [3]、FSRL [9] 和 LSS [10] 可为雪天和雾天提供数据增强，而 LISA [15] 则可为雨雪雾天提供数据增强。为确保公平，我们采用经典的 PointPillars [17] 作为检测器，在 Seeing Through Fog [1] 的“train clear”训练集上训练，并在“dense fog”、“heavy snowfall”和“rain”测试集上测试。使用 mini-weather 时，我们将 train clear (3,469 帧) 中随机的 256 帧替换为来自 mini-weather 的对应天气数据。这意味着只有 7.4% 的训练数据来自 mini-weather。图 4、5、6 显示了三种天气条件下的数据有效性测试结果。

表 3. 在 Seeing Through Fog [1] 数据集的 snow heavy 测试集上的消融研究。

关键设计					点云	距离图	BEV 占据格	
MDP	SMG	CLC	LFA	FT	FPD ↓	FRD ↓	MMD $\times 10^{-4}$	JSD $\times 10^{-1}$ ↓
✓	✓	✓	-	-	244.61	1922.07	8.99	1.55
✓	✓	✓	-	-	221.73	1887.51	7.85	1.59
-	✓	✓	✓	-	238.16	1945.36	9.22	1.78
✓	✓	✓	-	*	148.25	1747.14	4.93	1.05
✓	✓	-	✓	✓	66.35	1423.69	2.28	0.94
✓	-	✓	✓	✓	79.45	1436.89	3.09	1.13
-	✓	✓	✓	✓	84.58	1501.79	3.41	1.85
✓	✓	✓	-	✓	77.39	1300.13	1.68	1.31
✓	✓	✓	✓	✓	59.28	1241.66	1.71	0.77




图6. 实际数据的 t-SNE 图 [1]、通过不含 $\mathcal{M}_d$ 的 MDP 和 FT 模拟的雪天气数据，以及生成的雪天气数据。与模拟数据相比，我们生成的数据与真实世界分布更为一致。

在21项指标中，我们方法生成的数据在18项中表现最佳。从表格最后一行可见，仅使用我们数据的 7.4%，相比完全不使用我们的数据，便能显著提升检测器性能。

值得一提的是，收集并构建一个千帧级别的恶劣天气 LiDAR 数据集所需时间以年计 [1]。相比之下，构建迷你天气 LiDAR 数据集仅需几天。

表4. 在 SeeingThrough Fog [1] 数据集密雾测试分割上与基于仿真方法的比较。

方法	密雾场景†				汽车 AP@.5IoU	循环车 AP@.25IoU	行人 AP@.25IoU
	0-80m	0-30m	30-50m	50-80m			
DROR [3]	12.25	24.52	9.60	1.22	33.42	23.89	30.73
LISA [15]	15.66	33.01	8.96	1.90	38.21	19.75	31.39
FSRL [9]	14.56	31.85	7.89	1.34	35.94	21.20	31.25
LSS [10]	17.43	36.77	9.93	1.52	41.03	22.74	30.82
无	16.29	34.82	8.05	1.44	35.98	20.30	28.84
WeatherGen	17.68	36.90	11.18	1.92	42.14	23.99	34.57
已改进	+1.39	+2.08	+3.13	+0.48	+6.15	+3.69	+5.73

表5. 在 SeeingThrough Fog [1] 数据集的暴雪测试分割上，与基于仿真的方法比较。

方法	暴雪场景†				汽车 AP@.5IoU	自行车 AP@.25IoU	行人 AP@.25IoU
	0-80m	0-30m	30-50m	50-80m			
DROR [3]	29.41	54.01	21.97	5.10	69.22	29.31	37.30
LISA [15]	28.22	49.96	25.01	5.32	72.23	36.28	38.07
FSRL [9]	30.03	51.92	23.95	5.54	71.62	33.23	37.38
LSS [10]	29.97	52.24	25.15	5.26	73.92	34.09	37.66
无	28.07	50.64	23.13	5.08	72.10	31.74	37.32
天气生成	30.98	53.68	25.98	5.33	72.48	39.51	38.66
改进	+2.91	+3.04	+2.85	+0.25	+0.38	+7.77	+1.34

表6. 在 SeeingThrough Fog [1] 数据集的雨天测试划分上，与基于仿真的方法比较。

方法	雨情景†				车辆 AP@.5IoU	周期 AP @.25IoU	Ped. AP@.25IoU
	0-80m	0-30m	30-50m	50-80m			
LISA [15]	34.65	56.19	25.21	13.09	73.49	34.27	36.63
无	33.69	52.04	24.69	13.01	74.02	34.02	35.01
WeatherGen	36.00	56.56	26.96	18.57	75.32	35.54	37.94
改进	+2.31	+4.52	+2.27	+5.56	+1.30	+1.52	+2.93

这表明 WeatherGen 在提高无人系统在恶劣天气条件下的安全性方面具有重要价值。

4.6. 复杂度分析

图8展示了我们的方法与无条件生成方法[25, 46, 54]在模型参数与生成速度上的对比。与R2DM相比，我们的方法在参数仅增加 0.6M 的情况下实现了7.38%的性能提升。与作为该领域首个采用扩散技术的方法LiDARGen相比，WeatherGen展现出全面优势：性能提升76.07%，生成速度提升91.16%。我们还对基于Transformer的Text2LiDAR进行了效率比较，结果显示Transformer结构在性能和生成速度上存在劣势。以上说明WeatherGen在速度、参数与性能的平衡上达到了目前的领先水平。




图7. 构建的迷你天气数据集的组成。每种天气包含256帧，图中显示了不同对象在其中出现的频率。




图8. 模型效率比较。WeatherGen 在参数数量较少的情况下平衡了性能。

5. 结论

在本文中，我们提出了 WeatherGen，这是首个用于生成多样化天气下 LiDAR 数据的统一框架。在 WeatherGen 中，我们设计了一个 MDP，以地图到地图的方式生成多样天气的 LiDAR 数据，提供了高保真和高多样性的充足训练数据。在扩散网络中，设计了 SMG 与 spider mamba 一起恢复多样的天气数据。通过以每束光束逐束扫描 LiDAR，SMG 能出色地保持 LiDAR 数据的物理结构。随后提出的 LFA 将真实世界的知识嵌入模型。随后，我们设计了 CLC，通过对比学习为控制信号配备紧凑的语义知识。CLC 使生成器能够生成更具判别性的 LiDAR 数据。大量实验和所提出的迷你天气数据集证明了其生成质量的优越性及其在恶劣天气条件下对下游任务的巨大价值。

致谢。 本工作由国家重点研发计划（编号 2024YFC3015801）资助，及国家自然科学基金（项目编号62361166670、62276144、62276141、62176124和U24A20330）资助。

参考文献

- [1] Mario Bijelic, Tobias Gruber, Fahim Mannan, Florian Kraus, Werner Ritter, Klaus Dietmayer 和 Felix Heide. 透过雾而不“看见”雾：在未知恶劣天气下的深度多模态传感器融合。载于 IEEE/CVF 计算机视觉与模式识别会议论文集，页码 11682-11692，2020。1、2、5、6、7、8
- [2] Lucas Caccia, Herke Van Hoof, Aaron Courville 和 Joelle Pineau. 激光雷达数据的深度生成建模。载于 2019 IEEE/RSJ 国际智能机器人与系统会议 (IROS)，页码 5034-5040。IEEE，2019。6
- [3] Nicholas Charron, Stephen Phillips 和 Steven L Waslander. 被降雪污染的激光雷达点云去噪。载于 2018 第十五届计算机与机器人视觉会议 (CRV)，页码 254-261。IEEE，2018。1、2、4、7、8
- [4] 杜成斌, 李燕曦, 许昌. 理解视觉状态空间模型在图像分类中的鲁棒性. arXiv preprint arXiv:2403.10935, 2024. 3
- [5] Albert Gu 和 Tri Dao. Mamba: 使用选择性状态空间的线性时间序列建模. arXiv preprint arXiv:2312.00752, 2023. 2
- [6] Albert Gu, Karan Goel, 和 Christopher Ré. 使用结构化状态空间高效建模长序列. arXiv preprint arXiv:2111.00396, 2021. 2, 3
- [7] Albert Gu, Karan Goel, Ankit Gupta, 和 Christopher Ré. 关于对角状态空间模型的参数化与初始化. Advances in Neural Information Processing Systems, 35:35971-35983, 2022. 2
- [8] Ankit Gupta, Albert Gu, 和 Jonathan Berant. 对角状态空间与结构化状态空间一样有效. Advances in Neural Information Processing Systems, 35:22982-22994, 2022. 2
- [9] Martin Hahner, Christos Sakaridis, Dengxin Dai, and Luc Van Gool. 在真实激光雷达点云上模拟雾以用于 3d 在恶劣天气下的目标检测。收录于 IEEE/CVF 国际计算机视觉大会论文集，页码 15283-15292，2021。1, 2, 4, 6, 7, 8
- [10] Martin Hahner, Christos Sakaridis, Mario Bijelic, Felix Heide, Fisher Yu, Dengxin Dai, and Luc Van Gool. 激光雷达降雪模拟以增强 3D 目标检测的鲁棒性。收录于 IEEE/CVF 计算机视觉与模式识别会议论文集，页码 16364-16374，2022。1, 2, 4, 6, 7, 8
- [11] Jonathan Ho, Ajay Jain, and Pieter Abbeel. 去噪扩散概率模型。发表于 Advances in Neural Information Processing Systems, 33:6840-6851, 2020。3
- [12] 钱江湖, 志敏张, 和 伟胡. Rangeldm: 快速现实感激光雷达点云生成. 载于欧洲计算机视觉会议, 页 115-135. Springer, 2024.2
- [13] 世哲胡, 正政姿, 晓强颜, 和 阳东叶. 信息瓶颈综述. IEEE 模式分析与机器智能汇刊, 2024. 5
- [14] 文森特陶胡, 斯特凡安德里亚斯鲍曼, 明贵, 奥尔加格列班科娃, 平川马, 约翰内斯费舍尔, 和 比约恩奥默. Zigma: 之字形曼巴扩散模型. arXiv 预印本 arXiv:2403.13802, 2024. 3, 4
- [15] Velat Kilic, Deepti Hegde, Vishwanath Sindagi, A Brinton Cooper, Mark A Foster, and Vishal M Patel. Lidar lightscattering augmentation (lisa): Physics-based simulation of adverse weather conditions for 3d object detection. arXiv preprint arXiv:2107.07004, 2021. 1, 2, 4, 6, 7, 8
- [16] Lingdong Kong, Youquan Liu, Xin Li, Runnan Chen, Wen-wei Zhang, Jiawei Ren, Liang Pan, Kai Chen, and Ziwei Liu. Robo3d: Towards robust and reliable 3d perception against corruptions. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 19994-20006, 2023.1
- [17] Alex H Lang, Sourabh Vora, Holger Caesar, Luning Zhou, Jiong Yang, and Oscar Beijbom. Pointpillars: Fast encoders for object detection from point clouds. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pages 12697-12705, 2019. 7
- [18] 梁定康, 周欣, 王欣宇, 朱兴魁, 徐威, 邹志康, 叶晓晴, 以及白翔. Point-mamba: 用于点云分析的简单状态空间模型. arXiv 预印本 arXiv:2402.10739, 2024. 3
- [19] 廖依依, 解军, 以及安德烈亚斯·盖格. Kitti-360: 用于二维和三维城市场景理解的新数据集与基准. IEEE 模式分析与机器智能汇刊, 45(3):3292-3310, 2022. 5, 6
- [20] 刘兴超, 张希文, 马健筑, 彭剑, 等. InstafLOW: 一步即可实现高质量基于扩散的文本到图像生成. 收录于第十二届国际学习表征大会, 2023. 5
- [21] 刘越, 田云杰, 赵宇中, 余洪天, 谢凌曦, 王耀伟, 叶奇翔, 及刘云帆. Vmamba: Visual state space model. arXiv preprint arXiv:2401.10166, 2024. 2, 3, 4
- [22] Gregory P Meyer, Ankit Laddha, Eric Kee, Carlos Vallespi-Gonzalez, 和 Carl K Wellington. Lasernet: 一种高效的概率性自动驾驶三维目标检测器. 载于 Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 页 12677-12686, 2019. 2
- [23] Andres Milioto, Ignacio Vizzo, Jens Behley, 和 Cyrill Stachniss. Rangenet++: 快速且精确的激光雷达语义分割. 载于 2019 IEEE/RSJ international conference on intelligent robots and systems (IROS), 页 4213-4220. IEEE, 2019. 2, 5
- [24] 中岛和人(Kazuto Nakashima) 和 藏爪亮(Ryo Kurazume). 学习 droppoints 用于激光雷达扫描合成. 载于 2021 年 IEEE/RSJ 国际智能机器人与系统会议 (IROS)，第 222–229 页。IEEE，2021。2
- [25] 中岛和人(Kazuto Nakashima) 和 藏爪亮(Ryo Kurazume). 基于去噪扩散概率模型的激光雷达数据合成. arXiv 预印本 arXiv:2309.09256，2023。2, 4, 5, 6, 8
- [26] 中岛和人(Kazuto Nakashima)、岩下由美(Yumi Iwashita) 和 藏爪亮(Ryo Kurazume). 用于学习三维激光雷达数据场景先验的生成式距离成像. 载于 IEEE/CVF 冬季计算机视觉应用会议论文集，第 1256–1266 页，2023。2
- [27] Antonio Orvieto, Samuel L. Smith, Albert Gu, Anushan Fernando, Çağlar Gülçehre, Razvan Pascanu 和 Soham De.

- 为长序列复活循环神经网络。载于国际机器学习会议, 页码 26670-26698。PMLR, 2023。2
- [28] 大岛优太, 田口翔平, 铃木雅弘, 松尾雄高。SSM 遇上视频扩散模型: 具有结构化状态空间的高效视频生成。arXiv 预印本 arXiv:2403.07711, 2024。3
- [29] 朴俊成, 金灵民, 沈贤中。重新考虑针对恶劣天气下鲁棒激光雷达语义分割的数据增强。arXiv 预印本 arXiv:2407.02286, 2024。1, 3, 4
- [30] 查尔斯·R·齐, 苏浩, 莫凯春, 莱昂尼达斯·J·圭巴斯。PointNet: 用于 3 d 分类和分割的点集深度学习。载于IEEE 计算机视觉与模式识别会议论文集, 页码652-660, 2017。5
- [31] 曲文涛, 邵远天, 孟令武, 黄晓水, 和 肖亮。一种用于点云上采样的条件去噪扩散概率模型。载于 IEEE/CVF 计算机视觉与模式识别会议论文集, 页面 20786-20795, 2024。2
- [32] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, 等。从自然语言监督中学习可迁移的视觉模型。载于国际机器学习大会论文集, 页面 8748-8763。PMLR, 2021。2, 5
- [33] 冉浩熙, Vitor Guizilini, 和 王岳。面向真实场景生成的激光雷达扩散模型。载于 IEEE/CVF 计算机视觉与模式识别会议论文集, 页面 14738-14748, 2024。2, 4, 6
- [34] Branko Ristic, Ba-Tuong Vo, Ba-Ngu Vo, 和 Alfonso Farina。Bernoulli 滤波器教程: 理论、实现与应用。IEEE Transactions on Signal Processing, 61(13):3406-3430, 2013。4
- [35] Christoph Sager, Patrick Zschech, 和 Niklas Kühl。labelcloud: 一个用于点云中 3D 目标检测的轻量级领域无关标注工具。arXiv 预印本 arXiv:2103.04970, 2021。7
- [36] Christos Sakaridis, Dengxin Dai, Simon Hecker, 和 Luc Van Gool。使用合成与真实数据进行模型自适应以实现语义雾天场景理解。载于欧洲计算机视觉大会 (ECCV) 论文集, 页 687-704, 2018。2
- [37] Christos Sakaridis, Dengxin Dai, 和 Luc Van Gool。使用合成数据的语义雾天场景理解。International Journal of Computer Vision, 126:973-992, 2018。2
- [38] Axel Sauer, Kashyap Chitta, Jens Müller, and Andreas Geiger。Projected gans converge faster. Advances in Neural Information Processing Systems, 34:17480-17492, 2021。6
- [39] Alvari Seppänen, Risto Ojala, and Kari Tammi。4denoisenet: Adverse weather denoising from adjacent point clouds. IEEE Robotics and Automation Letters, 8(1):456-463, 2022。3
- [40] Jimmy TH Smith, Andrew Warrington, and Scott W Linder-man。Simplified state space layers for sequence modeling。arXiv preprint arXiv:2208.04933, 2022。2
- [41] Yang Song, Prafulla Dhariwal, Mark Chen, and Ilya Sutskever。Consistency models. In Proceedings of the 40th International Conference on Machine Learning, pages 32211-32252, 2023。5
- [42] Maxime Tremblay, Shirsendu Sukanta Halder, Raoul De Charette, 和 Jean-François Lalonde。用于评估和平衡对恶劣天气鲁棒性的雨渲染。国际计算机视觉杂志, 129:341-360, 2021。2
- [43] Xin Wang, Hong Chen, Zihao Wu, Wenwu Zhu, 等。去缠结表示学习。IEEE 模式分析与机器智能汇刊, 2024。2
- [44] Renkai Wu, Yinghao Liu, Pengchen Liang, 和 Qing Chang。超轻 vm-unet: 并行视觉 mamba 显著减少皮肤病变分割参数。arXiv 预印本 arXiv:2403.20035, 2024。4
- [45] Yang Wu, Huihui Song, Bo Liu, Kaihua Zhang, 和 Dong Liu。具有不确定性感知组交换掩码的共同显著性目标检测。在 IEEE/CVF 计算机视觉与模式识别会议论文集中, 页 19639-19648, 2023。5
- [46] Yang Wu, Kaihua Zhang, Jianjun Qian, Jin Xie, 和 Jian Yang。Text2lidar: 一种基于等矩形变换器的文本引导激光雷达点云生成方法。载于欧洲计算机视觉大会, 页码 291-310。Springer, 2024。2, 4, 5, 6, 8
- [47] Yuwen Xiong, Wei-Chiu Ma, Jingkan Wang, 和 Raquel Urtasun。学习用于激光雷达补全与生成的紧凑表示。载于 IEEE/CVF 计算机视觉与模式识别会议论文集, 页码 1074-1083, 2023。2
- [48] Rui Xu, Shu Yang, Yihui Wang, Bo Du, 和 Hao Chen。关于视觉 Mamba 的综述: 模型、应用与挑战。arXiv 预印本 arXiv:2404.18861, 2024。2
- [49] 颜志强, 林远凯, 王坤, 郑宇鹏, 王钰斐, 张振宇, 李俊, 与 杨剑。面向几何感知深度补全的三视角分解。收录于 IEEE/CVF 计算机视觉与模式识别会议论文集, 页码 4874-4884, 2024。2
- [50] 叶子 与 陈天翔。P-mamba: 将 peronamalik 扩散与 mamba 结合以实现高效儿科超声心动图左室分割。arXiv 预印本 arXiv:2402.08506, 2024。3
- [51] 张晶, 樊登平, 戴玉超, Saeed Anwar, Fatemeh Saleh, Sadegh Aliakbarian, 与 Nick Barnes。不确定性启发的 RGB-D 显著性检测。IEEE 模式分析与机器智能汇刊, 44(9):5761-5779, 2021。5
- [52] 梁辉竹, 廖本成, 张倩, 王新龙, 刘文宇, 与 王兴刚。Vision mamba: 一种基于双向状态空间模型的高效视觉表征学习。arXiv 预印本 arXiv:2401.09417, 2024。2, 3, 4
- [53] 朱云, 惠乐, 沈雅琦, 与 谢进。Spgroup3d: 用于室内3D目标检测的超点分组网络。载于 AAAI 人工智能大会论文集, 页 7811-7819, 2024。2
- [54] 弗拉斯·兹里亚诺夫, 朱曦跃, 与 王申龙。学习生成逼真的激光雷达点云。载于欧洲计算机视觉大会, 页 17-35。Springer, 2022。2, 4, 5, 6, 8