



SPIRAL: 语义感知的渐进式 LiDAR 场景生成与理解

Dekai Zhu ^{1,4,*} Yixuan Hu ^{1,*} Youquan Liu ² Dongyue Lu ³ Lingdong Kong ³ Slobodan Ilic ¹

¹ 慕尼黑工业大学 ² 复旦大学 ³ 新加坡国立大学 ⁴ 慕尼黑机器学习中心




WorldBench 团队

利用近期的扩散模型，基于 LiDAR 的大规模 3D 场景生成已取得显著进展。尽管近期的体素方法能同时生成几何结构和语义标签，现有的视距图（range-view）方法仅能生成无标签的 LiDAR 场景。依赖预训练分割模型来预测语义图常导致跨模态一致性欠佳。为了解决此限制并保留视距表示的优势（如计算效率和简化的网络设计），我们提出 Spiral，一种新颖的视距 LiDAR 扩散模型，可同时生成深度图、反射率图和语义图。此外，我们引入了新的语义感知指标来评估生成的带标签视距数据的质量。在 SemanticKITTI 和 nuScenes 数据集上的实验证明，Spiral 在参数量最小的情况下实现了最先进的性能，优于将生成与分割模型结合的两步方法。我们还验证了 Spiral 生成的视距图可有效用于下游分割训练的合成数据增强，从而显著减少 LiDAR 数据的标注工作量。

⑥ 项目页面: <https://dekai21.github.io/SPIRAL>

• GitHub 仓库: <https://github.com/worldbench/SPIRAL>



• 车 • bicy • moto • truc • o.veh • ped • b.list • m.list • road • park • walk • o.gro • build • fenc • veg • trun • terr • pole • sign

图1 展示了由 Spiral 联合生成的 LiDAR 场景及其语义标签，可见高几何保真度、语义与几何一致性，以及对机器人和自动驾驶丰富的下游任务利用价值。

1 介绍

通过在各种环境光照下提供准确的距离测量，LiDAR 在机器人与自动驾驶的场景理解与导航中发挥着关键作用 [1-8]。然而，收集与标注大规模 LiDAR 数据集既昂贵又耗时 [9-13]。为解决此问题，近期研究愈发聚焦于使用去噪扩散概率模型 (DDPMs) [14] 进行 LiDAR 生成建模，旨在开发能够生成无限 LiDAR 场景的工具 [15-21]。

现有生成方法可分为基于体素的方法 [19, 22-24] 和基于视域的方法 [15-18]。前者将三维空间划分为规则体积网格（即体素），并通过三维卷积网络捕捉详细的几何结构 [25]。然而，它们通常面临高内存消耗和计算开销的问题 [26]。基于视域的方法则将 LiDAR 点云使用传感器的方位角和仰角投影到二维圆柱像面上 [15-17, 27]。这导致深度和反射率的紧凑二维表示，从而可以通过二维卷积网络高效处理 [28, 29]。这些方法在内存和计算上显著更高效 [30, 31]。

在本工作中，我们旨在解决现有基于视域的生成方法中的两个限制：

1. 虽然诸如 LiDARGen [15] 和 R2DM [18] 等最新模型能生成高保真 LiDAR 场景，但它们的输出仅限于深度和反射率图像，未生成语义标签。


现有评估从三种视角（视距图像、笛卡尔点云和 BEV 投影）为每个场景提取全局特征，以评估生成场景与真实场景的分布相似性。然而，这些评估方法均未考虑语义标签。

针对第一个局限，一个直接的解决方案是采用两步流水线：先使用生成模型生成无标签 LiDAR 场景 [15, 16, 18]，然后用预训练的分割模型（如 RangeNet++ [32]）预测相应语义标签，如图 2 (a) 所示。但该方法通常表现不佳，原因有两点：（1）生成模型与分割模型独立训练，阻碍了两任务间共享表征并降低训练效率；（2）语义图作为事后预测，无法在生成过程中提供条件引导，导致语义与深度、反射率等其他模态间的一致性受限。


因此，我们提出了一种新颖的语义感知视距图 LiDAR 扩散模型，名为 Spiral，如图 2 (b) 所示，具有以下关键特性：

- 语义感知生成：我们的框架旨在从高斯噪声联合生成深度、反射率和语义图，不同于缺乏语义感知且需要单独分割模型来获取语义标签的现有模型。

(a) 传统两步流水线



(b) SPIRAL：统一的一步与闭环框架



(c) 定量比较




图2 (a) 两步法：现有视域（range-view）LiDAR生成模型通常只生成深度与反射率图，还需额外的预训练分割模型来预测语义标签。(b) Spiral：相反，Spiral 联合生成深度、反射率与语义图。一个闭环推理机制（虚线箭头所示）进一步提升跨模态一致性。(c) 结果：在相关方法中，Spiral 以最小参数量（61M）实现了最先进的性能。

- 逐步语义预测：在每个去噪步骤，Spiral 输出一个中间语义图，该图通过指数移动平均 (EMA) 聚合以抑制噪声并生成稳定的每像素置信度分数。EMA 轨迹既作为最终语义输出，也作为闭环推理的基础。
- 闭环推理：一旦预测置信度超过阈值，语义地图就被反馈回模型作为条件，用以指导深度和反射率的生成。通过在有条件与无条件步骤之间交替，Spiral 实现了几何与语义的联合精炼，从而增强了跨模态一致性。

对于第二个限制，我们将三种度量都扩展为具有语义感知，能够对生成的 LiDAR 场景的几何、物理和语义质量进行全面评估。(1) 对于依赖预训练模型（如 RangeNet++ [32] 和 PointNet [33]）在视域图像和笛卡尔点云视角上提取基于学习的全局特征的评估，我们整合了来自 LiDM [16] 的语义图条件模块（最初用于语义到 LiDAR 的生成）来编码语义标签。编码后的语义特征随后与原始全局特征拼接，形成语义感知的全局特征。(2) 对于在俯视图（BEV）投影视角上使用基于规则的全局特征（通过在 xy 平面上的二维直方图产生）的评估，我们对每个语义类别分别计算二维直方图，然后将它们拼接成统一的语义感知直方图表示。

在 SemanticKITTI [34] 和 nuScenes [35] 数据集上的实验证明，Spiral 在有标签的 LiDAR 场景生成上以最小的参数量达到了最先进的性能，如图 1 与图 2 (c) 所示。此外，我们展示了 Spiral 生成的样本可作为合成数据有效用于下游训练，这对需要大规模训练数据的自动驾驶任务尤为重要 [36-38]。总之，本工作的主要贡献如下：

- 我们提出了一种新颖的、达到最先进水平的语义感知视域（range-view）LiDAR 扩散模型 Spiral，该模型联合生成深度与反射率图像以及语义标签。
- 我们引入了统一的评估指标，全面评估生成的有标签 LiDAR 场景在几何、物理与语义方面的质量。
- 我们展示了生成的 LiDAR 场景在训练分割模型时的有效性，凸显了 Spiral 在生成式数据增强方面的潜力。

2 相关工作

从深度图生成 LiDAR。LiDARGen [15] 首创基于扩散的 LiDAR 生成，通过学习在距离视图图像空间建模对数似然梯度的得分函数 [39]。在此基础上，LiDM [16] 推进了条件生成建模，支持从多种输入模态合成。R2DM [18] 通过扩散模型增强了无条件 LiDAR 场景生成，并对提升生成保真度的关键组件进行了深入分析。RangeLDM [17] 优化了计算效率以实现实时生成，而 Text2LiDAR [40] 开发了用于语义控制的文本引导生成能力。然而，对于语义分割应用，这些方法仍需额外专用模型，增加了计算开销。

来自体素网格的 LiDAR 生成。若干研究探讨在笛卡尔空间生成完整 LiDAR 场景，旨在保持几何重建精度 [19, 22-24, 41-46]。SemCity [22] 利用三平面表示通过将 3D 空间投影到三个位正交 2D 平面来建模户外 LiDAR 场景。XCube [23] 使用分层体素潜变量扩散模型生成大规模场景。[19] 提出使用潜变量 DDPM 生成语义 LiDAR 场景，而无需依赖中间图像投影或粗到细多分辨率建模。DynamicCity [24] 采用 VAE [47] 模型和基于 DiT 的 [48] DDPM 生成大规模、高质量的动态 4D 场景。

LiDAR 语义分割。针对不同表示提出了多种 LiDAR 场景分割方法，包括视距图（range-view）[28-30, 32, 49, 50]、BEV [51]、体素 [25, 52-54] 与多视图融合 [36, 55-62]。作为代表性的视距图分割模型，RangeNet++ [32] 提供了一个用于 LiDAR 语义分割的实时且高效的解决方案。




图3 (a) 无条件步骤：Spiral 以带噪 LiDAR 场景 x_t 为输入，预测语义地图 $\hat{y}_t$ 与噪声 $\hat{\epsilon}_t$ ，此时开关 $\mathcal{A}$ 关闭且 $\mathcal{B}$ 打开。(b) 有条件步骤：Spiral 在给定语义地图 y 条件下预测 $\hat{\epsilon}_t$ ，此时 $\mathcal{A}$ 打开且 $\mathcal{B}$ 关闭。(c) 在推理期间，Spiral 以无条件步骤开始于开环模式。一旦由渐进滤波器平滑后的预测语义地图达到高置信度，Spiral 切换到交替进行无条件与有条件步骤的闭环模式，以增强跨模态一致性。

Cylinder3D [52] 提出了一种柱状表示，特别适用于户外场景，解决了 LiDAR 点云的不规则性和稀疏性问题。SPVCNN [63] 作为一种点-体素融合框架，将点云与体素表示结合以利用其互补优势，从而提升分割性能。

3 方法

3.1 用于视图图 (range-view) LiDAR 生成的扩散模型预备知识

扩散模型[14]通过模拟随机过程生成数据。从一个真实样本 $x_0 \sim q(x_0)$ 开始，前向过程在 T 步中逐步加入高斯噪声，使得最终样本近似标准正态分布，即 $q(x_T) \approx \mathcal{N}(0, I)$ 。对于视角深度图的 LiDAR 生成，样本表示为 $x_0 \in \mathbb{R}^{H \times W \times d}$ ，其中 H 和 W 表示深度图的高度与宽度， d 表示模态数。在 LiDARGen [15] 和 R2DM [18] 中 $d = 2$ 因为同时生成深度与反射率图像，而在 LiDM [16] 中 $d = 1$ ，因为它只生成深度图像。模型 ϵ_θ ，参数为 θ ，通过最小化以下目标来训练以预测在中间步骤 $t \in \{1, \dots, T\}$ 加入的噪声 ϵ ：

$$\mathcal{L} = \mathbb{E}_{t, x_0, \epsilon} \left[\|\epsilon_\theta(x_t, t, a) - \epsilon\|_2^2 \right], \quad (1)$$

其中 $\epsilon \sim \mathcal{N}(0, I)$ 是在前向过程中加入的随机噪声， a 表示条件输入，例如文本描述或语义图 $y \in \mathbb{R}^{H \times W \times C}$ ， C 表示类别数。推理时，模型从一个随机噪声样本 $x_T \sim \mathcal{N}(0, I)$ 开始，迭代去噪以生成一个新样本 x'_0 。在每一步，会在 x_t 上额外加入噪声 $\eta \sim \mathcal{N}(0, I)$ 以增加最终结果的多样性。在基础 DDPM 之上，通过引入连续时间变量 $t \in [0, 1]$ 提出了一种更灵活的扩散框架 [64]，它使得在推理时能灵活控制采样步数，从而在生成速度和质量之间进行权衡。

3.2 螺旋：语义感知的渐进式 LiDAR 生成

如前所述，尽管现有的视距图 (range-view) LiDAR 生成模型 [15, 16, 18] 展现了令人印象深刻的性能，但它们仅限于生成深度和反射率模态。LiDM [16] 可以在语义地图条件下生成 LiDAR 场景，但它要求事先提供语义地图。或者，先生成 LiDAR 场景再预测语义标签的两步流水线存在训练效率低下且跨模态一致性受限的问题。受到扩散模型可作为分类与分割等多种任务强大表征学习器这一见解的启发 [65-68]，我们提出了一种新颖的语义感知渐进式视距图 LiDAR 扩散模型，称为 Spiral，如图 2(b) 所示，以解决这些限制。Spiral 包含三项主要创新：

完整的语义感知。Spiral 的语义感知包含两个方面：(1) 除了生成深度图和反射率图，Spiral 还预测相应的语义图；(2) Spiral 支持在给定语义图引导下有条件生成深度图和反射率图。它在两种步骤之间交替进行：无条件与有条件。为控制两者之间的切换，我们引入了两个控制开关， $\mathcal{A}$ 和 $\mathcal{B}$ ，如图 3 所示。开关 $\mathcal{A}$ 与 $\mathcal{B}$ 遵循异或 (XOR) 关系。它们的开/关状态如下：

$$\begin{cases} \mathcal{A} = 0, \mathcal{B} = 1; & \text{for the unconditional step,} \\ \mathcal{A} = 1, \mathcal{B} = 0; & \text{for the conditional step,} \end{cases} \quad (2)$$

其中 0 表示关闭状态，1 表示开启状态。在训练期间，在无条件步骤中，具有可学习参数的 Spiral θ, ϵ_θ 同时预测语义图 $\hat{y}_t$ 和噪声 $\hat{\epsilon}_t$ ，基于带噪 LiDAR 场景 x_t ，即

$$\hat{\epsilon}_t, \hat{y}_t \leftarrow \epsilon_\theta(x_t), \quad (3)$$

以及相应的训练损失 $\mathcal{L}_u$ 计算如下：

$$\mathcal{L}_u = \mathcal{L}_{\text{noise}} + \mathcal{L}_{\text{sem}} = \text{MSE}(\epsilon_t, \hat{\epsilon}_t) + H(\hat{y}_t, y), \quad (4)$$

其中 $\text{MSE}(\cdot)$ 表示均方误差， $H(\cdot)$ 表示交叉熵损失。在条件步骤中， ϵ_θ 将语义图 y 作为条件输入并仅预测去噪残差：

$$\hat{\epsilon}_t \leftarrow \epsilon_\theta(x_t, y), \quad (5)$$

训练损失 $\mathcal{L}_c$ 计算如下：

$$\mathcal{L}_c = \mathcal{L}_{\text{noise}} = \text{MSE}(\epsilon_t, \hat{\epsilon}_t). \quad (6)$$

我们使用随机变量 $\psi \sim \text{Uniform}(0, 1)$ 在每个训练步骤中决定模式。因此，

$$\mathcal{L} = \mathcal{L}_c \cdot \mathbb{I}(\psi \leq \psi_c) + \mathcal{L}_u \cdot \mathbb{I}(\psi > \psi_c), \quad (7)$$

其中 $\mathbb{I}(\cdot)$ 为指示函数， ψ_c 为训练条件步骤的比例。经验上，我们将 ψ_c 设为 0.5 以平衡这两种步骤的训练。


进阶语义预测。在推理过程中，Spiral 在每个无条件步预测语义图 $\hat{y}_t$ 。为缓解扩散过程的固有随机性并提高稳定性，我们对预测结果应用指数移动平均 (EMA) 以获得平滑的预测 $\bar{y} \in \mathbb{R}^{H \times W \times C}$ 。EMA 初始化为 $\bar{y}_T = \hat{y}_T$ ，并递归更新，直到 $t = T - 1$ 为 0，具体为：

$$\bar{y}_t \leftarrow \alpha \cdot \hat{y}_t + (1 - \alpha) \cdot \bar{y}_{t+1}, \quad (8)$$

其中 α 表示 EMA 的平滑系数。在推理结束时，Spiral 不仅输出深度和反射率图像，还输出最终平滑的语义预测 $\bar{y}_0$ 。

闭环推理。两步方法存在跨模态一致性有限的问题，因为事后预测的语义图无法引导先前的生成。为了解决此问题，Spiral 引入了一种新颖的闭环推理机制，在推理过程中将语义预测 $\bar{y}_t$ 持续反馈为模型的条件输入。值得注意的是，为了缓解可能存在于 $\bar{y}_t$ 中会降低生成质量的伪影，Spiral 采用基于置信度的过滤策略来选择可靠的预测作为条件。具体而言，在从步骤 $t = T$ 到 0 的推理过程中，Spiral 默认以开环模式开始。然而，如果 $\bar{y}_t$ 中超过比例 δ 的像素的置信度分数超过 δ ，则切换到闭环模式，如图 3(c) 所示。例如，将 δ 设为 0.8 要求 $\bar{y}_t$ 中超过 80% 的像素的预测置信度分数超过 0.8。一旦满足该条件，Spiral 即在无条件步和有条件步之间交替循环：(1) 在无条件步中，Spiral 同时预测 $\hat{\epsilon}_t$ 和 $\hat{y}_t$ 。(2) 在有条件步中，Spiral 在以 $\bar{y}_t$ 为条件的情况下预测 $\hat{\epsilon}_t$ ，从而最终提高 $\bar{y}_0$ 与 x_0 之间的一致性。关于闭环模式的优势及置信度阈值 δ 影响的定量研究在实验部分给出。

(a) 基于视距范围的度量



(b) 基于俯视图的度量




图4 (a) 基于视距的语义感知特征 f^s 通过将 RangeNet++ [34] 编码器从 LiDAR 场景 x 提取的特征与 LiDM [16] 语义编码器从语义地图 y 提取的特征串联构建。(b) 基于鸟瞰(BEV)的语义感知特征 h^s 通过聚合逐类别的二维直方图构建。

总体架构。Spiral 采用 4 层 Efficient U-Net [64] 作为主干网络，并遵循默认连续 DDPM 框架。Spiral 的输入为扰动后的深度和反射率图像 x_t ，以及作为 RGB 图像编码的语义图 y 。值得注意的是，在无条件的步骤中，语义图会被全零填充以禁用语义引导。在输出端，Spiral 使用两个分支分别预测扩散残差 $\hat{\epsilon}_t$ 和分割标签 $\hat{y}_t$ 。每个输出分支由一个 2D 卷积层后接一个顺序 MLP 层组成。关于 Spiral 架构的更多细节见附录。

3.3 面向语义的度量以改进更好的 LiDAR 生成评估

近期基于视域图的 LiDAR 研究 [15, 16, 18] 从三方面评估生成场景的质量：视域图、笛卡尔点云和鸟瞰图（BEV）投影。(1) 对于基于视域图和点云的评估，它们依赖预训练模型如 RangeNet++ [32] 和 PointNet [33] 提取每个场景的基于学习的特征 f 。从真实集和生成集提取的特征随后用于计算 Fréchet Range Distance (FRD) [15]、Fréchet Point Cloud Distance (FPD) [18] 和最大平均差异 (MMD)，以量化两集合之间的分布相似性。(2) 对于基于 BEV 的评估，使用 xy 平面的二维直方图为每个场景计算基于规则的描述 h 。这些从真实集和生成集中提取的特征随后用于计算 MMD 和 Jensen-Shannon 发散 (JSD)。然而，这些评估方法均未考虑语义标签。由于生成场景的语义标签“真实标注”不可得，诸如 mIoU 的标准度量无法直接应用。因此，我们提出基于语义感知特征 f^s 和 h^s 评估生成的带标签 LiDAR 场景的质量。

基于学习的语义特征。对于基于视域的评估，按照 LiDARGen [15]，我们使用 RangeNet++ [32] 作为编码器 $\mathcal{E}$ 。此外，我们提出使用语义地图编码器 $\mathcal{G}$ 来提取语义潜在特征。对于 $\mathcal{G}$ ，我们采用 LiDM [16] 中的语义条件模块。给定带有语义标签的 LiDAR 场景 $x y$ ，语义感知特征 f^s 通过将这两种特征串联得到，如图 4(a) 所示：

$$f^s \leftarrow \mathcal{E}(x) \oplus \mathcal{G}(y). \quad (9)$$

从真实和生成集中提取的特征 $\{f^s\}_r$ 和 $\{f^s\}_g$ 最终用于计算语义感知的 Fréchet 范围距离 (S-FRD) 和语义感知最大均值差异 (S-MMD)，将 FRD 和 MMD 扩展为包含语义信息。对于基于笛卡尔的评估，我们采用相同的过程来提取 f^s ，唯一的区别是将 RangeNet++ [32] 替换为 PointNet [33]。类似地， $\{f^s\}_r$ 和 $\{f^s\}_g$ 用于计算语义感知的 Fréchet 点云距离 (S-FPD) 和 S-MMD。

基于规则的语义特征。文献[15, 18]中的基于 BEV 的评估将 xy 平面划分为一个由 $B \times B$ 个格子组成的网格，并计算作为规则化特征的二维 BEV 直方图 $h \in \mathbb{R}^{B \times B}$ 。然而，不同类别点的空间分布显然不同。

例如，“道路”点通常集中在沿 x 轴的区域附近，而“建筑”和“植被”点则往往出现在更远处。场景中不同类别点的分布包含丰富的语义信息，并有效反映场景的整体语义结构。因此，我们提出对每个类别单独计算直方图并将它们聚合为语义感知直方图 $h^s \in \mathbb{R}^{C \times B \times B}$ ，如图4(b)所示。只有当生成场景与真实场景在点分布和语义分类上都相似时，它们的直方图才可能相似。来自真实集和生成集的提取描述 $\{h^s\}_r$ 与 $\{h^s\}_g$ 用于计算语义感知 JSD (S-JSD) 和 S-MMD。

4 实验

4.1 实验设置

数据集。我们在 SemanticKITTI [34] 和 nuScenes [35] 数据集上进行了广泛的实验研究，并遵循它们的官方数据划分。SemanticKITTI 包含 23k 个带有 19 个语义类别的标注激光雷达场景，而 nuScenes 包含 28k 个带有 16 个语义类别的激光雷达场景。在预处理过程中，激光雷达场景分别投影到空间分辨率为 64×1024 和 32×1024 的距离视图图像中。为了进一步评估鲁棒性，我们还在 Robo3D [53] 的雾天和湿地面子集上评估基于螺旋的生成式数据增强，这些子集模拟了分布外测试的恶劣天气条件。

关于训练与推理的细节。我们在配备 48 GB 显存的 NVIDIA A6000 GPU 上使用 Adam 优化器 [69] 以学习率 $1e-4$ 训练 Spiral 共 300k 步，训练过程耗时 ~ 36 小时。对于两步基线方法中的生成模型（包括 LiDARGen [15]、LiDM [16] 和 R2DM [18]），我们遵循官方的训练设置。为生成的未标注 LiDAR 场景获取语义标签时，我们使用带官方预训练权重的 RangeNet++ [32] 和 UniSeg 代码库中提供的对 SPVCNN [63] 的改进实现 SPVCNN++ [57]。在推理时，函数评估次数 (NFE) [18] 即采样步数，Spiral 与 R2DM 均设为 256 步。为公平比较，我们也对 LiDM 使用 DDIM [70] 采样方法并设为 256 步。LiDARGen 将去噪过程建模为 232 个噪声等级并默认每级 5 步，导致总 NFE 为 1160。按照 [15]，我们每种方法生成 10k 个样本以供评估。

评估指标。我们遵循此前工作 [15, 18] 从距离图、点云和鸟瞰图投影三个视角评估生成的 LiDAR 场景质量。重要的是，我们使用第 3.3 节中新提出的语义感知指标对生成的带标签 LiDAR 场景进行评估，包括 S-FRD、S-FPD、S-MMD 和 S-JSD。对于所有指标，数值越低表示生成质量越好。注意，LiDM [16] 生成的样本仅包含深度图，这使得它们无法在基于视距的基准中评估，因为 RangeNet++ [17] 编码器需要反射率通道作为输入。

4.2 实验结果

在 SemanticKITTI 上的评估。我们在表 1 中报告了在 SemanticKITTI [34] 数据集上的实验结果。尽管参数量最小仅为 61M，Spiral 在所有语义相关指标上均取得最佳表现，分别在 S-FRD、S-FPD 和 S-JSD 上比两步方法 R2DM [18] 与 SPVCNN++ [57] 高出 31.03%、56.33% 和 50.94%。针对仅评估未标注 LiDAR 场景的先前指标，Spiral 在大多数指标上也优于 R2DM，表明额外的语义预测任务并未损害深度和反射率图像的生成质量。令人惊讶的是，更先进的分割模型 SPVCNN++ 在 LiDARGen [15] 和 LiDM [16] 生成的未标注场景上表现反而不如 RangeNet++，导致在语义相关指标上成绩较差。我们将此性能下降归因于更大模型对噪声更敏感，同时 LiDARGen 与 LiDM 生成的 LiDAR 场景中噪声更大。尽管在基于抖动的微调后 SPVCNN++ 的性能有所提升，但仍落后于 RangeNet++。对该问题的进一步讨论见附录。图 5 中展示的 Spiral 与其他基线方法生成的有标签 LiDAR 场景证明了 Spiral 在几何和语义方面的优越性。

在 nuScenes 上的评估。我们在表 2 中报告了 nuScenes [35] 数据集的实验结果。

表 1 在 SemanticKITTI [34] 数据集上与最先进 LiDAR 生成模型的比较。我们使用视野图 (Range View)、笛卡尔 (Cartesian) 和鸟瞰图 (BEV) 表示评估方法。符号 $\dagger$ 和 $\ddagger$ 分别表示 RangeNet++ [32] 主干和 SPVCNN++ [57] 主干。参数量包含生成和分割模型。每项指标的最佳和次佳得分分别以粗体和下划线标出。

方法	参数 (M)	NFE	视野图				笛卡尔				BEV			
			FRD $\downarrow$ ($\times 1$)	MMD $\downarrow$ ($\times 10^{-2}$)	S-FRD $\downarrow$ ($\times 1$)	S-MMD $\downarrow$ ($\times 10^{-2}$)	FPD $\downarrow$ ($\times 1$)	MMD $\downarrow$ ($\times 10^{-1}$)	S-FPD $\downarrow$ ($\times 1$)	S-MMD $\downarrow$ ($\times 10^{-1}$)	JSD $\downarrow$ ($\times 10^{-2}$)	MMD $\downarrow$ ($\times 10^{-3}$)	S-JSD $\downarrow$ ($\times 10^{-2}$)	S-MMD $\downarrow$ ($\times 10^{-3}$)
LiDARGen $\dagger$ [15]	30+50	1160	681.37	47.87	1216.61	35.65	115.17	46.37	710.791	52.711	13.23	2.19	28.65	10.96
LiDARGen $\ddagger$ [15]	30+97				1708.05	61.42			366.17	03.12			54.84	68.16
LiDM $\dagger$ [16]	275+50	256	-	-	-	-	108.70	33.87	458.33	28.60	4.56	0.29	16.69	5.59
LiDM $\ddagger$ [16]	275+97				-	-			522.47	32.39			21.03	6.23
R2DM $\dagger$ [18]	31+50	256	<u>192.81</u>	4.93	559.26	11.56	<u>19.29</u>	2.30	363.16	15.00	3.73	0.16	18.13	3.91
R2DM $\ddagger$ [18]	31+97				555.09	11.50			351.73	14.06			18.67	3.97
螺旋 (本方法)	61	256	170.18	4.81	382.87	4.10	8.06	1.10	153.61	3.20	3.76	0.15	9.16	1.41





图5 在 SemanticKITTI [34] 上生成的 LiDAR 场景可视化。对于两步法，我们使用 RangeNet++ [32] 生成的标签，因为其性能优于 SPVCNN++ [57]。伪影以虚线框标出。语义伪影示例见 (7)、(8)、(9)和(1)，而几何伪影如局部畸变和大量噪声见10和12。

Spiral 在所有指标上始终优于其他基线方法，且参数量最小。与第二名方法 (R2DM [18] & RangeNet++ [32]) 相比，Spiral 在 S-FRD、S-FPD 和 S-JSD 上分别提升了49.03%、67.84% 和 46.79%。图6 展示了 Spiral 与基线方法生成的场景以供定性比较，显示了 Spiral 在几何和语义方面的优越性能。

生成式数据增强。我们评估了使用 Spiral 生成样本来扩充 SemanticKITTI [34] 上分割学习训练集的有效性。以 SPVCNN++ [57] 作为分割骨干网络，在不同可用真实标注数据比例下，我们将 Spiral 与 R2DM [18] 和 RangeNet++ [32] 进行比较。如表 3 第一行所示，Spiral 生成的样本持续提升了 SPVCNN++ 的性能，且优于 R2DM 生成的样本。每类详细结果见附录。此外，我们在 Robo3D [53] 的分布外子集（雾天与湿地面）上以相同设置评估了 SPVCNN++。如表 3 的第二和第三行所示，尽管 Spiral 并未针对如此极端的天气条件进行微调，其生成的数据仍然丰富了训练集并在这些挑战性场景下提升了性能。

表2 在 nuScenes [35] 数据集上与最先进的 LiDAR 生成模型的比较。我们评估了基于距离视图、笛卡尔视图和 BEV 表示的方法。符号 † 和 ‡ 分别表示 RangeNet++ [32] 主干和 SPVCNN++ [57] 主干。参数量包含生成模型和分割模型。每项指标中的最好和第二好成绩分别以加粗和下划线标出。

方法	参数 (M)	NFE	距离视图				笛卡尔视图				BEV			
			FRD ₁ (×1)	MMD ₁ (×10 ⁻¹)	S-FRD ₁ (×1)	S-MMD ₁ (×10 ⁻¹)	FPD ₁ (×1)	MMD ₁ (×10 ⁻¹)	S-FPD ₁ (×1)	S-MMD ₁ (×10 ⁻¹)	JSD ₁ (×10 ⁻²)	MMD ₁ (×10 ⁻³)	S-JSD ₁ (×10 ⁻²)	S-MMD ₁ (×10 ⁻³)
LiDARGen [†] [15]	30+50	1160	188.80	3.03	1381.42	29.63	26.52	12.23	1395.83	92.311	3.98	0.15	37.37	15.23
LiDARGen [‡] [15]	30+97				2133.04	50.20			2370.18	65.17			54.43	90.78
LiDM [†] [16]	275+50	256	-	-	-	-	124.95	90.14	1472.81	129.65	4.00	0.29	27.60	11.75
LiDM [‡] [16]	275+97		-	-	-	-			1823.77	147.36			32.42	13.61
R2DM [†] [18]	31+50	256	<u>157.52</u>	2.96	<u>871.25</u>	<u>19.14</u>	16.86	<u>5.61</u>	<u>866.33</u>	<u>75.36</u>	3.12	0.05	<u>17.14</u>	4.94
R2DM [‡] [18]	31+97				1108.43	25.27			1198.16	100.38			35.83	17.70
螺旋 (本论文)	61	256	153.40	2.95	444.04	5.49	7.13	1.04	278.64	12.86	3.10	0.05	9.12	0.80



车 人行 自行车 摩托 真实地面 平坦 开放 空驶 客车 覆盖 载具 障碍 交通锥 拖车 旁边 地形 人造 可通行路面

图6 在 nuScenes [35] 上生成的 LiDAR 场景可视化。对于两步法，我们使用 RangeNet++ [32] 生成的标签，因为其性能优于 SPVCNN++ [57]。伪影用虚线框标出。语义伪影的例子见(8)、(1)和(12)，而局部畸变和大量噪声等几何伪影在(7)、(9)和(10)中有所示例。

4.3 实验分析

NFE 的影响。直观地，增加函数评估次数 (NFE) 会提升生成样本的质量，但会线性增加推理开销。我们在 {32, 64, 128, 256, 512, 1024} 上于 SemanticKITTI [34] 中评估了不同 NFE 设置下 Spiral 的性能。图 7 所示结果表明，当 $NFE < 256$ 时，Spiral 的性能显著提升，而在大多数度量上进一步增加 NFE 仅带来边际收益。因此，我们将 $NFE = 256$ 设为默认配置。在 A6000 GPU 上，Spiral 的平均推理速度为每个样本 5.7 秒。

闭环推理与开环推理。闭环推理是 Spiral 的一项关键创新，增强了跨模态一致性。为量化闭环推理的影响，我们禁用预测语义图作为条件输入反馈给 Spiral，在整个生成过程中保持开环推理。表 4 第一行列出的在 SemanticKITTI [34] 上的实验结果表明，采用开环设置会导致 Spiral 在所有指标上的性能下降，例如在 S-FRD 和 S-FPD 上分别下降了 3.34% 和 8.68%。

闭环推理中置信度阈值的影响。在闭环模式中，Spiral 采用基于置信度的过滤策略以排除在去噪过程早期阶段经常出现的不可靠语义图。为量化置信度阈值 δ 的影响，我们在 {0.3, 0.5, 0.6, 0.7, 0.8, 0.9} 中评估了不同 δ 设置下 Spiral 的性能。




图7 函数评估次数（NFE）的影响。增加NFE（32、64、128、256、512和1024）提高了所有指标的性能。在采样步数较少时，Spiral 在其默认NFE = 256 设置下优于R2DM [18]（以虚线表示）。注：横轴表示NFE，纵轴表示评估指标（值越低越好）。

表 4 中列出的结果表明 Spiral 在 $\delta \in \{0.7, 0.8, 0.9\}$ 时表现良好，并在 $\delta = 0.8$ 时略优。因此，我们将 $\delta = 0.8$ 设为 Spiral 的默认配置。然而，当 $\delta < 0.6$ 时 Spiral 的性能开始下降。使用 $\delta = 0.3$ 时，闭环推理的性能甚至落后于开环推理。

开/闭环模式切换点。我们对来自 SemanticKITTI 和 nuScenes 的各 1,000 个样本进行了统计分析。在默认 256 次去噪步数下，闭环推理在语义预测的 $\geq 80\%$ 超过置信阈值时被激活，平均在 SemanticKITTI 的第 180 ± 36 步和 nuScenes 的第 189 ± 39 步发生。这表明切换通常出现在生成过程的最后 $\sim 30\%$ 期间，此时语义预测已趋于稳定，从而避免了早期噪声并确保可靠的语义-几何对齐。

推理效率。我们在表5中报告了在 A6000 GPU 上 LiDARGen [15]、LiDM [16]、R2DM [18] 和 Spiral 的平均每样本采样时间。此外，在相同硬件上 RangeNet++ [32] 和 SPVCNN++ [57] 的每样本推理时间分别为 0.08s 和 0.05s。与两步法不同，Spiral 不需要分割模型来生成语义标签。Spiral 在推理效率上优于 LiDM 和 LiDARGen。尽管在使用相同生成步数时它比与 SPVCNN++ 结合的 R2DM 慢约 2.05 s，但在 128 步时 Spiral 仍然比 0.75 s 更快并且获得更高的生成质量。

表5 在 NVIDIA A6000 GPU 上 LiDARGen [15]、LiDM [16]、R2DM [18] 和 Spiral 的平均每样本采样时间。

方法	NFE	平均时间 (s)
LiDARGen [15]	1160	72.0
LiDM [16]	256	7.2
R2DM [18]	256	3.6
螺旋	256	5.7
螺旋	128	2.9

表 3 LiDAR 语义分割训练的生成式数据增强（GDA）。我们使用来自 R2DM [18] 和 Spiral 的合成样本评估 GDA，在不同真实标注数据比例（SemanticKITTI [34] 的 1%、10%、20%）下，以及来自 Robo3D [53] 的雾天和潮湿地面场景，遵循 LaserMix [7, 49] 的设置。符号 † 表示使用 RangeNet++ 作为分割模型。结果以 mIoU (%) 报告。

设置	1%			10%			20%		
GDA	w/o	R2DM† [18]	Spiral	w/o	R2DM† [18]	螺旋	w/o	R2DM† [18]	螺旋
SemanticKITTI	37.76	44.16	47.41	59.07	60.62	61.14	61.16	61.21	62.35
Robo3D（雾）	32.07	36.82	44.06	53.93	54.20	58.61	55.89	56.07	61.24
Robo3D（湿地）	34.26	37.96	44.19	54.70	55.92	59.31	56.81	57.53	62.02

表 4 闭环推理与置信度阈值的影响。每项指标下的最佳和次佳得分以加粗和下划线标示。高亮行表示 Spiral 的默认配置。

闭环	置信度阈值 δ	视距视图				笛卡尔				BEV			
		FRD $\downarrow$ ($\times 1$)	MMD $\downarrow$ ($\times 10^2$)	S-FRD $\downarrow$ ($\times 1$)	S-MMD $\downarrow$ ($\times 10^2$)	FPD $\downarrow$ ($\times 1$)	MMD $\downarrow$ ($\times 10$)	S-FPD $\downarrow$ ($\times 1$)	S-MMD $\downarrow$ ($\times 10$)	JSD $\downarrow$ ($\times 10^2$)	MMD $\downarrow$ ($\times 10^3$)	S-JSD $\downarrow$ ($\times 10^2$)	S-MMD $\downarrow$ ($\times 10^3$)
X	-	173.93	4.98	395.64	4.35	10.61	1.82	166.95	4.41	3.89	0.16	9.29	1.44
y	0.3	190.03	5.56	444.31	6.06	47.67	17.97	265.79	17.65	4.68	0.19	11.31	2.51
y	0.5	174.04	5.15	396.71	4.67	22.31	6.81	187.90	8.51	3.96	0.16	9.55	1.71
y	0.6	173.25	5.02	392.36	4.24	11.14	2.59	174.25	5.12	3.87	0.15	9.40	1.59
y	0.7	170.93	4.87	385.05	4.17	8.32	1.60	161.47	3.77	3.89	0.15	9.22	1.50
y	0.8	170.18	4.81	382.87	4.10	8.06	1.10	153.61	3.20	3.76	0.15	9.16	1.41
y	0.9	170.72	5.00	<u>384.42</u>	4.16	8.36	1.22	155.28	3.27	3.89	0.16	9.18	1.42

5 结论

我们提出 Spiral——首个语义感知的视距视图（range-view）LiDAR扩散模型，在统一框架内联合生成深度、反射率和语义标签。我们进一步引入新颖的语义感知评估指标，以实现生成质量的整体评估。通过在 SemanticKITTI 和 nuScenes 上的大量评估，Spiral 在多项几何和语义感知指标上以极小的模型规模达成了最先进的性能。此外，Spiral 在通过生成式数据增强用于下游分割任务时展现了强大的实用性，减少了对人工标注的依赖。我们认为 Spiral 为多模态 LiDAR 场景生成提供了新视角，并为可扩展、标注高效的 3D 感知开辟了有前景的方向。

附录

A 评估指标

在主文中，我们从三方面评估 Spiral 对 LiDAR 场景 x 与语义图 y 的生成质量：视距视图图像、笛卡尔点云与鸟瞰图（BEV）投影。这里我们详述每种表示的评估细节。

A.1 视距视图与笛卡尔点云的评估

对于视距图像和点云评估，我们通过将由 RangeNet++ [32] 或 PointNet [33] 提取的几何特征 $\mathcal{E}(x)$ 与 LiDM [16] 条件模块的语义特征 $\mathcal{G}(y)$ 级联，提取统一的语义感知特征 f^s ：

$$f^s \leftarrow \mathcal{E}(x) \oplus \mathcal{G}(y). \quad (10)$$

来自真实和生成集合的特征， $\{f^s\}_r$ 和 $\{f^s\}_g$ ，用于计算 S-FRD、S-FPD 和 S-MMD。S-FRD 的计算公式如下：

$$\text{S-FRD} = \|\mu_r - \mu_g\|_2^2 + \text{Tr} \left(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{\frac{1}{2}} \right), \quad (11)$$

其中 μ_r 和 μ_g 分别是 $\{f^s\}_r$ 与 $\{f^s\}_g$ ， Σ_r 的均值， Σ_g 是协方差矩阵， $\text{Tr}(\cdot)$ 是矩阵的迹。S-FPD 的计算遵循相同的公式。对于 S-MMD，可通过核技巧来度量：

$$\text{S-MMD} = \frac{1}{N^2} \sum_i^N \sum_{i'}^N k(f_i^s, f_{i'}^s) - \frac{2}{NM} \sum_i^N \sum_j^M k(f_i^s, f_j^s) + \frac{1}{M^2} \sum_j^M \sum_{j'}^M k(f_j^s, f_{j'}^s), \quad (12)$$

其中 N 和 M 分别是真实集与生成集中的样本数。参照 [18]，我们使用三阶多项式核函数：

$$k(f^s, f^{s'}) = \left(\frac{(f^s)^T \cdot f^{s'}}{d_f} + 1 \right)^3, \quad (13)$$

其中 d_f 为 f^s 的维度。

A.2 鸟瞰图 (BEV) 上的评估

对于基于 BEV 的评估，我们首先为真实集与生成集 $\{h^s\}_r$ 和 $\{h^s\}_g$ 计算语义感知直方图，然后计算基于 BEV 的 S-JSD 与 S-MMD。S-JSD 的计算如下：

$$\text{JSD}(P||Q) = \frac{1}{2} D_{KL}(P||M) + \frac{1}{2} D_{KL}(Q||M), \quad (14)$$

where P and Q are the approximation of Gaussian distribution on $\{h^s\}_r$ and $\{h^s\}_g$, and M is the mean of them: $M = \frac{1}{2}(P + Q)$.

B 数据预处理

在本节中，我们将提供关于数据预处理的更多细节。对于 SemanticKITTI [34] 和 nuScenes [35]，我们首先将原始点云投影到包含深度、反射强度和语义通道的视距图像。然后我们对深度和反射强度通道做重新缩放，并将语义图编码为 RGB 图像。

B.1 深度和反射强度通道的重新缩放

对于深度通道，我们首先将视距深度图像 x^d 转换为对数尺度表示 $x_{\log}^d$ ，如下所示：

$$x_{\log}^d = \frac{\log(x^d + 1)}{\log(x_{\max}^d + 1)}, \quad (15)$$

其中 $x_{\max}^d$ 是最大深度值。然后我们将反射率、辐射强度和对数缩放深度图线性重缩放到 $[-1, 1]$ 。

B.2 语义编码

对于语义通道，我们使用官方配色方案将独热语义图 $y \in \mathbb{R}^{H \times W \times C}$ 转换为二维 RGB 图像，其中 C 是类别数。值得注意的是，Spiral 在有条件和无条件模式下都进行训练，在无条件模式中 RGB 图像被零填充。为区分无条件模式中零填充的图像与有条件模式中语义图的黑色区域，我们增加了一个额外通道以指示是否提供了语义图。

C 模型架构细节

C.1 空间特征编码

我们采用四层 Efficient U-Net [64] 作为 Spiral 的骨干网络，中间特征维度分别为 128、256、384 和 640。每层由三个残差块组成，沿行列方向各下采样两倍。用于生成残差与语义预测的预测头由一个 2D 卷积层随后接一个两层 MLP 构成。

表6 在 SemanticKITTI [34] 数据集上, 使用不同抖动尺度训练的 RangeNet++ [32]、SPVCNN++ [57] 和 RangeViT [28] 的性能。

生成模型	分割主干	抖动尺度	距离图视图		笛卡尔坐标		BEV	
			S-前端 减少 $\downarrow(\times 1)$	S-中间减 少 $\downarrow(\times 10^{-2})$	S-后端 减少 $\downarrow(\times 1)$	S-中间减 少 $\downarrow(\times 10^{-1})$	S-坚守 减少 $\downarrow(\times 10^{-2})$	S-中间减 少 $\downarrow(\times 10^{-3})$
LiDARGen [15]	RangeNet++ [32]	默认	1216.61	35.65	710.79	52.71	28.65	10.96
		大	1202.45	34.97	702.38	50.03	28.49	10.85
	SPVCNN++ [57]	默认	1978.13	70.33	1826.54	210.67	56.40	68.97
		large	1708.05	61.42	1366.17	103.12	54.84	68.16
	RangeViT [28]	默认	2034.15	72.09	1726.54	195.44	55.20	67.47
		large	1891.42	70.17	1625.27	187.02	54.13	65.09

C.2 时序特征编码

对于时序和坐标编码, 我们沿用 R2DM [18] 的策略。对于坐标编码, 我们将每个像素的方位角和仰角映射为 32 维傅里叶特征 [71], 然后与输入数据拼接。具体地, 扩散时间步被编码为 256 维正弦位置嵌入, 并在每一层通过自适应组归一化 (AdaGN) [72] 模块整合。

D 关于两步法 LiDAR 生成中最先进分割模型的讨论

在两步方法中, 主论文报告了使用 RangeNet++ [32] 和 SPVCNN++ [57] 作为分割骨干的结果。尽管 SPVCNN++ 在真实世界数据集上优于 RangeNet++, 但在 LiDARGen [15] 和 LiDM [16] 的生成 LiDAR 场景上表现较差。本节我们进一步展示了 RangeNet++、SPVCNN++ 以及一款最先进的分割模型 RangeViT [28] 在 LiDARGen 生成场景上的性能。我们观察到增大抖动尺度可以提升 SPVCNN++ 的鲁棒性, 因此我们用默认抖动和增大抖动尺度两种方式训练所有模型。

D.1 实验设置

我们使用所有模型的官方实现。在默认设置下, RangeNet++ 和 RangeViT 在没有抖动增强的情况下训练, 而 SPVCNN++ 使用高斯噪声抖动进行训练, 其中 $\sigma = 0.1$ 。在更大尺度抖动的设置中, 我们将所有模型的抖动 σ 增加到 0.3。

D.2 观察与分析

RangeNet++、SPVCNN++ 和 RangeViT 在不同抖动尺度下的详细结果见表6。尽管对 SPVCNN++ 和 RangeViT 进行更强抖动的微调 ($\sigma = 0.3$) 提升了它们的性能, 但它们仍落后于 RangeNet++, 而 RangeNet++ 在生成样本上表现出最佳的鲁棒性。这些实验结果表明, 在“干净”的真实场景上取得高性能的分割模型并不一定能在生成场景上表现良好。这突显了将最先进分割模型的预测作为评估生成场景的伪“真值”的局限性。相反, 如本文所提出, 通过度量真实场景与生成场景之间语义感知特征的分布相似性, 能为预测语义图的质量提供更可靠的评估。

E 额外的定性结果

在本节中，我们展示了生成的反射强度图的更多可视化结果，以及更多生成的 LiDAR 场景示例及其对应的语义图。

E.1 反射强度图的可视化

我们在图 8 中展示了在 SemanticKITTI [34] 上生成的反射强度图。由于 LiDM 不产生反射强度图，我们仅展示 Spiral、LiDARGen [15] 和 R2DM [18] 的结果。其中，Spiral 在深度、反射强度和语义标签之间表现出较强的跨模态一致性。相比之下，LiDARGen 和 R2DM 生成的场景经常在模态间出现伪影和不一致，如红色框所示。

E.2 生成的 LiDAR 场景可视化

我们在图 9 和图 10 中分别展示了在 SemanticKITTI [34] 和 nuScenes [35] 上更多生成的 LiDAR 场景。生成的 LiDAR 场景的几何和语义伪影用虚线框标出。

F 生成式数据增强

F.1 全监督设置

在表 7 中，我们报告了在 SemanticKITTI [34] 数据集上，对 SPVCNN++ [57] 的分割训练中使用两步法（RangeNet++ [32] 与 R2DM [18]）和 Spiral 生成样本进行生成式数据增强的实验结果。我们使用全监督方法训练 SPVCNN++。除了不同比例的可用真实有标签数据（1%, 10%, 20%）外，我们还用生成样本（10k）扩充真实数据子集。结果表明，Spiral 生成的样本持续提升 SPVCNN++ 的性能，并优于 R2DM 生成的样本。

F.2 半监督设置

Spiral 中的两个开关 $\mathcal{A}$ 和 $\mathcal{B}$ 提供了在无条件与有条件模式之间切换的高灵活性。在完全监督训练中——所有输入样本都有语义标签时， $\mathcal{A}$ 与 $\mathcal{B}$ 以异或（X-OR）方式工作：(1) 在无条件模式下， $\mathcal{A}$ 关闭且 $\mathcal{B}$ 打开；(2) 在有条件模式下， $\mathcal{A}$ 打开且 $\mathcal{B}$ 关闭。当两个开关都关闭时（ $\mathcal{A} = 0$ and $\mathcal{B} = 0$ ），Spiral 退化为一个普通的无条件 LiDAR 生成模型，即非标注模式。该设计使 Spiral 支持半监督训练。具体来说，当只有一小部分训练样本有标签（例如 10%）时，Spiral 在有标签数据上按主文中描述的有条件或无条件模式进行训练，并在剩余未标注样本上按非标注模式进行训练。

我们在训练集中仅对 10% 的样本标注标签，其余样本不标注来训练 Spiral。对于两步基线方法，生成模型在完整训练集上训练，而分割模型仅在标注的 10% 子集上训练。表 8 的结果表明，在这种情况下 Spiral 的生成性能持续优于其他基线两步方法。

此外，我们利用在半监督设置下训练的 Spiral 所生成的样本，来扩充最先进半监督 LiDAR 分割框架 LaserMix [49] 的标注训练集。我们采用 MinkUNet [25] 和 FIDNet [73] 作为分割骨干。表 9 的实验结果表明，在 LaserMix 框架中引入 Spiral 生成的样本，进一步提升了 MinkUNet 和 FIDNet 的性能。




图8 在 Se-manticKITTI [34] 的视距图视角中生成的深度、反射强度与语义标签的可视化。生成伪影与跨模态不一致处以边框标注。




图9 在SemanticKITTI [34]上生成的 LiDAR 场景可视化。




图10 在 nuScenes [35] 上生成的 LiDAR 场景可视化。

表7 用于分割训练的生成式数据增强（GDA）。我们评估了在不同真实标注数据比例（1%、10%、20%）下，使用 R2DM [18] 和 RangeNet++ [32] 及 Spiral 生成的合成样本对 GDA 有效性的影响。符号 † 表示使用 RangeNet++ [32] 作为分割骨干。

设置 (GDA)		1%			10%			20%		
		无	R2DM†	Spiral	无	R2DM†	螺旋	无	R2DM†	螺旋
mIoU		37.76	44.16	47.41	59.07	60.62	61.14	61.16	61.21	62.35
每类 mIoU	汽车	89.82	87.65	92.87	94.52	94.53	95.13	95.78	94.52	96.03
	自行车	0.00	0.00	12.67	25.04	43.23	31.57	25.92	42.62	34.07
	摩托车	13.98	23.36	25.68	62.78	55.99	55.47	66.22	58.98	58.50
	卡车	24.15	7.93	47.92	52.89	49.40	60.19	50.53	48.44	57.82
	其他车辆	15.50	29.60	33.71	42.06	52.30	53.58	55.85	51.19	55.44
	行人	25.82	28.56	26.18	68.32	60.25	61.87	69.48	65.98	73.85
	骑自行车者	0.00	53.54	0.00	82.72	77.55	86.07	88.02	83.32	85.20
	摩托车骑士	1.97	0.00	0.20	0.00	0.26	0.00	0.00	1.52	0.00
	道路	78.37	86.14	92.79	91.59	92.55	93.23	92.95	92.64	93.42
	停车场	15.41	18.99	51.05	38.99	43.49	47.73	43.61	43.03	47.94
	人行道	60.78	70.56	79.61	77.87	79.90	80.62	79.96	79.72	80.52
	其他地面	0.01	0.25	0.67	4.21	2.09	1.30	2.11	3.31	1.40
	建筑	79.20	86.93	88.38	88.58	90.40	90.52	89.87	90.13	90.03
	围栏	32.62	52.14	53.14	56.13	62.22	61.82	59.80	60.77	60.45
	植被	83.62	86.28	88.07	87.97	89.49	89.82	88.35	89.21	88.69
	树干	52.78	46.19	61.62	66.11	66.58	68.27	66.29	66.69	68.51
	地形	69.38	72.84	77.67	74.97	78.36	78.28	75.63	77.74	75.34
	杆	54.32	44.96	54.26	63.03	61.80	62.81	64.27	62.12	63.85
	交通标志	19.77	43.12	14.21	44.61	51.44	43.44	47.39	51.01	53.66

G 更广泛的影响与局限性

在本节中，我们阐述所提出方法的更广泛影响、社会影响及潜在局限性。

G.1 更广泛的影响

本工作对自动驾驶和计算机视觉的学术研究与实际应用具有若干重要意义。SPIRAL 通过提出一个用于联合生成深度、反射强度与语义标签的统一框架，推进了 LiDAR 场景生成领域。该突破可能会显著影响：

1. 研究社区

- 为语义感知的 LiDAR 生成建立新的基准
- 提供用于多模态场景理解的新框架
- 为 3D 场景生成与理解开启新的研究方向

2. 工业应用

- 降低对昂贵且耗时的人工数据标注的依赖

表 8 在 SemanticKITTI [34] 数据集上对 Spiral 和基线两步方法的半监督训练。我们使用视野范围（Range View）、笛卡尔（Cartesian）和 BEV 表示来评估方法。符号 † 表示用 10% 标注样本训练的 RangeNet++[32]。参数量包括生成模型和分割模型。

方法	参数 (M)	NFE	视野范围		笛卡尔		BEV	
			S-FRD↓ ×1	S-MMD↓ ×10 ⁻²	S-FPD↓ ×1	S-MMD↓ ×10 ⁻¹	S-JSD↓ ×10 ⁻²	S-MMD↓ ×10 ⁻³
LiDARGen † [15]	30+50	1160	1285.55	47.56	750.68	58.26	34.49	12.66
LiDM † [16]	275+50	256	-	-	486.22	29.78	16.91	6.33
R2DM† [18]	31+50	256	528.82	7.82	281.96	8.95	16.13	2.99
Spiral	61	256	508.86	5.77	211.97	4.79	11.47	2.65

表 9 在 LaserMix [49] 框架下用于半监督训练的生成式数据增强（GDA）。我们在半监督训练框架 LaserMix 中评估由 Spiral 生成的合成样本的 GDA 效果。

主干网络	MinkUNet [25]			FIDNet [73]		
方法	仅监督	LaserMix [49]	LaserMix +Spiral	仅监督	LaserMix [49]	LaserMix +Spiral
mIoU	64.0	66.6	67.2	52.2	60.1	60.3

- 促进自动驾驶系统更高效的开发
- 为合成数据生成提供具有成本效益的方案

图 G.2 社会影响

SPIRAL 的开发可能带来若干积极的社会影响：

1. 交通安全

- 通过更好的训练数据增强自动驾驶车辆的感知能力
- 通过改善场景理解可能减少交通事故

2. 经济影响

- 降低数据采集的开发成本
- 加速自动驾驶车辆的部署

G.3 潜在限制

尽管 SPIRAL 展示了令人鼓舞的结果，但应当承认若干限制和挑战：

1. 技术约束：生成场景的质量仍有提升空间。
2. 方法学限制：生成数据可能无法完全涵盖所有现实世界的复杂性。
3. 实施挑战：实际应用中的实时性能考量。

这项工作语义感知的 LiDAR 场景生成上是重要的一步，但也承认仍需持续研究以解决这些限制与挑战。未来的工作可聚焦于提升模型在处理复杂场景时的能力与提高计算效率，同时保持生成质量。

H 公共资源使用

在本节中，我们承认在本工作过程中使用了以下公共资源：

H.1 使用的公共数据集

- nuScenes¹ CC BY-NC-SA 4.0
- nuScenes-DevKit² Apache 许可证 2.0
- SemanticKITTI³ 署名-非商业性使用-相同方式共享 4.0 国际 (CC BY-NC-SA 4.0)
- SemanticKITTI-API⁴ MIT 许可证
- Robo3D5 CC BY-NC-SA 4.0

H.2 使用的公共实现

- MMDetection⁶ Apache License 2.0
- MMDetection3D⁷ Apache License 2.0
- RangeNet++⁸ MIT 许可证
- OpenPCSeg Apache 许可证 2.0
- RangeViT¹⁰ Apache 许可证 2.0
- LiDARGen¹¹ MIT 许可证
- LiDM¹² MIT 许可证
- R2DM¹³ MIT 许可证

¹ <https://www.nuscenes.org/nuscenes>.

² <https://github.com/nutonomy/nuscenes-devkit>.

³ <http://semantic-kitti.org>.

⁴ <https://github.com/PRBonn/semantic-kitti-api>.

⁵ <https://github.com/worldbench/robo3d>.

⁶ <https://github.com/open-mmlab/mmdetection>.

⁷ <https://github.com/open-mmlab/mmdetection3d>.

⁸ <https://github.com/PRBonn/lidar-bonnetal>.

⁹ <https://github.com/PJLab-ADG/OpenPCSeg>.

¹⁰ <https://github.com/valeoai/rangevit>.

¹¹ <https://github.com/vzyrianov/lidargen>.

¹² <https://github.com/hancyran/LiDAR-Diffusion>.

¹³ <https://github.com/kazuto1011/r2dm>.

参考文献

- [1] T. Feng, W. Wang, 和 Y. Yang, “自动驾驶世界模型综述,” arXiv 预印本 arXiv:2501.11260, 2025.
- [2] A. Xiao, X. Zhang, L. Shao, 和 S. Lu, “面向三维点云的标注高效深度学习综述,” IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024.
- [3] B. Fei, W. Yang, L. Liu, T. Luo, R. Zhang, Y. Li, 和 Y. He, “用于三维点云预训练的自监督学习综述,” arXiv 预印本 arXiv:2305.04691, 2023.
- [4] Y. Guo, H. Wang, Q. Hu, H. Liu, L. Liu, 和 M. Bennamoun, “三维点云深度学习综述,” IEEE Transactions on Pattern Analysis and Machine Intelligence, 卷 43, 期 12, 页 4338-4364, 2020.
- [5] R. Li, S. Li, L. Kong, X. Yang, and J. Liang, "SeeGround: See and ground for zero-shot open-vocabulary 3Dvisual grounding," arXiv preprint arXiv:2412.04383, 2024.
- [6] L. Kong, X. Xu, J. Cen, W. Zhang, L. Pan, K. Chen, and Z. Liu, "Calib3D: Calibrating model preferences for reliable 3D scene understanding," in IEEE/CVF Winter Conference on Applications of Computer Vision, pp. 1965-1978, 2025.
- [7] L. Kong, X. Xu, J. Ren, W. Zhang, L. Pan, K. Chen, W. T. Ooi, and Z. Liu, "Multi-modal data-efficient 3D scene understanding for autonomous driving," IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 47, no. 5, pp. 3748-3765, 2025.
- [8] X. Wang 等人, “通过掩码递归网络实现单目语义场景完成,”发表于 IEEE/CVF 国际计算机视觉大会, 页 24811-24822, 2025。
- [9] B. Gao, Y. Pan, C. Li, S. Geng, 和 H. Zhao, “我们是否渴求用于语义分割的 3D LiDAR 数据? 数据集与方法综述,”IEEE 智能交通系统学报, 卷 23, 期 7, 页 6063-6081, 2021。
- [10] D. J. Yeong, G. Velasco-Hernandez, J. Barry, 和 J. Walsh, “自动驾驶车辆中的传感器与传感器融合技术: 综述,”Sensors, 卷 21, 期 6, 页 2140, 2021。
- [11] K. Muhammad, T. Hussain, H. Ullah, J. D. Ser, M. Rezaei, N. Kumar, M. Hijji, P. Bellavista, and V. H. C. de Albuquerque, "基于视觉的语义分割在自动驾驶场景理解中的应用: 近期成果、挑战与展望," IEEE Transactions on Intelligent Transportation Systems, vol. 23, no. 12, pp. 22694-22715, 2022.
- [12] Y. Liu, L. Kong, J. Cen, R. Chen, W. Zhang, L. Pan, K. Chen, and Z. Liu, "通过蒸馏视觉基础模型对任意点云序列进行分割," in Advances in Neural Information Processing Systems, vol. 36, pp. 37193-37229, 2023.
- [13] X. Xu, L. Kong, H. Shuai, W. Zhang, L. Pan, K. Chen, Z. Liu, and Q. Liu, "4D 对比超流是稠密 3D 表示学习者," in European Conference on Computer Vision, pp. 58-80, 2024.
- [14] J. Ho, A. Jain 与 P. Abbeel, “Denoising diffusion probabilistic models”, 载于 Advances in Neural Information Processing Systems, 第33卷, 第6840-6851页, 2020年。
- [15] V. Zyrianov, X. Zhu 与 S. Wang, “学习生成逼真的 LiDAR 点云”, 载于 European Conference on Computer Vision, 第17-35页, Springer, 2022年。
- [16] H. Ran, V. Guizilini 与 Y. Wang, “面向逼真场景生成的 LiDAR 扩散模型”, 载于 IEEE/CVF Conference on Computer Vision and Pattern Recognition, 第14738-14748页, 2024年。
- [17] Q. Hu, Z. Zhang 与 W. Hu, “RangeLDM: 快速逼真的 LiDAR 点云生成”, arXiv 预印本 arXiv:2403.10094, 2024年。
- [18] K. Nakashima and R. Kurazume, "使用去噪扩散概率模型合成 LiDAR 数据," in IEEE International Conference on Robotics and Automation, pp. 14724-14731, 2024.
- [19] L. Nunes, R. Marcuzzi, J. Behley, and C. Stachniss, "面向自动驾驶生成真实 3D 语义训练数据," arXiv preprint arXiv:2503.21449, 2025.
- [20] Y. Liu et al., "La La LiDAR: 从 LiDAR 数据生成大规模布局," arXiv preprint arXiv:2508.03691, 2025.

- [21] A. Liang 等, “视角不变的三维目标检测,” 载于 IEEE/CVF 国际计算机视觉会议, 第 27725-27738 页, 2025.
- [22] J. Lee, S. Lee, C. Jo, W. Im, J. Seon, 和 S.-E. Yoon, “SemCity: 基于三平面扩散的语义场景生成,” 载于 IEEE/CVF 计算机视觉与模式识别会议, 第 28337-28347 页, 2024.
- [23] X. Ren, J. Huang, X. Zeng, K. Museth, S. Fidler, 和 F. Williams, “XCube: 使用稀疏体素层级的大规模三维生成建模,” 载于 IEEE/CVF 计算机视觉与模式识别大会论文集, 第 4209-4219 页, 2024.
- [24] H. Bian, L. Kong, H. Xie, L. Pan, Y. Qiao, 和 Z. Liu, “DynamicCity: 来自动态场景的大规模 4D 占据生成,” 载于 国际学习表征会议, 2024.
- [25] C. Choy, J. Gwak, and S. Savarese, “4D 时空卷积网络: Minkowski 卷积神经网络,” 载于 IEEE/CVF 计算机视觉与模式识别会议, 第 3075-3084 页, 2019.
- [26] J. Sun, C. Qing, X. Xu, L. Kong, Y. Liu, L. Li, C. Zhu, J. Zhang, Z. Xiao, R. Chen, 等, “当前最先进 LiDAR 分割模型的训练实证研究,” arXiv 预印本 arXiv:2405.14870, 2024.
- [27] Y. Li, L. Kong, H. Hu, X. Xu, and X. Huang, “你的 LiDAR 布置是否为 3D 场景理解优化?,” 载于《神经信息处理系统进展》(Advances in Neural Information Processing Systems), 卷 37, 第 34980-35017 页, 2024.
- [28] A. Ando, S. Gidaris, A. Bursuc, G. Puy, A. Boulch, and R. Marlet, “RangeViT: 面向自动驾驶中三维语义分割的视觉变换器,” 收录于 IEEE/CVF 计算机视觉与模式识别会议, 页码 5240-5250, 2023.
- [29] L. Kong, Y. Liu, R. Chen, Y. Ma, X. Zhu, Y. Li, Y. Hou, Y. Qiao, and Z. Liu, “重新思考 LiDAR 分割的距离视图表示,” 收录于 IEEE/CVF 国际计算机视觉大会, 页码 228-240, 2023.
- [30] X. Xu, L. Kong, H. Shuai, and Q. Liu, “FRNet: 可扩展 LiDAR 分割的截锥-距离网络,” IEEE 图像处理汇刊, 卷 34, 页码 2173-2186, 2025.
- [31] X. Xu 等, “超越单次观测与单一视角: 跨视角与长时域蒸馏以提升 LiDAR 表征,” 载于 IEEE/CVF 国际计算机视觉会议, 第 25506-25518 页, 2025.
- [32] A. Milioto, I. Vizzo, J. Behley, 和 C. Stachniss, “RangeNet++: 快速且准确的 LiDAR 语义分割,” 载于 IEEE/RSJ 国际智能机器人与系统会议, 第 4213-4220 页, 2019.
- [33] C. R. Qi, H. Su, K. Mo, 和 L. J. Guibas, “PointNet: 面向点集的三维分类与分割深度学习,” 载于 IEEE/CVF 计算机视觉与模式识别大会, 第 652-660 页, 2017.
- [34] J. Behley, M. Garbade, A. Milioto, J. Quenzel, S. Behnke, C. Stachniss, and J. Gall, “SemanticKITTI: 用于 LiDAR 序列语义场景理解的数据集,” 载于 IEEE/CVF 国际计算机视觉会议, 页码 9297-9307, 2019.
- [35] H. Caesar, V. Bankiti, A. H. Lang, S. Vora, V. E. Liong, Q. Xu, A. Krishnan, Y. Pan, G. Baldan, and O. Beijbom, “nuScenes: 用于自动驾驶的多模态数据集,” 载于 IEEE/CVF 计算机视觉与模式识别会议, 页码 11621-11631, 2020.
- [36] Y. Liu, L. Kong, X. Wu, R. Chen, X. Li, L. Pan, Z. Liu, and Y. Ma, “朝向通用 LiDAR 分割的多空间对齐,” 载于 IEEE/CVF 计算机视觉与模式识别会议, 页码 14648-14661, 2024.
- [37] D. Zhu, Q. Khan 与 D. Cremers, “利用状态与意图信息在交叉口进行多车轨迹预测与控制,” Neurocomputing, 第574卷, 页127220, 2024年。
- [38] D. Zhu, G. Zhai, Y. Di, F. Manhardt, H. Berkemeyer, T. Tran, N. Navab, F. Tombari 与 B. Busam, “IPCC-TP: 利用增量皮尔逊相关系数进行联合多主体轨迹预测,” 载于 IEEE/CVF 计算机视觉与模式识别会议论文集, 页5507-5516, 2023年。
- [39] A. Hyvärinen 与 P. Dayan, “通过得分匹配估计非归一化统计模型,” Journal of Machine Learning Research, 第6卷第4期, 2005年。
- [40] Y. Wu, K. Zhang, J. Qian, J. Xie, and J. Yang, “Text2LiDAR: 基于等矩形变换器的文本引导 LiDAR 点云生成,” in European Conference on Computer Vision, pp. 291-310, Springer, 2024.
- [41] B. Li, J. Guo, H. Liu, Y. Zou, Y. Ding, X. Chen, H. Zhu, F. Tan, C. Zhang, T. Wang, et al., “UniScene: 以占用为中心的統一驾驶场景生成,” arXiv preprint arXiv:2412.05435, 2024.

- [42] L. Wang, W. Zheng, Y. Ren, H. Jiang, Z. Cui, H. Yu, and J. Lu, "OccSora: 4D occupancy generation models as world simulators for autonomous driving," arXiv preprint arXiv:2405.20337, 2024.
- [43] W. Zheng, W. Chen, Y. Huang, B. Zhang, Y. Duan, and J. Lu, "OccWorld: Learning a 3D occupancy world model for autonomous driving," arXiv preprint arXiv: 2311.16038, 2023.
- [44] H. Tang, Z. Liu, X. Li, Y. Lin, and S. Han, "TorchSparse: Efficient point cloud inference engine," in Conference on Machine Learning and Systems, 2022.
- [45] H. Tang, S. Yang, Z. Liu, K. Hong, Z. Yu, X. Li, G. Dai, Y. Wang, and S. Han, "TorchSparse++: Efficient training and inference framework for sparse convolution on GPUs," in IEEE/ACM International Symposium on Microarchitecture, 2023.
- [46] G. Puy, A. Boulch, and R. Marlet, "使用华夫格进行汽车点云语义分割," in IEEE/CVF 国际计算机视觉大会, pp. 3379-3389, 2023.
- [47] D. P. Kingma, M. Welling, et al., "自编码变分贝叶斯," 2013.
- [48] W. Peebles and S. Xie, "具有变换器的可扩展扩散模型," in IEEE/CVF 国际计算机视觉大会论文集, pp. 4195-4205, 2023.
- [49] L. Kong, J. Ren, L. Pan, and Z. Liu, "用于半监督激光雷达语义分割的 LaserMix," in IEEE/CVF 计算机视觉与模式识别会议, pp. 21705-21715, 2023.
- [50] H. Cheng, X. Han, and G. Xiao, "CENet: 面向自动驾驶的简洁高效激光雷达语义分割," in IEEE 国际多媒体与博览会, pp. 1-6, 2022.
- [51] Y. Zhang, Z. Zhou, P. David, X. Yue, Z. Xi, B. Gong, and H. Foroosh, "PolarNet: 一种改进的栅格表示用于在线 LiDAR 点云语义分割," 载于 IEEE/CVF 计算机视觉与模式识别会议, 页 9601-9610, 2020.
- [52] X. Zhu, H. Zhou, T. Wang, F. Hong, Y. Ma, W. Li, H. Li, and D. Lin, "用于 LiDAR 分割的柱状与不对称 3D 卷积网络," 载于 IEEE/CVF 计算机视觉与模式识别会议, 页 9939-9948, 2021.
- [53] L. Kong, Y. Liu, X. Li, R. Chen, W. Zhang, J. Ren, L. Pan, K. Chen, and Z. Liu, "Robo3D: 面向对抗损坏的稳健可靠 3D 感知," 载于 IEEE/CVF 国际计算机视觉会议, 页 19994-20006, 2023.
- [54] F. Hong, L. Kong, H. Zhou, X. Zhu, H. Li, and Z. Liu, "通过动态位移网络实现统一的三维与四维全景分割," IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 46, no. 5, pp. 3480-3495, 2024.
- [55] M. Jaritz, T.-H. Vu, R. de Charette, E. Wirbel, and P. Pérez, "xMUDA: 用于三维语义分割的跨模态无监督领域自适应," in IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 12605-12614, 2020.
- [56] M. Jaritz, T.-H. Vu, R. de Charette, E. Wirbel, and P. Pérez, "用于三维语义分割领域自适应的跨模态学习," IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 45, no. 2, pp. 1533-1544, 2023.
- [57] Y. Liu, R. Chen, X. Li, L. Kong, Y. Yang, Z. Xia, Y. Bai, X. Zhu, Y. Ma, Y. Li, Y. Qiao, and Y. Hou, "UniSeg: 一个统一的多模态 LiDAR 分割网络及 openpcseg 代码库," 在 IEEE/CVF 国际计算机视觉大会, 页 21662-21673, 2023.
- [58] R. Chen et al., "CLIP2Scene: 通过 CLIP 实现面向标签高效的 3D 场景理解," 在 IEEE/CVF 计算机视觉与模式识别会议, 页 7020-7030, 2023.
- [59] G. Puy, S. Gidaris, A. Boulch, O. Siméoni, C. Sautier, P. Pérez, A. Bursuc, and R. Marlet, "Three pillars: 提升视觉基础模型蒸馏用于 LiDAR 的方法," 在 IEEE/CVF 计算机视觉与模式识别会议, 页 21519-21529, 2024.
- [60] L. Li, H. P. Shum, and T. P. Breckon, "RAPiD-Seg: 面向三维 LiDAR 分割的基于距离分布的逐点感知范围网络," in European Conference on Computer Vision, pp. 222-241, 2024.
- [61] V. E. Liong, T. N. T. Nguyen, S. Widjaja, D. Sharma, and Z. J. Chong, "AMVNet: 基于断言的多视图融合网络用于 LiDAR 语义分割," arXiv preprint arXiv:2012.04934, 2020.

- [62] Q. Hu, B. Yang, L. Xie, S. Rosa, Y. Guo, Z. Wang, N. Trigoni, and A. Markham, "RandLA-Net: 高效的大规模点云语义分割," 载于 IEEE/CVF 计算机视觉与模式识别会议, 页码 11108-11117, 2020.
- [63] H. Tang, Z. Liu, S. Zhao, Y. Lin, J. Lin, H. Wang, and S. Han, "使用稀疏点体素卷积搜索高效的 3D 架构," 载于 欧洲计算机视觉会议, 页码 685-702, 2020.
- [64] C. Saharia, W. Chan, S. Saxena, L. Li, J. Whang, E. L. Denton, K. Ghasemipour, R. Gontijo Lopes, B. Karagol Ayan, T. Salimans, et al., "具有深度语言理解的逼真文本到图像扩散模型," 载于 神经信息处理系统进展, 卷 35, 页码 36479-36494, 2022.
- [65] D. Baranchuk, I. Rubachev, A. Voynov, V. Khruikov, and A. Babenko, "使用扩散模型的标注高效语义分割", arXiv 预印本 arXiv:2112.03126, 2021。
- [66] D. Zhu, Y. Di, S. Gavranovic 和 S. Ilic, "Sealion: 面向语义部件的潜在点扩散模型用于 3D 生成", 载于计算机视觉与模式识别大会论文集, 页 11789-11798, 2025。
- [67] L. Kong, W. Yang, J. Mei, Y. Liu, A. Liang, D. Zhu, D. Lu, W. Yin, X. Hu, M. Jia 等, "3D 与 4D 世界建模: 综述", arXiv 预印本 arXiv:2509.07996, 2025。
- [68] D. Zhu, S. Gavranovic, F. Boussuge, B. Busam, and S. Ilic, "用于物体点云分割的生成式数据增强," arXiv 预印本 arXiv:2505.17783, 2025.
- [69] D. P. Kingma and J. Ba, "Adam: 一种用于随机优化的方法," 载于 International Conference for Learning Representations, 2015.
- [70] J. Song, C. Meng, and S. Ermon, "去噪扩散隐式模型," arXiv 预印本 arXiv:2010.02502, 2020.
- [71] M. Tancik, P. Srinivasan, B. Mildenhall, S. Fridovich-Keil, N. Raghavan, U. Singhal, R. Ramamoorthi, J. Barron, and R. Ng, "傅里叶特征使网络在低维域中学习高频函数," Advances in Neural Information Processing Systems, vol. 33, pp. 7537-7547, 2020.
- [72] P. Dhariwal 和 A. Nichol, "扩散模型在图像合成上胜过 GAN," 神经信息处理系统进展, 卷. 34, 页. 8780-8794, 2021.
- [73] Y. Zhao, L. Bai 和 X. Huang, "FIDNet: 基于完全插值解码的 LiDAR 点云语义分割," 见 IEEE/RSJ 国际智能机器人与系统会议, 页. 4453-4458, 2021.